为什么需要生物数据库

生物数据库是生命科学研究领域中十分重要的资源。我们不讲如何创建生物数据库，我们只讲如何使用数据库，比如什么时候该用什么数据库，如何在数据库中查找想要的信息，以及如何解读这些信息。

首先我们来看看这密密麻麻的是什么玩意儿!这是DNA序列,你猜对了吗？确切的说，这是HIV-one病毒的整个基因组，包含了9752个碱基，编码9个基因。差不多一页A4纸，正反面打印就可以把这九千多个碱基记录下来。当然，病毒的基因组是很小的。与之相比，我们人的基因组就要大得多了，有多大呢？3个G，也就是30亿个碱基。如果一页A4纸打印5000个碱基的话，我们需要打印60万页，才能把整个人的基因组打印完。如果600页装订一本书，60万页得装订1000本书。这样的一本书厚度大约在3厘米左右，那么1000本3cm厚的书摆在一起有30米长，比一节和谐号火车的车厢是还要长。这只是一个物种的基因组，目前已经有超过1000个物种通过测序技术获得了全部基因组序列。那么就需要至少200个五层30米宽的书架。这相当于两个山东大学趵突泉校区图书馆的藏书。即使我们建一个足够大的图书馆，把所有的基因组天书全都放进去了。可是还有比基因组大好几倍的注释信息呐！没有这些注释，天书无法解读。就算把这些注释也都塞进去，现在给你一条DNA序列，让你到图书馆里去找找，他是哪个基因组里面的，找的到吗？

所以这些庞大的信息不能放在实体店里，而只能放在线上，放在数据库里。事实上两个图书馆也装不下的基因组序列，一块3T的硬盘就搞定了。当然把数据放进硬盘只是完成了数据库的收集工作。收入的数据要能方便的访问，要能根据各种条件进行搜索，当然有变动或有新注释的时候还要能够更新。这样一个存储数据的空间加上一套完善的管理系统才能构成一个完整的数据库系统。因此我们说，生物数据库是被组织起来的大量生物数据，这些数据通过计算机可被方便的访问、管理及更新。

讲到这里，加入一个小插曲。我们一起来熟悉一下这些天文数字单位。这些单位到处都能用到，日常生活中也是，尤其是从千到拍。千 kilo，你应该很熟悉，kilometer，一千米。一千简称1K。1000 个K，是1兆，简称1M。1000个M是1G。1000个G是1T，1000个T是1P，依次1000倍1000倍的往上增长。谁是谁的1000倍，一定要记清楚，千万不要搞混。