一级核酸数据库：GenBank 真核生物核酸序列 mRNA

我们浏览真核生物的核酸序列。真核生物的基因与原核生物不同，是非线性排列的，也就是基因里有外显子和内含子。因此真核生物核酸序列的数据库记录要要比原核生物复杂。有时需要几条记录拼凑在一起才能描述出一个完整的基因。我们先来看看编码人 dUTPase 的成熟 mRNA 序列。成熟 mRNA 是已经剪切掉内含子，只剩外显子的序列，所以这条成熟 mRNA 序列和我们之前看到的原核生物的 DNA 序列从拓扑结构上看是几乎一样的，都是线性的。输入这条成熟 mRNA 序列的检索号 U90223，搜索！

打开数据库记录，基本的注释内容和原核生物的差不多，这里只挑两点特别的地方说一下。大家看到 **KEYWORDS** 后面只有一个点。这个点提示我们，数据库并不是完美的，所有数据库都存在数据不完整的问题。再有，**JOURNAL** 后面我们看到是写的是未正式发表。但事实上，这篇文章早在 1997 年就已经发表在 JBC 上了。因此，忠言逆耳：别指望 Genbank 或任何一个数据库能够百分百做到数据无误且实时更新。

Features 里的注释内容与原核生物的数据库记录相似，**CDS** 指出了从 63 到 821 是一段编码区，在这段编码区里基因是连续的，因为是经过剪切后的成熟 mRNA，它将被翻译成线粒体型 dUTPase 蛋白。下面**/translation** 里给出的是计算机翻译出的该蛋白的序列。

在 Features 里还有两个新的条目之前没有见到过。**sig_peptide** 和 **mat_peptide**。sig_peptide，也就是 signal peptide，指出了编码信号肽的碱基的位置。信号肽决定了蛋白质的亚细胞定位，也就是蛋白质工作的地方。mat_peptide，也就是 mature peptide，指出了编码成熟肽链的碱基的位置。他从信号肽后面开始，到编码区结尾提前三个碱基结束。编码区一直到第 821 号碱基，而编码成熟蛋白的最后一个碱基是第 818 号碱基，这中间差了 3 个碱基，那最后的这三个碱基干嘛去了呢？编码区的最后三个碱基是终止密码子，不翻译。这条真核生物序列的 Genbank 注释看起来和原核生物的差不多，这是因为我们很小心的挑了一条成熟 mRNA 的序列。