一级核酸数据库：GenBank 真核生物核酸序列 DNA

基因组里的 DNA 序列，是非线性分布的基因序列。我们仍然浏览编码人的 dUTPase 的 *dut* 基因序列。输入检索号 AF018430，搜索！

这个检索号下的序列标题是“人 *dut* 基因的第三号外显子”。人的 *dut* 基因肯定包含多个外显子，而当前的这条 DNA 序列里只包含了一个外显子。其他的外显子在别的数据库记录里。从 **SEGMENT** 处可以看到，人的 *dut* 基因序列被分成了 4 个片段，并且分别存储在 4 条数据库记录中。也就是说，只有把四个片段全部凑在一起，才能拼凑出完整的基因。当前这条数据库记录是所有四个片段里的第二个。这个片段里只包含一个外显子，是第三号外显子。需要注意的是，一个片段可以只包含一个外显子，也可以包含不止一个外显子。另外，这个例子告诉我们，LOCUS 和 ACCESSION 是可以不相同的。

从 **FEATURES** 里可以找到这个序列片段在染色体上的具体位置。是在 15 号染色体的长臂上，位置在 15 到 21.1 条带之间。

GENE 这部分指出了拼出完整基因所需的所有四个片段的检索号，以及具体的位置。也就是 AF018429 这条序列的 1 到 1735 号碱基，连上当前这条序列的 1 到 1177 号碱基，连上 AF018431 这条序列的 1 到 45 号碱基，连上 AF018432 这条序列的 658 到 732 号碱基和 884 到 954 号碱基，以及 1391 到 1447 号碱基。后面给出了基因的名字，*dut*。

mRNA 给出了拼凑出上面基因的各个片段中外显子的位置。也就是说，GENE 里的片段拼在一起是完整的基因，mRNA 里的片段拼在一起就等于完成了剪切的过程，相当于成熟 mRNA。值得注意的是，剪接后形成的 mRNA 有两种，其中一种比另一种在前端多了一个外显子。多的这一段将被翻译成定位线粒体的信号肽，从而翻译出线粒体型的蛋白质。而另一种没有信号肽的将形成细胞核型蛋白质。

Mitochondrial or Nuclear dUTPase mRNAs in AF018430

Mrna	*AF018429*	*AF018430*	*AF018431*	*AF018432*
Type 1 (Mitochondria)	282-561 1034-1172	560-651	1-45	658-732 884-954 1391-1447 ->
Type 2 (Nuclear)	<1018- 1172	560-651	1-45	658-732 884-954 1391-1447 ->

上表清晰的列出了四个片段中所有外显子的位置。能够清楚的看到，线粒体型的比细胞核型的多了一个翻译信号肽的外显子，其他的翻译成熟肽段的外显子都是一样的。虽然信号肽最终也会被切掉,但是由此产生了两种亚细胞定位的蛋白质。有信号肽的会到线粒体中去，没有的将留在细胞核里。

最后 **exon** 条目明确的告诉我们，当前这条序列里 560 到 651 号碱基是 *dut* 基因的第三个外显子。至此，大家应该看得出来，解读真核生物的 DNA 序列要比原核生物复杂得多。但是，只要你熟知基因的结构和 Genbank 的存储方式，这本天书不难看懂。