一级蛋白质序列数据库：UniProt 数据库介绍

上次课我们讲了核酸数据库。这节课我们来讲蛋白质数据库。蛋白质数据库的种类比核酸数据库要多，但它的注释要比核酸数据库直白得多。像核酸数据库一样，蛋白质数据库也分为一级和二级。一级蛋白质数据库又分为蛋白质序列数据库和蛋白质结构数据库。这两种数据库里存放的都是通过实验方法直接获得的基础数据。而二级蛋白质数据库都是在一级数据库的基础上分析加工出来的。我们首先来看一级蛋白质序列数据库。一级蛋白质序列数据库包含三大蛋白质序列数据库，Swiss-Prot，TrEMBL 和 PIR，这三个数据库共同构成 UniProt 数据库。

Swiss-Prot 是一个人工注释的蛋白质序列数据库。它拥有注释可信度高，冗余度小的优点。它是由欧洲生物信息学研究所 EBI 与瑞士生物信息学研究所 SIB 共同管理的。TrEMBL 也是 EBI 和 SIB 共同管理的一个数据库，他与 Swiss-Prot 的区别是：TrEMBL 里的蛋白质序列注释是由计算机完成的，它包含了 EMBL 核酸序列数据库中为蛋白质编码的核酸序列的所有翻译产物。换言之，TrEMBL 是通过计算机，把核酸序列数据库里能编码蛋白的核酸序列都翻译成了蛋白质序列，然后把这些计算机翻译出来的蛋白质序列存入其中。可想而知，这样的数据库一定是可信度低而冗余度大的。好在 TrEMBL 把已经包含在 Swiss-Prot 数据库中的序列剔除掉了。也就是在 Swiss-Prot 里已经有人工注释的蛋白质序列在 TrEMBL 里就不再出现了。PIR 数据库是蛋白质信息资源数据库，他设在美国 Georgetown 大学医学中心。是一个支持基因组学，蛋白质组学和系统生物学研究的综合公共生物信息学资源。

2002 年，Swiss-Prot 和 TrEMBL 的数据库管理组与 PIR 的数据库管理组成立联合蛋白质数据库协作组，管理联合蛋白质序列数据库，也就是 UniProt 数据库。UniProt 数据库有三个层次。第一层叫 UniParc，收录了所有 UniProt 数据库子库中的蛋白质序列，量大，粗糙。第二层是 UniRef，他归纳了 UniProt 几个主要数据库并且是将重复序列去除后的数据库。第三层是 UniProtKB，他有详细注释并与其他数据库有链接，分为 UniProtKB 下的 Swiss-Prot 和 UniProtKB 下的 TrEMBL 数据库。关系稍有点复杂，但实际上我们最常用的就是 UniProtKB 下的 Swiss-Prot 数据库。