序列相似性

认识了序列就要开始比较了，可是我们为什么要比较它们呢？比较的目的是为了**找相似**。特别是从一大堆序列里找相似，这就是数据库中的序列相似性搜索。在学习如何比较序列之前，我们先看一个游戏。麻将泰坦这个游戏不知道你玩过没有。就是从最外围没有被压住或挡住的麻将中找出两个相同的消掉。比如图 1 中最上面的二条和右下角的二条。我们很容易就用眼睛找到了。



图 1. 麻将泰坦游戏找想相同

但是，如果给你一条序列，蛋白质序列也好，核酸序列也罢，让你从数据库中找到与它相同或相似的序列。这就不是能用眼睛去完成的了，因为数据库中的序列实在是太多。上一章我们了解到 UniProtKB 下属的数据库中，蛋白质序列的数量是惊人的。别说从这里面找了，就是让你用眼睛比较一对序列都是不可能做到的。所以我们需要特殊的算法，特殊的工具，在尽可能准确的前提下，快速找到相似的序列。

假设我们已经找到相似的序列了，那接下来又能干什么呢，也就是说找到这些相似的序列有什么意义呢？意义在于，相似的序列往往起源于一个共同的祖先。它们很可能有相似的空间结构和生物学功能。因此，对于一个已知序列但未知结构和功能的蛋白质，如果与它序列相似的某些蛋白质的结构和功能已知，那么就可以推测出这个未知结构和功能的蛋白质的结构和功能。简言之，相似的序列意味着相似的结构，相似的结构意味着相似的功能。当然，这也存在例外，比如两个人可能长得很相似，但其他方面相差甚远。要说两个人有多相似，

可以很相似，也可以很不相似，但是没有办法量化。不过，序列有多相似是可以量化的。

我们用一致度（identity）和相似度（similarity）这两个指标来定量描述序列有多相似。我们先从最简单的情况入手，看看如何计算一致度和相似度。如果两个序列长度相同，那么它们的一致度可以暂时定义为它们对应位置上相同的残基数目占总长度的百分比。一个残基就是指一个字母（氨基酸或碱基）。比如下面这两条序列中，

```
序列 1 : CLHK
序列 2 : CIHL
```

上下相同的残基位置有 2 个，序列长度为 4。它们的一致度就是 2 除以 4，50%。再看相似度，如果两个序列长度相同，那么它们的相似度可以暂时定义为他们对应位置上相似的残基与相同的残基的数目和占总长度的百分比。这里，相同好找，但是相似怎么找呢？比如 L 和 I 是否相似？K 和 L 是否相似呢？要解决这个问题，我们需要替换记分矩阵。