BLAST 搜索：BLAST 是怎么样工作的？

这一节我们来看这个早就听说过，但是还一直没见过的 BLAST。之前我们提到，从一堆麻将牌中找出一对儿二条并不难。但是从数据库中找出一对儿相似的序列，就没那么简单了。我们已经学会如何做双序列比对，那可不可以拿一条序列和数据库中的每条序列逐一进行双序列比对，通过这种方法来找相似呢？这确实是一个办法。这样我们只要根据比对后得出的相似度排序，就可以找到最相似的那条序列了。但是，这种方法因计算耗时过长，只是理论上可行而已。之前我们用 EMBL 的双序列比对工具做全局比对，虽然很快就出结果了，但至少也要经历一两秒钟的时间。而数据库中有几百万条序列，全部比对一遍，耗时太长。因此，我们需要快速的数据库相似性搜索工具。目前世界上广泛使用的就是 BLAST。它可以在尽可能准确的前提下，快速的从数据库中找到跟某一条序列相似的序列。

国际上著名的生物数据库网站都提供 BLAST 在线搜索服务。在第二章数据库这一章里，搜索序列都是在搜索条里输入关键词，包括序列的名字或者序列的编号。但是，在实际应用中，更多时候，输入值是一条序列。想要找到这条序列在数据库中的相关注释，是不能把这条序列直接放到搜索条里搜索的。这个时候就得用 BLAST 搜索了！

BLAST 是 Basic Local Alignment Search Tool 的首字母缩写，直译过来就是基本局部比对搜索工具。BLAST 的基本原理很简单，要点是片段对的概念。所谓片段对是指两个给定序列中的一对子序列，它们的长度相等，且可以形成无空位的完全匹配。图 1-A 中方框里的就是两个片段对。BLAST 从头至尾将两条序列扫描一遍并找出所有片段对，并在允许的阈值范围内对片段对进行延伸，最终找出高分值片段对（high-scoring pairs, HSPs）（图 1-B）。这样的计算复杂度是 n 的一次方（n 是序列的长度）。如果做双序列比对话需要构建一个 n 乘以 n 的表格，计算复杂度是 n 的二次方。所以找高分值片段对比做双序列比对节省了大量的时间，当然，前提是牺牲了一定的准确度。

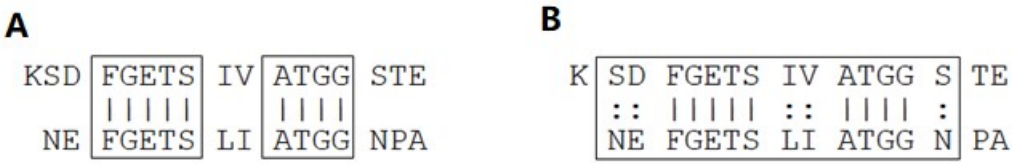


图 1. 片段对及高分值片段对