Ontoprotein:基于基因本体嵌入的蛋白质预训练

张宁宇 [1、2、3*] **bizhen** [2、3*] **梁晓纯** [2、3*] **程思源** [2、3*] **洪浩森** [4] **邓淑敏** [1、3] **张强** [1、4] **连家彰** [4] **陈华军** [1、3、4†]

[1] 浙江大学计算机科学与技术学院

[2] 浙江大学软件技术学院

[3] 阿里巴巴-浙江大学前沿技术联合研究院

[4] 浙江大学杭州创新中心

摘要

自监督蛋白质语言模型已经证明了其在学习蛋白质表示方面的有效性。随着计算能力的不断增强，目前用数百万个不同序列预训练的蛋白质语言模型可以将参数规模从百万级提升到十亿级，并取得显著的提升。然而，那些流行的方法很少考虑纳入知识图谱(KGs)，它可以为更好的蛋白质表示提供丰富的结构化知识事实。本文认为，KGs 中的信息性生物学知识可以与外部知识增强蛋白质表示。在这项工作中，我们提出了 **OntoProtein**，这是第一个将 GO(基因本体)中的结构用于蛋白质预训练模型的通用框架。我们构建了一个新的大规模知识图谱，由 GO 及其相关蛋白质组成，基因注释文本或蛋白质序列描述了图中的所有节点。本文提出了具有知识感知负采样的新型对比学习，以在预训练期间联合优化知识图谱和蛋白质嵌入。实验结果表明，OntoProtein 可以在 TAPE 基准中超过最先进的预训练蛋白质语言模型的方法，并在蛋白质相互作用和蛋白质功能预测 [1] 方面与基线相比产生更好的性能。

1 介绍

蛋白质科学是控制生物学和生命本身的基本大分子，它在理解疾病治疗和人类健康方面取得了显著进展(Vig et al.(2021))。作为氨基酸序列，蛋白质可以被精确地视为一种语言，这表明它们可能是使用为自然语言处理(NLP)开发的神经网络进行建模的。最近的自监督预训练蛋白质语言模型(plm)，如 ESM (Rao et al. (2021b))、ProteinBERT (Brandes et al.(2021))、ProtTrans (Elnaggar et al.(2020))可以学习强大的蛋白质表示，在理解蛋白质的结构和功能方面取得了有希望的结果。然而，现有的用于蛋白质表示学习的 plm 通常不能充分捕捉生物学事实知识，这对许多蛋白质任务至关重要，但通常是稀疏的，并且在序列中具有多样化和复杂的形式。

相比之下，来自基因本体 [2] 的知识图谱(KGs)包含广泛的生物结构事实，而知识嵌入(KE)方法(Bordes 等人(2013)，Zheng 等人(2021))可以有效地将它们嵌入到实体和关系的连续向量中。例如，如图 1 所示，在不知道 *PEX5* 具有特定的生物过程和细胞成分的情况下，它

* 平等贡献和共同第一作者。

† 相应的作者。

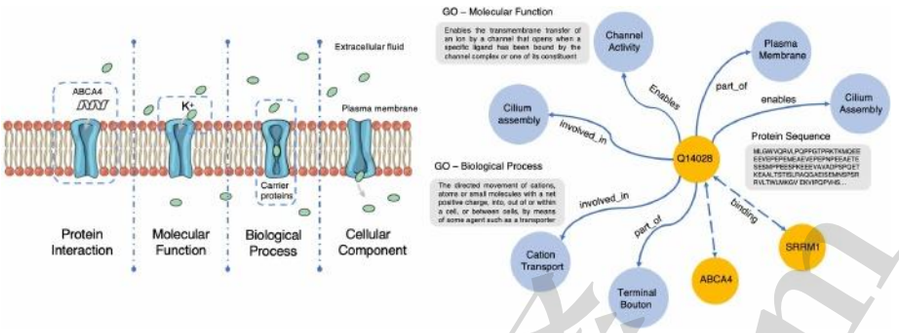


图 1:**左**:具有生物学知识(分子功能、生物过程和细胞成分)的蛋白质示例:K^+ (钾离子)环核苷酸门控阳离子通道蛋白。**右**:**ProteinKG25** 中关于$^+$ k 载体蛋白的对应子图。**黄色**节点是蛋白质序列，**蓝色**节点是带有生物描述的 GO(基因本体)实体。

识别它与其他蛋白质的相互作用是一个挑战。此外，由于*蛋白质的形状决定了它的功能*，因此，有了具有相似形状的蛋白质功能的先验知识，模型识别蛋白质的功能会更加方便。因此，考虑丰富的知识可以导致更好的蛋白质表示，并有利于各种生物学应用，例如蛋白质接触预测、蛋白质功能预测和蛋白质-蛋白质相互作用预测。然而，不同于 NLP 中的知识增强方法(Zhang et al. (2019b)， Wang et al. (2021b)， Wang et al. (2021a))，蛋白质序列和基因本体是两种不同类型的数据。注意，蛋白质序列是由氨基酸组成的，而基因本体是带有文本描述的知识图谱;因此，结构化知识编码和异质信息融合仍然存在严重问题。

本文首次提出了基于基因本体嵌入的蛋白质预训练**(OntoProtein)**，这是第一个将外部知识图谱整合到蛋白质预训练中的通用框架。我们提出了一个混合编码器来表示语言文本和蛋白质序列，并引入了知识感知负采样的对比学习，以在预训练期间联合优化知识图谱和蛋白质序列嵌入。对于 KE 目标，我们将节点描述(go 注释)编码为其相应的实体嵌入，然后按照 vanilla KE 方法优化它们(Bordes et al.(2013))。我们进一步利用了分子功能、细胞成分和生物过程的基因本体，并为 KE 目标引入了一种知识感知的负采样方法。对于 MLM(掩码语言建模)目标，我们遵循现有蛋白质预训练方法的方法(Rao et al. (2021b))。OntoProtein 具有以下优点:

(1) OntoProtein 继承了具有 MLM 对象的 plm 对蛋白质的强大理解能力。(2)利用 KE 对象，在 KG 的监督下，OntoProtein 可以将生物学知识融入到蛋白质表示中。(3) OntoProtein 构成了一种与模型无关的方法，可以很容易地插入到广泛的蛋白质任务中，而不需要额外的推理开销，因为我们没有修改模型架构，而是添加了新的训练目标。

对于预训练和评估 OntoProtein，我们需要一个与蛋白质序列对齐的大规模生物学知识事实的知识图谱。因此，我们构建了 **ProteinKG25**，其中包含约 612,483 个实体、4,99097 个三元组和来自 GO 注释的对齐节点描述。据我们所知，这是第一个用于促进蛋白质预训练的大规模 KG 数据集。我们为归纳和转导设置提供了数据分割，以促进未来的研究。

总而言之，我们的贡献有三个方面:(1)提出了 OntoProtein，这是第一个知识增强的蛋白质预训练方法，为广泛的蛋白质任务带来了有希望的改进。(2)通过知识感知采样的对比学习来联合优化知识和蛋白质嵌入，OntoProtein 在广泛的下游任务中显示了其有效性，包括蛋白质功能预测、蛋白质相互作用预测、接触预测等。(3)构建并发布了全新的大规模 KG 数据集 ProteinKG25，促进了

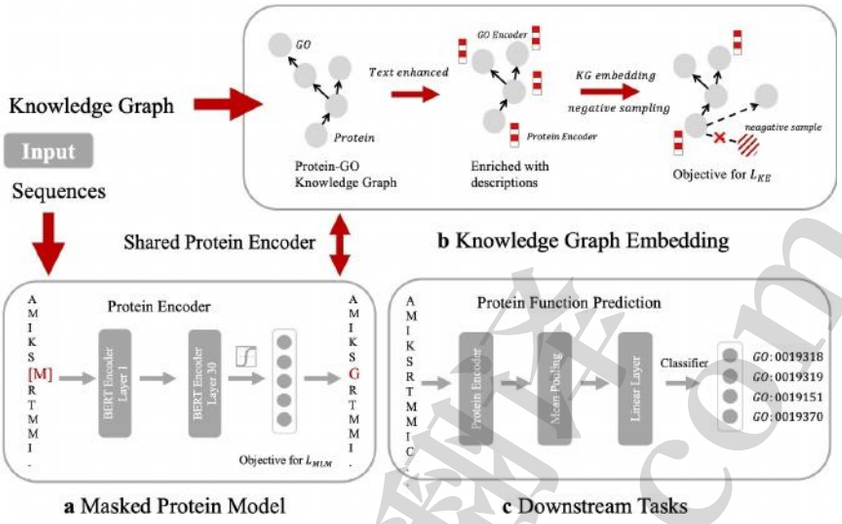


图 2:我们提出的联合优化知识图谱嵌入和掩码蛋白质模型的 OntoProtein 的概述(彩色显示效果最好)。

蛋白质语言预训练的研究。(4)在广泛的蛋白质任务中进行了广泛的实验，包括 TAPE 基准、蛋白质-蛋白质相互作用预测和蛋白质功能预测，这些实验证明了所提出方法的有效性。

2 方法

我们开始介绍我们的带有本体嵌入(OntoProtein)的蛋白质预训练方法，如图 2 所示。OntoProtein 通过联合优化两个目标，将来自基因本体(Go)的外部知识整合到语言表示中。我们将首先介绍混合编码器、掩码蛋白质建模和知识编码器，然后我们将介绍知识感知负采样的对比学习的细节。最后，我们将说明整体的预训练对象。

2.1 混合编码器

首先引入混合编码器来表示蛋白质和 GO 知识;对于蛋白质编码器，我们使用 Elnaggar 等人(2020)的预训练 ProtBert。ProtBert 使用带有 UniRef100 数据集的 BERT 架构进行预训练。与 BERT Devlin 等人(2019)相比，ProtBert 将氨基酸序列编码为 token 级或句子级表示，可用于下游蛋白质任务，如接触预测任务。编码器采用 N 个 token 的蛋白质序列(x_1，…， x_N)作为输入，并计算上下文化的羊水酸表示手 p^i_{rotein} 序列表示 $Hvia_{P\ rotein}$ 均值*池化*。为了弥合文本和蛋白质之间的差距，我们利用仿射变换(一个额外的线性层)将这些表示投影到相同的空间。我们将在 Section Mask 蛋白质建模中讨论学习蛋白质表示的细节。对于 Go 编码器，我们利用 BERT (Devlin et al.(2019))、基于 Transformer (Vaswani et al.(2017))的文本编码器用于基因本体实体中的生物描述。具体来说，我们利用了来自(Gu et al.(2020))的预训练语言模型。[3]编码器 $_1$ 采用 N个 token 的序列(x，…， x)作为输入，并通过对所有 $_{GO}$ token 嵌入 $^{N^{X}d}$ 进行平均来计算 $_N$ Go表示 H∈r。

[3] https://huggingface.co/microsoft/BiomedNLP-PubMedBERT-base-uncased-abstract-fulltext

由于基因本体中的关系对于表示生物学特征的知识很重要，因此，我们利用了一个具有随机初始化的关系编码器，并且这些关系的嵌入将在预训练期间进行优化和更新。

2.2 知识嵌入

我们利用知识嵌入(KE)目标在预训练过程中获得表示，因为基因本体实际上是一个事实知识图谱。与 Bordes 等人(2013)类似，我们使用分布式表示对实体和关系进行编码。这里的知识图谱由大量的三元组组成，用来描述关系事实。我们将三元组定义为(h, r, t)，其中 h 和 t 是头和尾实体，r 是关系，其类型通常在模式 [4] 中预先定义。注意，在我们的知识图谱中有**两种不同类型的节点** eGO 和 eprotein。eGO 表示为存在于基因本体中的节点，如分子功能或细胞成分节点，可以通过注释 GO 文本进行描述。Eis 是连接到 protein 基因本体的蛋白质节点，我们也用羊水酸序列来表示 Eis。protein 具体来说，这个知识图谱中的三元组可以分为两组，tripleGO2GO 和 tripleP rotein2GO。为了将多模态描述整合到相同的语义空间中，并解决异构信息融合问题，我们利用了上一节介绍的混合编码器。注意，蛋白质编码器和 GO 编码器分别表示蛋白质序列和 GO 注释。

2.3 掩码蛋白质建模

我们使用掩码蛋白质建模来优化蛋白质表示。掩码蛋白质建模类似于掩码语言建模(MLM)。在模型预训练期间，我们使用 15%的概率来掩码每个标记(氨基酸)，并利用交叉熵损失'MLM 来估计这些掩码标记。我们用 ProtBert 的预训练模型初始化我们的模型，并 MLM 通过联合训练 KE(知识嵌入)和 MLM 将`作为 OntoProtein 的总体目标之一。我们的方法是与模型无关的，也可以利用其他预训练模型。

2.4 基于知识感知负采样的对比学习

知识嵌入(KE)是学习实体和关系的低维表示，而对比估计代表了一种可扩展且有效的推断连通性模式的方法。请注意，对比学习方法的一个关键方面是选择生成硬负样本的腐败分布，这迫使嵌入模型学习有判别力的表示，并找到观察数据的关键特征。然而，之前的方法要么采用过于简单的腐败分布，即均匀的，产生容易的无信息的负性，要么采用具有挑战性优化方案的复杂的对抗性分布。因此，本文提出了基于知识感知负采样的对比学习，这是一种廉价的负采样策略，利用丰富的 GO 知识来采样负样本。形式上，KE 目标可以定义为:

$$\ell_{KE} = -\log\sigma(\gamma - d(h,t)) - \sum_{i=1}^{n}\frac{1}{n}\log\sigma(d(h'_i,t'_i) - \gamma) \tag{1}$$

(h^0_i, t^0_i)为负样本，在负样本中，头或尾实体被随机采样以构建腐败三元组。N 是负样本的数量，σ 是 sigmoid 函数，γ 表示间隔。d 是评分函数，为了简单起见，我们使用 TransE (Bordes et al.(2013))，其中

$$d_r(h,t) = \|h + r - t\| \tag{2}$$

具体来说，我们将三重集合和实体集合定义为 T 和 E，所有三重集合分为两组。如果头部实体是蛋白质节点，尾部实体是 GO 节点，我们将三重实体表示为 $t_{protein-GO}$。同样，如果头部和尾部实体都是 GO 节点，我们将它们表示为 t_{GO-GO}。由于基因本体描述了涉及三个方面的生物学领域的知识，基因本体中的所有实体都属于 MFO(分子功能)、CCO(细胞成分)或 BPO(生物过程)。

[4] 知识图谱的模式可以在附录 A.1 中找到

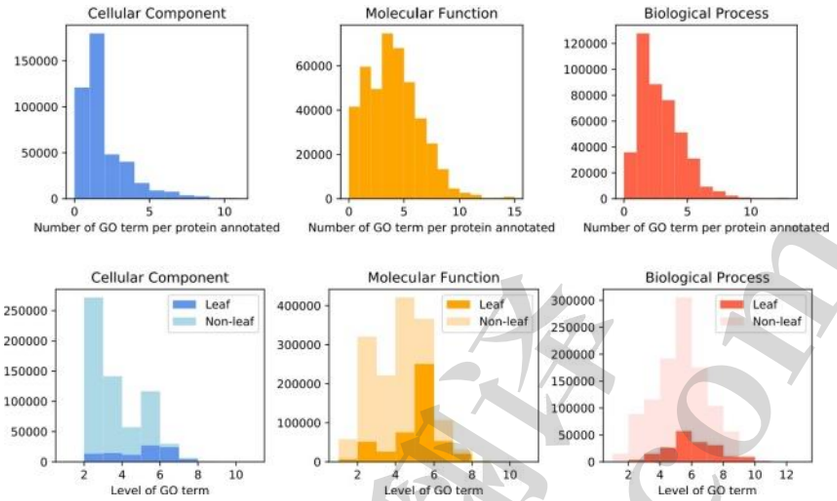


图 3:**上图**:GO 术语的数据分布。**下**:蛋白质-go 术语统计。

为了避免纯阴性样本，对于那些 GO-GO 三元组，我们通过替换具有相同方面(MFO, CCO, BPO)的实体来采样三元组[5]。最后，我们将负三组 t0 和正三组定义为(h, r, T)，负采样过程可以描述如下:

$$T'_{GO-GO(h,r,t)} = \{(h', r, t) \mid h' \in E', h \in E'\} \cup \{(h, r, t') \mid t' \in E', t \in E'\}$$
$$T'_{Protein-GO(h,r,t)} = \{(h, r, t') \mid t' \in E'\} \tag{3}$$

其中 E0∈{EMF 0, ECCO, EBPO}，我们只替换 TP 蛋白- GO 三元组的尾部实体。

2.5 预训练目标

我们采用掩膜蛋白建模对象和知识嵌入目标来构建 OntoProtein 的整体对象。我们联合优化整体对象如下:

$$\ell = \alpha \ell_{KE} + \ell_{MLM} \tag{4}$$

其中 α 是超参数。我们的方法可以嵌入到现有的微调场景中。

3 实验

大量的实验证明了我们方法的有效性。在预训练阶段，我们构建了一个新的知识图谱数据集，该数据集由基因本体和公开标注的蛋白质组成。我们提出的模型使用这个数据集进行了预训练，并在几个下游任务中进行了评估。评估了蛋白质功能预测、蛋白质相互作用和 TAPE 基准中的 OntoProtein (Rao et al.(2019))。

3.1 数据集

预训练数据集为了将基因本体知识纳入语言模型，我们构建了一个新的预训练数据集 ProteinKG256，这是一个大规模的 KG 数据集，分别具有对齐的描述和蛋白质序列，用于 GO terms7 和蛋白质实体。基因本体论

[5] 对于三元 protein-GO 组，用它们的同源蛋白替换蛋白质来生成硬负三元组也是很直观的，我们把这个留给以后的工作。

有道文档翻译 pdf.youdao.com

[6]https://zjunlp.github.io/项目/ProteinKG25/

[7]GO的结构可以用图来描述，图中的每个GO项是一个节点，项与项之间的关系是节点之间的边。

有道文档翻译 pdf.youdao.com

方法	结构		联系	进化	工程	
	SS-Q3	SS-Q8		同源性	影响稳定	
LSTM	0.75	0.59	0.26	0.26	0.67	0.69
带变压器	0.73	0.59	0.25	0.21	**0.68**	0.73
ResNet	0.75	0.58	0.25	0.17	0.21	0.73
MSA 变压器	-	**0.73**	**0.49**	-	-	-
ProtBert	0.81	0.67	0.35	**0.29**	0.61	**0.82**
OntoProtein	**0.82**	0.68	0.40	0.24	0.66	0.75

表 1:TAPE 基准测试结果。SS 是一个二级结构任务，在 CB513 中评估。在接触预测中，我们使用 P@L/2 指标测试中期和长程。在蛋白质工程任务中，我们使用斯皮尔曼 ρ 指标测试荧光和稳定性预测。

由一组 GO 术语(或概念)和它们之间的关系组成，例如，分子功能术语描述发生在分子水平上的活动。GO 注释是关于特定基因或基因产物功能的陈述，例如，基因产物“细胞色素 c”可以通过分子功能氧化还原酶活性来描述。由于基因本体和基因注释之间的联系，我们将这两种结构结合成一个统一的知识图谱。对于基因本体中的每个 GO 术语，我们将其与相应的名称和描述对齐，并通过冒号将它们连接起来作为一个完整的描述。对于基因注释中的每个蛋白质，我们将其与蛋白质知识库 Swiss-Prot[8] 对齐，并提取其对应的序列作为其描述。在 ProteinKG25 中，存在 4990,097 个三元组，其中包括 4,879,951 个 $T_{protein-GO}$ and 110146_{GO-GO} 个三元组。图 3 展示了我们的 ProteinKG25 的统计数据。详细的构建过程和预训练数据集的分析可以在附录 A.1 中找到。

下游任务数据集 我们使用 TAPE 作为基准(Rao 等人(2019))来评估蛋白质表示学习。TAPE 中有三种类型的任务，包括蛋白质的结构、进化和工程。继 Rao et al. (2021a)之后，我们选择了包括二级结构(SS)、接触预测在内的 6 个代表性数据集来评估 OntoProtein。

蛋白质-蛋白质相互作用(PPI)是在两个或更多蛋白质分子之间建立的具有高度特异性的物理接触;我们将 PPI 视为一个序列分类任务，并使用三个不同大小的数据集进行评估。STRING 由 Lv 等人(2021)构建，包含 15,335 个蛋白质和 593,397 个 ppi。我们还使用了由 Chen 等人(2019)生成的 SHS27k 和 SHS148k。

蛋白质功能预测旨在为蛋白质分配生物或生化角色，我们也将此任务视为序列分类任务。我们基于我们的 ProteinKG25 构建了一个新的评估数据集，遵循标准的 CAFA 协议(Zhou et al.(2019))。具体来说，我们设计了两种评估设置，转导设置和归纳设置，它们模拟了现实中基因注释的两种场景。在转导设置中，该模型可以生成具有实体描述的未见过的蛋白质实体的嵌入。相反，对于归纳设置，这些实体已经发生在预训练阶段。数据集的详细构造可以在附录 A.1 中找到。如图 3 所示，蛋白质在 CCO 中平均有 2 个词条注释，在 MFO 中有 4 个词条注释，在 BPO 中有 3 个词条注释，这表明蛋白质功能预测可以被视为一个多标签问题。值得注意的是，我们注意到 leaf GO 术语往往比非 leaf GO 术语具有更具体的概念。同时，对于功能预测任务存在一个具有挑战性的长尾问题。

3.2 结果

带基准

基线 在 TAPE 中，我们与五个基线进行了比较，评估了我们的 OntoProtein。第一个是对输入氨基酸序列进行 LSTM 编码的模型，它提供了一个简单的基线。第二个是 TAPE Transformer，它提供了一个基本的 Transformer 基线。我们进一步从 He et al.(2016)中选择 ResNet 作为基线。第四种是 MSA Transformer (Rao et al. (2021a))。

[8] https://www.uniprot.org/

方法	SHS27k		SHS148k		字符串	
	BFS	DFS	BFS	DFS	BFS	DFS
DPPI	41.43	46.12	52.12	52.03	56.68	66.82
DNN-PPI	48.09	54.34	57.40	58.42	53.05	64.94
PIPR	44.48	57.80	61.83	63.98	55.65	67.45
GNN-PPI	63.81	74.72	71.37	82.67	78.37	91.07
GNN-PPI (ProtBert)	70.94	73.36	70.32	78.86	67.61	87.44
GNN-PPI (OntoProtein)__	**72.26**	**78.89**	**75.23**	77.52	76.71	**91.45**

表 2:蛋白质相互作用预测结果。呼吸优先搜索(BFS)和深度优先搜索(DFS)是分割训练和测试 PPI 数据集的策略。

方法	转换			归纳		
	业务流程外包	MFO	罗经航向	业务流程外包	MFO	罗经航向
ProtBert	0.58	0.13	8.47	0.64	0.33	9.27
OntoProtein	0.62	0.13	8.46	0.66	0.25	8.37

表 3:两个设置下三个子集的蛋白质功能预测结果。BPO 指生物过程，MFO 指分子功能，CCO 指细胞成分。

注意，MSA Transformer 利用了多序列比对(MSA)的优势，是目前最先进的方法。最后，我们使用具有 30 层 BERT 编码器的 ProtBert (Elnaggar et al.(2020))，这是基线中最大的预训练模型。

结果 我们在表 1 中详细描述了 TAPE 上的实验结果。具体来说，我们注意到 On- toProtein 在所有 token 水平测试中产生了更好的性能。对于第二个结构(SS-Q3 和 SS-Q8)和接触预测，OntoProtein 的表现优于 TAPE Transformer 和 ProtBert，表明它可以在预训练中受益于这些信息丰富的生物学知识图谱。此外，OntoProtein 可以实现与 MSA transformer 相当的性能。请注意，我们提出的 OntoProtein 没有利用来自 msa 的信息。然而，通过外部基因本体知识注入，OntoProtein 可以获得有希望的性能。在序列级任务中，On- toProtein 在荧光预测方面可以取得比 ProtBert 更好的性能。然而，我们观察到，OntoProtein 在蛋白质工程、同源性和稳定性预测方面表现不佳，这些都是回归任务。我们认为这是由于在我们的预训练对象中缺乏序列级目标，我们把这个留给未来的工作。

蛋白质相互作用

基线 我们选择了四种具有代表性的方法作为蛋白质-蛋白质相互作用的基线。PIPR (Chen et al.(2019))、DNN-PPI (Li et al.(2018))和 DPPI (Hashemifar et al.(2018))都是基于深度学习的方法。GNN-PPI (Lv et al.(2021))是一种基于图神经网络的方法，用于更好地预测新颖蛋白质之间的相互作用。为了评估我们的 OntoProtein，我们将 GNN-PPI 的初始蛋白质嵌入部分替换为 ProtBERT 和 OntoProtein 作为基线。

结果 从表 2 中，我们观察到 OntoProtein 的性能优于 PIPR，这表明外部结构知识可以有利于蛋白质-蛋白质相互作用预测。我们还注意到，我们的方法可以在较小的数据集 SHS2K 中实现有希望的改进，甚至优于 GNN-PPI 和 GNN-PPI (ProtBert)。在更大的数据集上，OntoProtein 仍然可以获得与 GNN-PPI 和 GNN-PPI (ProtBert)相当的性能。

蛋白质功能预测

基线 为简单起见，我们利用 Seq2Vec (Littmann et al.(2021))作为公平比较的骨干，并使用 ProtBert 和我们的 OntoProtein 初始化嵌入。请注意，我们的方法是模型无关的，其他骨干也可以被利用。

paperpaper.com

有道文档翻译
pdf.youdao.com

	6≤seq < 12			12≤seq < 24			24≤seq		
	p@l	p@l /2	p@l /5	p@l	p@l /2	p@l /5	p@l	p@l /2	p@l /5
带变压器	0.28	0.35	0.46	0.19	0.25	0.33	0.17	0.20	0.24
LSTM	0.26	0.36	0.49	0.20	0.26	0.34	0.20	0.23	0.27
ResNet	0.25	0.34	0.46	0.28	0.25	0.35	0.10	0.13	0.17
ProtBert	0.30	0.40	0.52	0.27	0.35	0.47	0.20	0.26	0.34
OntoProtein	**0.37**	**0.46**	**0.57**	**0.32**	**0.40**	**0.50**	**0.24**	**0.31**	**0.39**

表 4:接触预测的消融研究。Seq 是指氨基酸之间的序列长度。“P@K”是前 K 个接触点的精度，L 是蛋白质的长度。

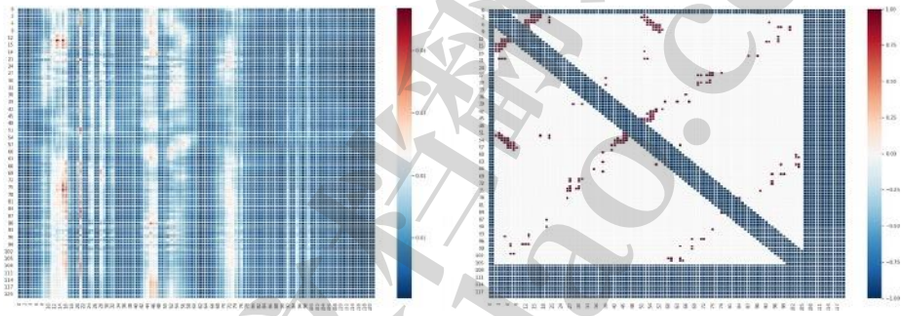


图 4:我们从接触测试数据集中随机选择一种蛋白质进行可视化分析。**左**:我们在 OntoProtein 中可视化了最后一个注意力层中的第 7 个头部。**右**:它是接触标签矩阵。

结果我们将测试集分为三个子集(BPO, MFO，和 CCO)，并分别评估模型的性能。从表 3 中，我们注意到我们的 OntoProtein 在转导设置下可以产生 4%的改进，在 BPO 中在诱导设置下可以产生 2%的改进，进一步证明了我们所提出方法的有效性。我们还观察到，OntoProtein 在其他子集中获得了类似的性能。请注意，数据集中存在严重的长尾问题，知识注入可能会影响头部的表示学习但削弱尾部表示，从而导致性能下降。我们把这个留给未来的工作。

3.3 分析

表 4 给出了详细的接触预测实验分析。为了进一步分析模型的性能，我们进行了实验来探究不同序列的性能。具体来说，从短程(6≤seq < 12)到长程(24≤seq)的蛋白质序列长度用三个指标(P@L, P@L/2, P@L/5)进行了测试。我们选择了 LSTM 和 TAPE transformer 等几种基本算法作为基线。为了公平起见，ProtBert 也被用于比较。可以看出，OntoProtein 在所有测试设置下的表现都超过了所有其他方法，这是合理的，因为从基因本体注入的知识是有益的。进一步，我们从测试数据集中随机采样了一个蛋白质实例，并分析了其 OntoProtein 的注意力权重。我们进行了如图 4 所示的可视化分析，以比较氨基酸之间的接触与接触标签矩阵。

3.4 讨论

将 NLP 的技术应用于蛋白质，打开了以自监督、数据驱动的方式从蛋白质中提取信息的新机会。在这里，我们首次表明，注入来自基因本体的外部知识可以帮助更好地学习蛋白质表示，从而促进下游蛋白质任务。然而，与之前使用大规模语料库的预训练模型相比，我们提出的 OntoProtein 的收益仍然相对较小。请注意，知识图谱 ProteinKG25 只能覆盖所有蛋白质的一个小子集，因此限制了进步。我们将继续通过添加来自基因本体的新事实来维护知识图谱。此外，之前的研究(Liu et al. (2020);Zhang et al. (2021a))表明并非所有的外部知识都是

有利于下游任务，有必要研究何时以及如何有效地将外部知识注入预训练模型。最后，我们提出的方法可以被视为联合预训练人类语言和蛋白质(生命的语言)。我们的动机是通过注入基因知识的蛋白质预训练来破解生命语言的密码。我们的工作只是朝着这个方向迈出的一小步。

4 相关工作

4.1 预训练语言模型

到目前为止，各种努力都致力于探索大规模的 ptm，要么是用于 NLP (Peters et al. (2018);Devlin et al.(2019))，或 CV (Tan & Bansal(2019))。微调大规模的 ptm，如 ELMo (Peters et al.(2018))、GPT3 (Brown et al.(2020))、BERT (Devlin et al.(2019))、XLNet (Yang et al. (2019)) UniLM (Dong et al.(2019))，以实现特定的 AI 任务，而不是从头学习模型，也已成为共识(Han et al.(2021))。除了用于自然语言处理的大规模语言模型之外，人们对开发类似的蛋白质模型也有相当大的兴趣(Xiao et al. (2021);Rives et al.(2021))。Rao et al. (2021a)首先研究了蛋白质 Transformer 语言模型，证明了残基-残基接触的信息可以通过蛋白质结构监督的线性投影从学习到的表示中恢复。Vig 等人(2021)对 Transformer 的注意力进行了广泛的分析，识别了与生物学相关特征的对应关系，还发现模型的不同层负责学习不同的特征。Elnaggar et al.(2020)提出了 ProtTrans，探索了在蛋白质以及蛋白质序列数据库上训练的放大语言模型的局限性，并比较了自回归和自编码预训练对后续监督训练成功的影响。人类策划的或特定领域的知识对下游任务至关重要，这被广泛研究，如 Himmelstein & Baranzini (2015)，Smaili 等人(2018)，Smaili 等人(2019)，Hao 等人(2020)，Ioannidis 等人(2020)。然而，这些预训练方法并没有明确考虑像我们提出的 OntoProtein 这样的外部知识。

4.2 知识增强的语言模型

背景知识一直被认为是语言理解不可或缺的一部分((Zhang et al.， 2021a;Deng 等人，2021;李等人，2021;张等，2019a;于等，2020;朱等人，2021 年;张等，2021b;陈等，2021;张等，2022b;Silvestri 等人，2021 年;张等人，2021c;姚等，2022;Zhang et al.， 2022a))，它启发了知识增强模型，包括 ERNIE (Tsinghua) (Zhang et al. (2019b))、ERNIE(百度)(Sun et al.(2019))、KnowBERT (Peters et al.(2019))、WKLM (Xiong et al.(2020))、LUKE (Yamada et al.(2020))、KEPLER (Wang et al. (2021b))、K-BERT (Liu et al.(2020))、K-Adaptor (Wang et al. (2021a))和 CoLAKE (Sun et al.(2020))。ERNIE (Zhang et al. (2019b))将关系知识注入到预训练模型 BERT 中，该模型将维基百科中的实体与 WikiData 中的事实对齐。KEPLER (Wang et al. (2021b))联合优化了知识嵌入和预训练语言表示(KEPLER)，不仅可以更好地将事实知识整合到 plm 中，还可以通过文本中的丰富信息有效地学习 KE。

在这些工作的启发下，我们提出了 OntoProtein，将外部知识图谱集成到蛋白质预训练中。据我们所知，我们是第一个将基因本体知识注入蛋白质语言模型的人。

5 结论和未来工作

本文迈出了将来自基因本体的外部事实知识整合到蛋白质语言模型的第一步。我们提出了基于基因本体嵌入(On- toProtein)的蛋白质预训练，这是第一个将外部知识图谱集成到蛋白质预训练中的通用框架。在广泛的蛋白质任务上的实验结果表明，高效的知识注入有助于理解和揭示生命的语法。此外，OntoProtein 与许多预训练的蛋白质语言模型的模型参数兼容，这意味着用户可以直接采用 OntoProtein 上可用的预训练参数，而无需修改 ar-

chitecture。这些积极的结果指向了未来的工作:(1)通过注入更多信息知识的基因本体选择来改进 OntoProtein;(2)将这种方法扩展到蛋白质设计的序列生成任务中。

致谢

我们想对匿名评论者的辛勤工作和友好评论表示感谢。基金资助:NSFCU19B2027/NSFC91846204，国家重点研发计划项目(基金资助号:sq2018yfc000004)，浙江省自然科学基金资助项目(基金资助号:2018yfc000004);LGG22F030011、宁波市自然科学基金(2021J190)、甬江人才引进计划(2021A-156-G)资助。

再现性声明

我们的代码和数据集都可以在 https://github.com/zjunlp/ OntoProtein for repeatability 中找到。超参数在附录 A.3 中提供。

参考文献

Antoine Bordes, Nicolas Usunier, Alberto Garc´ıa-Dur´an, Jason Weston 和 Oksana Yakhnenko。翻译嵌入以建模多关系数据。在 Christopher J. C. Burges、L´eon Bottou、Zoubin Ghahramani 和 Kilian Q. Weinberger(编辑)的《*神经信息处理系统进展 26:第 27 届神经信息处理系统年会 2013》中。2013 年 12 月 5-8 日举行的会议记录，美国内华达太浩湖*，2013 年第 2787-2795 页。URL https://proceedings.neurips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html。

Nadav Brandes、Dan Ofer、Yam Peleg、Nadav Rappoport 和 Michal Linial。Proteinbert:蛋白质序列和功能的通用深度学习模型。*bioRxiv*，2021 年。

Tom B. Brown、Benjamin Mann、Nick Ryder、Melanie Subbiah、Jared Kaplan、Prafulla Dhari- wal、Arvind Neelakantan、Pranav Shyam、Girish Sastry、Amanda Askell、Sandhini Agarwal、Ariel Herbert-Voss、Gretchen Krueger、Tom Henighan、Rewon Child、Aditya Ramesh、Daniel M. Ziegler、Jeffrey Wu、Clemens Winter、Christopher Hesse、Mark Chen、Eric Sigler、Mateusz Litwin、Scott Gray、Benjamin Chess、Jack Clark、Christopher Berner、Sam McCan- dlish、Alec Radford、Ilya Sutskever 和 Dario Amodei。语言模型是少样本的学习者。在 Hugo Larochelle、Marc 'Aurelio Ranzato、Raia Hadsell、Maria-Florina Balcan 和 Hsuan-Tien Lin(编)的《神经信息处理系统*进展 33:2020 年神经信息处理系统年会》中，NeurIPS 2020, 2020 年 12 月 6 日-12 日，virtual*, 2020 年。URL https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfcb4967418bfb8ac142f64a-Abstract.html。

陈慕豪、切尔西 J.-T.;琚、周光宇、陈学禄、张天然、常开伟、扎尼奥洛、王伟。基于孪生残差 RCNN 的多层面蛋白质相互作用预测。*Bioinform*。，35(14): i305-i314, 2019。doi: 10.1093 /生物信息学/btz328。URL https://doi.org/10.1093/bioinformatics/btz328。

陈翔、张宁宇、谢欣、邓淑敏、姚云志、谭传奇、黄飞、司罗、陈华军。Knowprompt:基于协同优化的知识感知提示调优关系抽取。*CoRR*, abs/2104.07650, 2021。URL https://arxiv.org/abs/ 2104.07650。

邓淑敏、张宁玉、李罗秋、陈慧、头怀晓、陈磨沙、黄飞、陈华军。ontoe:基于本体嵌入的低资源事件检测。在宗承庆、夏飞、李文杰和 Roberto Navigli(编著)的《*计算语言学协会第 59 届年会暨第 11 届自然语言处理国际联席会议论文集》中，ACL/IJCNLP 2021，(第一卷:长论文)，Virtual Event, 2021 年 8 月 1-6* 日，第 2828-2839 页。计算语言学协会(Association for Computational Linguistics)，2021。Doi: 10.18653/ v1/2021.acl-long.220。URL https://doi.org/10.18653/v1/2021.acl-long.220。

Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。BERT:用于语言理解的深度双向 transformer 预训练。在 Jill Burstein、Christy Doran 和 Thamar Solorio(编著)的*《计算语言学协会北美分会 2019 年会议论文集:人类语言技术》中，NAACL-HLT 2019，明尼阿波利斯，MN，美国，2019 年 6 月 2 日-7 日，第 1 卷(长和短论文)*，第 4171 - 4186 页。《计算语言学协会》，2019 年。doi: 10.18653 / v1 / n19 - 1423。URL https://doi.org/10.18653/v1/n19 - 1423。

董力、杨楠、王文辉、魏福如、刘晓东、王宇、高剑峰、周明、洪小武。面向自然语言理解和生成的统一语言模型预训练。在 Hanna M. Wallach、Hugo Larochelle、Alina Beygelz- imer、Florence d’ alch´e-Buc、Emily B. Fox 和 Roman Garnett(编)的*《神经信息处理系统进展 32:2019 年神经信息处理系统年会》中，NeurIPS 2019，2019 年 12 月 8 日-14 日，加拿大 BC 州温哥华*，2019 年第 13042-13054 页。URL https://proceedings.neurips.cc/paper/2019/ hash/c20bb2d9a50d5ac1f713f8b34d9aac5a - Abstract.html。

Ahmed Elnaggar、Michael Heinzinger、Christian Dallago、Ghalia Rihawi、Yu Wang、Llion Jones、Tom Gibbs、Tamas Feher、Christoph Angerer、Martin Steinegger、Debsindhu Bhowmik 和 Burkhard Rost。Prottrans:通过自监督深度学习和高性能计算，迈向破解生命代码的语言。*CoRR*, abs/2007.06225, 2020。URL https://arxiv.org/abs/2007.06225。

顾宇、罗伯特·丁恩、程浩、迈克尔·卢卡斯、臼山直人、刘晓东、特里斯坦·诺曼、高剑峰、潘海峰。面向生物医学自然语言处理的领域特定语言模型预训练，2020。

韩旭、张正艳、丁宁、顾玉贤、刘晓、霍雨绮、邱杰忠、张亮、韩文涛、黄敏烈、金琴、兰燕燕、刘洋、刘志远、卢志武、邱西鹏、宋瑞华、唐洁、温吉荣、袁金辉、赵薇歆、朱军。预训练模型:过去、现在和未来。*CoRR*, abs/2106.07139, 2021。URL https://arxiv.org/abs/2106.07139。

郝俊恒、切尔西 J-T Ju、陈慕豪、孙逸洲、卡洛·扎尼奥洛、王伟。Bio-joie:生物知识库的联合表示学习。*发表在第 11 届 ACM 生物信息学国际会议论文集《计算生物学与健康信息学》*2020 年第 1-10 页。

Somaye Hashemifar, Behnam Neyshabur, Aly A. Khan, Jinbo Xu。通过基于序列的深度学习预测蛋白质-蛋白质相互作用。*Bioinform*。，34(17): i802-i810, 2018。doi: 10.1093 / 生物信息学/ bty573。URL https://doi.org/10.1093/bioinformatics/ bty573。

何凯明、张翔宇、任少卿、孙坚。深度残差学习用于图像识别。*2016 年 IEEE 计算机视觉与模式识别会议，CVPR 2016，拉斯维加斯，NV，美国，2016 年 6 月 27-30* 日，770-778 页。IEEE 计算机学会，2016。doi: 10.1109 / CVPR.2016.90。URL https://doi.org/10.1109/CVPR.2016.90。

Daniel S Himmelstein 和 Sergio E Baranzini。异质网络边缘预测:一种优先考虑疾病相关基因的数据集成方法。*PLoS 计算生物学*，11(7):e1004259, 2015。

Vassilis N Ioannidis, Song Xiang, Saurav Manchanda, Mufei Li, Xiaoqin Pan, Da Zheng, Xia Ning, Xiangxiang, George Karypis。Drkg-drug repurpose knowledge graph for covid-19, 2020。

李成曦、高飞宇、卜家军、徐路、陈翔、谷宇、邵子瑞、郑琦、张宁宇、王永攀、于志。Sentiprompt:情感知识增强的方面级情感分析提示调优。*CoRR*, abs/2109.08306, 2021。URL https://arxiv。org/abs/2109.08306。

李航、龚秀君、余华、周畅。基于深度神经网络的基于初级序列的蛋白质相互作用预测。*分子*，23(8):1923,2018。

Maria Littmann、Michael Heinzinger、Christian Dallago、Tobias Olenyi 和 Burkhard Rost。embedding - beddings from deep learning transfer go annotation beyond homology。*科学报告*，11(1):1 - 14,2021。

刘伟杰，周鹏，赵哲，王志若，鞠琦，邓昊棠，王平。K-BERT:用知识图谱实现语言表示。在*第 34 届 AAAI 人工智能大会 AAAI 2020、第 32 届人工智能创新应用大会 IAAI 2020、第十届 AAAI 人工智能教育进展研讨会 EAAI 2020 上，美国纽约州纽约，2020 年 2 月 7-12 日*，第 2901-2908 页。AAAI 出版社，2020 年。URL https://aaai.org/ojs/index.php/AAAI/article/view/5681。

吕国峰、胡志强、毕彦光、张少婷。从相关性中学习未知:基于图神经网络的新颖蛋白质间相互作用预测。载周志华主编，*第三十届人工智能国际联合会议论文集，IJCAI 2021, Virtual Event /加拿大蒙特利尔，2021 年 8 月 19-27 日*，第 3677-3683 页。ijcai.org, 2021。doi: 10.24963 / ijcai.2021/506。URL https://doi.org/10.24963/ijcai.2021/506。

Adam Paszke、Sam Gross、Francisco Massa、Adam Lerer、James Bradbury、Gregory Chanan、Trevor Killeen、zeeming Lin、Natalia Gimelshein、Luca Antiga、Alban Desmaison、Andreas K ¨ opf、Edward Yang、Zachary DeVito、Martin Raison、Alykhan Tejani、Sasank Chilamkurthy、Benoit Steiner、Lu Fang、Junjie Bai、sousmith Chintala。Pytorch:一个命令式风格、高性能的深度学习库。在 Hanna M. Wallach、Hugo Larochelle、Alina Beygelzimer、Florence d'alch´- buc、Emily B. Fox 和 Roman Garnett(编)的*《神经信息处理系统进展 32:2019 年神经信息处理系统年会》中，NeurIPS 2019, 2019 年 12 月 8 日-14 日，加拿大 BC 温哥华，2019* 年第 8024-8035 页。网址 https://proceedings.neurips.cc/paper/2019/hash/ bdbca288fe7f92f2bfa9f7012727740 - abstract.html。

Matthew E. Peters、Mark Neumann、Mohit Iyyer、Matt Gardner、Christopher Clark、Kenton Lee 和 Luke Zettlemoyer。深层语境化的单词表征。在 Marilyn A. Walker、Heng Ji 和 Amanda Stent(编著)的*《计算语言学协会北美分会 2018 年会议论文集:人类语言技术》中，NAACL-HLT 2018，美国路易斯安那州新奥尔良，2018 年 6 月 1-6 日，第 1 卷(长论文)*，2227-2237 页。计算语言学协会，2018 年。doi: 10.18653 / v1 / n18 - 1202。URL https: //doi.org/10.18653/v1/n18-1202。

Matthew E. Peters、Mark Neumann、Robert L. Logan IV、Roy Schwartz、Vidur Joshi、Sameer Singh、Noah A. Smith。知识增强的上下文单词表征。In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan(主编)，*《2019 年自然语言处理经验方法会议论文集》和第九届自然语言处理国际联席会议论文集，EMNLP-IJCNLP 2019，中国香港，2019 年 11 月 3 日-7* 日，第 43 - 54 页。计算语言学协会，2019 年。doi: 10.18653 / v1 / d19 - 1005。URL https: //doi.org/10.18653/v1/D19-1005。

用 TAPE 评估蛋白质迁移学习。在 Hanna M. Wallach、Hugo Larochelle、Alina Beygelzimer、Florence d'alch´e-Buc、Emily B. Fox 和 Roman Garnett(编)的*《神经信息处理系统进展32:2019 年神经信息处理系统年会》中，NeurIPS 2019, 2019 年 12 月 8 日-14 日，加拿大 BC 温哥华*，9686-9698 页，2019 年。URL https://proceedings.neurips.cc/paper/ 2019/hash/37f65c068b7723cd7809ee2d31d7861c - Abstract.html。

Roshan Rao, Jason Liu, Robert Verkuil, Joshua Meier, John F. Canny, Pieter Abbeel, Tom Sercu, Alexander Rives。MSA 变压器。在 Marina Meila 和 Tong Zhang(编)，*第 38 届国际机器学习会议论文集，ICML 2021, 2021 年 7 月 18-24 日，Virtual Event, Proceedings of Machine Learning Research* 第 139 卷，pp. 8844-8856。PMLR, 2021。URL http://proceedings.mlr.press/v139/rao21a.html。

Roshan Rao, Joshua Meier, Tom Sercu, Sergey Ovchinnikov, Alexander Rives。Transformer 蛋白质语言模型是无监督的结构学习器。*第 9 届学习表征国际会议，ICLR 2021, Virtual Event，奥地利，2021 年 5 月 3-7* 日。OpenReview.net, 2021 b。URL https://openreview.net/forum?id=fylclEqgvgd。

Alexander Rives、Joshua Meier、Tom Sercu、Siddharth Goyal、Zeming Lin、Jason Liu、Demi Guo、Myle Ott、C. Lawrence Zitnick、Jerry Ma、Rob Fergus。将无监督学习扩展到 2.5 亿个蛋白质序列，生物结构和功能应运而生。*Proc。国家的。学会科学。美国*，118(15):e2016239118,2021 。 doi: 10.1073 / pnas.2016239118 。 URL https://doi 。 org/10.1073/pnas.2016239118。

Mattia Silvestri, Michele Lombardi, Michela Milano。在神经网络中注入领域知识- works:对约束问题的控制实验。在 Peter J. Stuckey(编)，*《约束规划、人工智能和运筹学的集成——第 18 届国际会议》，2021 年 7 月 5-8 日，奥地利维也纳，2021 年 7 月 5-8 日，论文集，计算机科学讲义*第 12735 卷，第 266-282 页。施普林格,2021 年。Doi: 10.1007/978-3-030-78230-6\ 17。URL https://doi.org/10.1007/978 - 3 - 030 - 78230 - 6 _17。
-

Fatima Zohra Smaili, Xin Gao, Robert Hoehndorf。Onto2vec:生物实体的基于向量的联合表示及其基于本体的注释。*生物信息学*，34(13):i52-i60，2018。

Fatima Zohra Smaili, Xin Gao, Robert Hoehndorf。Opa2vec:结合生物医学本体的正式和非正式内容，提高基于相似性的预测。*生物信息学*，35(12):2133-2140,2019。

孙天祥，邵云帆，邱西鹏，郭启鹏，胡雅茹，黄宣景，张峥。Colake:语境化语言与知识嵌入。Donia Scott, N´uria Bel, and Chengqing Zong(编)，*第 28 届计算语言学国际会议论文集，COLING 2020，西班牙巴塞罗那(在线)，2020 年 12 月 8-13* 日，第 3660-3670 页。国际计算语言学委员会(International Committee on Computational Linguistics)，2020。doi: 10.18653 / v1/2020.coling-main。327.URL https://doi.org/10.18653/v1/2020.coling-main.327。

孙瑜、王朔环、李宇坤、冯世坤、陈绪义、张翰、田欣、朱丹翔、田浩、吴华。ERNIE:通过知识整合增强表征。*CoRR*, abs/1904.09223, 2019。URL http://arxiv.org/abs/1904.09223。

郝坦和莫希特·班萨尔。LXMERT:从 transformer 中学习跨模态编码器表示。In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan(编著)，*2019 年自然语言处理经验方法会议论文集和第九届自然语言处理国际联合会议论文集，EMNLP-IJCNLP 2019，中国香港，2019 年 11 月 3 日-7* 日，第 5099-5110 页。计算语言学协会，2019 年。doi: 10.18653 / v1 / d19 - 1514。URL https://doi.org/10.18653/v1/d19 - 1514。

Ashish Vaswani、Noam Shazeer、Niki Parmar、Jakob Uszkoreit、Llion Jones、Aidan N. Gomez、Lukasz Kaiser、Illia Polosukhin。注意力就是你所需的一切在 Isabelle Guyon、Ulrike von Luxburg、Samy Bengio、Hanna M. Wallach、Rob Fergus、S. V. N. Vishwanathan 和 Roman Garnett(编)的*《神经信息处理系统的进展 30:2017 年神经信息处理系统年度会议》中，2017 年 12 月 4 日至 9 日，美国加利福尼亚州长滩*，pp. 9998 - 6008, 2017 年 。网址 https://proceedings.neurips.cc/paper/2017/hash/ 3f5ee243547dee91fbd053c1c4a845aa-Abstract.html。

Jesse Vig, Ali Madani, Lav R. Varshney, Caiming Xiong, Richard Socher, Nazneen Fatema Rajani。Bertology meets biology:在蛋白质语言模型中解读注意力。*第 9 届国际学习表征会议，ICLR 2021, Virtual Event，奥地利，2021 年 5 月 3-7* 日。OpenReview.net, 2021。URL https://openreview.net/forum?id= YWtLZvLmud7。

王瑞泽、唐都裕、段楠、魏中宇、黄玄景、季建树、曹桂红、蒋大新、周明。K-adapter:用适配器将知识注入预训练模型。在 Chengqing Zong、Fei Xia、Wenjie Li 和 Roberto Navigli (eds.)的*《计算语言学协会的发现:ACL/IJCNLP 2021》，在线事件，2021 年 8 月 1-6* 日，卷 ACL/IJCNLP 2021 of *Findings of ACL*，第 1405-1418 页。《计算语言学协会》，2021a 。 doi: 10.18653 / v1/2021.findings-acl.121 。 URL https://doi.org/10 。 18653 / v1/2021.findings-acl.121。

王晓智、高天宇、朱兆成、张正彦、刘志远、李娟姿、唐健。KEPLER:知识嵌入和预训练语言表示的统一模型。*反式。Assoc。第一版。语言学*，9:176-194,2021b。URL https://transacl.org/ ojs/index.php/tacl/article/view/2447。

肖宜佳、邱杰忠、李子昂、谢长宇、唐洁。利用大规模预训练语言模型对蛋白质进行建模。*CoRR*, abs/2108.07435, 2021。URL https://arxiv.org/ abs/2108.07435。

熊文涵、杜景飞、王威廉杨、Veselin Stoyanov。预训练百科全书:弱监督知识-预训练语言模型。*第 8 届学习表征国际会议，ICLR 2020，埃塞俄比亚亚的斯亚贝巴，2020 年 4 月 26-30* 日。OpenRe- view.net, 2020。URL https://openreview.net/forum?id=BJlzm64tDH。

山田郁也、浅井赤里、新藤博行、武田秀明、松本裕二。LUKE:具有实体感知自注意力的深度语境化实体表征。在 Bonnie Webber、Trevor Cohn、Yulan He 和 Yang Liu(编)的《*2020 年自然语言处理经验方法会议论文集》(Proceedings on Empirical Methods In Natural Language Processing)上，EMNLP 2020，在线，2020 年 11 月 16 日-20* 日，第 6442-6454 页。计算语言学协会，2020 年。doi: 10.18653 / v1/2020.emnlp-main.523 。URL https://doi.org/10.18653/v1/2020.emnlp-main.523。

杨智霖、戴子航、杨一鸣、Jaime G. Carbonell、Ruslan Salakhutdinov、Quoc V. Le。Xlnet:用于语言理解的广义自回归预训练。在 Hanna M. Wallach、Hugo Larochelle、Alina Beygelzimer、Florence d'alch´- buc、Emily B. Fox 和 Roman Garnett(编)的《*神经信息处理系统进展 32:2019 年神经信息处理系统年度会议》上，NeurIPS 2019, 2019 年 12 月 8 日 -14 日，加拿大 BC 州温哥华*，5754-5764 页，2019 年。URL https://proceedings.neurips.cc/paper/ 2019/hash/dc6a7e655d7e5840e66733e9ee67cc69-Abstract.html。

姚云志、黄韶涵、张宁宇、董力、魏福如、陈华军。Kformer: transformer 前馈层中的知识注入。*CoRR*, abs/2201.05742, 2022。URL https://arxiv.org/abs/2201.05742。

于海洋、张宁宇、邓淑敏、叶宏斌、张伟、陈华军。基于多原型嵌入的文本与知识桥接小样本关系三元组抽取。Donia Scott、N´uria Bel 和 Chengqing Zong(编)，*第28 届计算语言学国际会议论文集，COLING 2020，西班牙巴塞罗那(在线)，2020 年 12 月 8-13* 日，第 6399-6410 页。国际计算语言学委员会(International Committee on Computational Linguistics)，2020。doi: 10.18653 / v1/2020.coling-main.563 。URL https://doi.org/10.18653/v1/2020。coling-main.563。

张宁宇，邓淑敏，孙占林，王冠英，陈曦，张伟，陈华军。基于知识图谱嵌入和图卷积网络的长尾关系抽取。在 Jill Burstein、Christy Doran 和 Thamar Solorio(编著)的《*计算语言学协会北美分会 2019 年会议论文集:人类语言技术》中，NAACL-HLT 2019，明尼阿波利斯，MN，美国，2019 年 6 月 2 日-7 日，第 1 卷(长和短论文)*，第 3016-3025 页。计算语言学协会，2019a。doi: 10.18653 /v1 /n19 - 1306。URL https://doi.org/10.18653/v1/n19 - 1306。

张宁宇、邓淑敏、程旭、陈曦、张益驰、张伟、陈华军。去掉冗余，缩小无关:选择性知识注入用于语言预训练。摘自周志华主编，*第三十届人工智能国际联合会议论文集，IJCAI 2021, Virtual Event /加拿大蒙特利尔，2021 年 8 月 19-27 日*，第 4007 - 4014 页。ijcai.org，2021。doi: 10.24963 / ijcai.2021/552。URL https://doi.org/10.24963/ ijcai.2021/552。

张宁宇、贾强怀、邓淑敏、陈翔、叶宏斌、陈慧、头怀孝、黄刚、王钊、华能伟、陈华军。Alicg:阿里巴巴语义搜索的细粒度、可演化的概念图构建。在朱飞达、黄本金、苗春燕(编)的《*KDD' 21:The 27 届 ACM SIGKDD Conference on Knowledge Discovery and Data Mining》中，Virtual Event，新加坡，2021 年 8 月 14-18* 日，第 3895-3905 页。ACM，

2021 b。doi: 10.1145/3447548.3467057。URL https://doi.org/10.1145/3447548。3467057.

张宁宇、叶宏斌、杨嘉成、邓淑敏、谭传奇、陈磨沙、黄松芳、黄飞、陈华军。罗根:带自我训练的少样本逻辑知识条件文本生成。*CoRR*, abs/2112.01404, 2021c。URL https://arxiv.org/ abs/2112.01404。

张宁宇、谢欣、陈翔、邓淑敏、谭传奇、黄飞、程旭、陈华军。通过记忆进行推理:最近邻知识图谱嵌入。*CoRR*,abs/2201.05575, 2022a。URL https://arxiv.org/abs/2201.05575。

张宁宇、徐昕、陶连宽、于海洋、叶宏斌、谢欣、陈翔、李周波、李磊、梁小庄、姚云志、邓淑敏、张真如、谭传琦、黄飞、郑国洲、陈华军。Deepke:面向知识库人群的基于深度学习的知识抽取工具包。*CoRR*, abs/2201.03335, 2022b。URL https://arxiv.org/ abs/2201.03335。

张正艳、韩旭、刘志远、蒋欣、孙茂松、刘群。ERNIE:信息实体增强语言表征。在 Anna Korhonen、David R. Traum 和 Llu'ı s M'arquez(编著)的《*第 57 届计算语言学协会会议论文集》(Proceedings of the Association for Computational Linguistics, ACL 2019，意大利佛罗伦萨，2019 年 7 月 28 日- 8 月 2 日)，第 1 卷:长论文*，页 1441-1451。计算语言学协会，2019b.;doi: 10.18653 / v1 / p19 - 1139。URL https://doi.org/10.18653/v1/p19 - 1139。

郑恒一、温睿、陈曦、杨一凡、张云燕、张子恒、张宁宇、秦斌、徐明、郑叶峰。PRGC:基于潜在关系和全局对应的联合关系三元组抽取。在宗承庆、夏飞、李文杰和 Roberto Navigli(编)的《*计算语言学协会第 59 届年会暨第 11 届自然语言处理国际联合会议论文集》中，ACL/IJCNLP 2021，(第一卷:长论文)，Virtual Event, 2021 年 8 月 1-6* 日，第 6225-6235 页。计算语言学协会(Association for Computational Linguistics)， 2021。doi: 10.18653 / v1/2021.acl-long.486。URL https://doi.org/10.18653/v1/2021.acl-long.486。

周乃辉、江玉相、Timothy R Bergquist、Alexandra J Lee、Balint Z Kacsoh、Alex W Crocker、Kimberley A Lewis、George Georghiou、Huy N Nguyen、Md Nafiz Hamid 等。cafa 挑战赛报告了通过实验筛选改进的蛋白质功能预测和对数百个基因的新功能注释。*基因组生物学*，20(1):1 - 23,2019。

朱玉山，头怀晓，张文，叶干强，陈慧，张宁宇，陈华军。电商中的知识感知多模态预训练。*CoRR*, abs/2109.00895, 2021。URL https://arxiv.org/abs/2109.00895。

一个附录

A.1 蛋白 g25 的构建

为了将基因本体知识纳入语言模型并训练 OntoProtein，我们构建了 ProteinKG25，一个大规模的 KG 数据集，分别具有对齐的描述和蛋白质序列，用于 GO 术语和蛋白质实体。设计了两种评估方案，转导设置和归纳设置，模拟了现实中基因注释的两种场景。

我们使用 2020 年 4 月发布的最新基因本体和基因注释。基因本体使用 GO-GO 三元组描述 GO 术语之间的关系，基因注释使用蛋白质-GO 三元组描述蛋白质和 GO 术语之间的关系。由于这种连通性，我们将这两种结构结合成一个统一的知识图谱。对于基因本体中的每个 GO 术语，我们将其与相应的名称和描述对齐，并用冒号将它们连接起来作为一个完整的描述。对于基因注释中的每个蛋白质，我们将其与 Swiss-Prot 对齐，并提取其对应的序列作为其描述。最终的 KG 包含 4990,097 个三元组(4,879,951 个 Protein-GO 三元组和 110,146 个 GO-GO 三元组)，612,483 个实体(565,254 个蛋白质和 47229 个 GO 术语)和 31 个关系。

由于基因本体的树形层次结构，我们使用从当前 GO 术语到 GO 术语根节点的最短路径来定义 GO 术语的深度。蛋白质- GO 三元组相对于 GO 术语深度的分布如图 3 底部所示。通常，a GO 项的位置越深，GO 项的定义就越具体，例如小分子生物合成过程是生物合成过程的子节点。我们注意到，在所有三种类型的本体中，与 leaf GO 术语相关的基因注释数量所占比例相对较小。我们认为存在两种可能性:(1)某些具体 GO 术语注释的复杂性，例如，蛋白质是否参与己糖生物合成过程的识别。(2)自然界中涉及某些特定 GO 术语的蛋白质数量相对较少，这是这些 GO 术语所固有的。

我们进一步对 ProteinKG25 数据集进行了如下预处理。我们观察到 Protein- Go 的关系具有长尾分布，且主要集中*在参与*、*部分*和*使能*。这样的数据分布会严重影响预训练期间的蛋白质特征嵌入，因此我们对我们的数据集进行预处理，以添加更精确和细粒度的关系。图 5 展示了原始模型的关系分布和经过预处理后的分布。我们搜索在 ProteinKG25 中出现频率在 MF 和 CC 中为 top 10，在 BP 中为 top 20 的 GO 术语，然后通过它们的对应关系如*细胞质的部分*形成一种新型的 Protein2GO 关系。

- -

A.2 下游任务定义

我们列出了自然语言处理中下游任务及其对应或类似任务的详细定义。

- **二级结构预测**是一个 token 级别的任务，类似于 NER(名称实体识别)。每个 token(氨基酸)x 被 $_i$ 映射到一个标签 $y_i \in$ {Helix, Strand, Other}。
- **接触预测**是一个标记级别的匹配任务。每个 token(氨基酸)对 x_i , x_j of 序列(蛋白质)x 被映射到一个标签 $y_{ij} \in \{0,1\}$。
- **远程同源检测**是一个序列级别的分类任务。每个输入序列(蛋白质)x 被映射到一个标签 $y \in \{1, \cdots, 1195\}$，表示不同可能的蛋白质折叠。
- **荧光景观预测**和**稳定性景观预测**是回归任务，其中每个序列(蛋白质)x 被映射到标签 $y \in R$。
- **蛋白质蛋白质界面**是一个序列级匹配任务。每个序列(蛋白质)对 x_{i} ,$_{j}$ x 映射到一个标签 $y_{ij} \in \{0,1\}$。
- **蛋白质功能预测**是一个序列级分类任务或知识图谱补全任务，用于预测蛋白质与基因本体的链接。

A.3 实验设置

本节详细介绍了每个数据集的训练过程和超参数。我们利用 Pytorch (Paszke et al.(2019))使用 Nvidia V100 gpu 进行实验。在 OntoProtein 的预训练中，类似于 Elnaggar 等人(2020)，我们在 BERT 模型上使用相同的训练协议，如优化器、学习率调度。在方程 1 中，我们将 γ 设置为 12.0，负采样数量设置为 128。

A.4 ontoprotein 的数据流

我们使用 batch (protein-seq, protein-go, go-go)来联合训练模型，如图 7 所示。

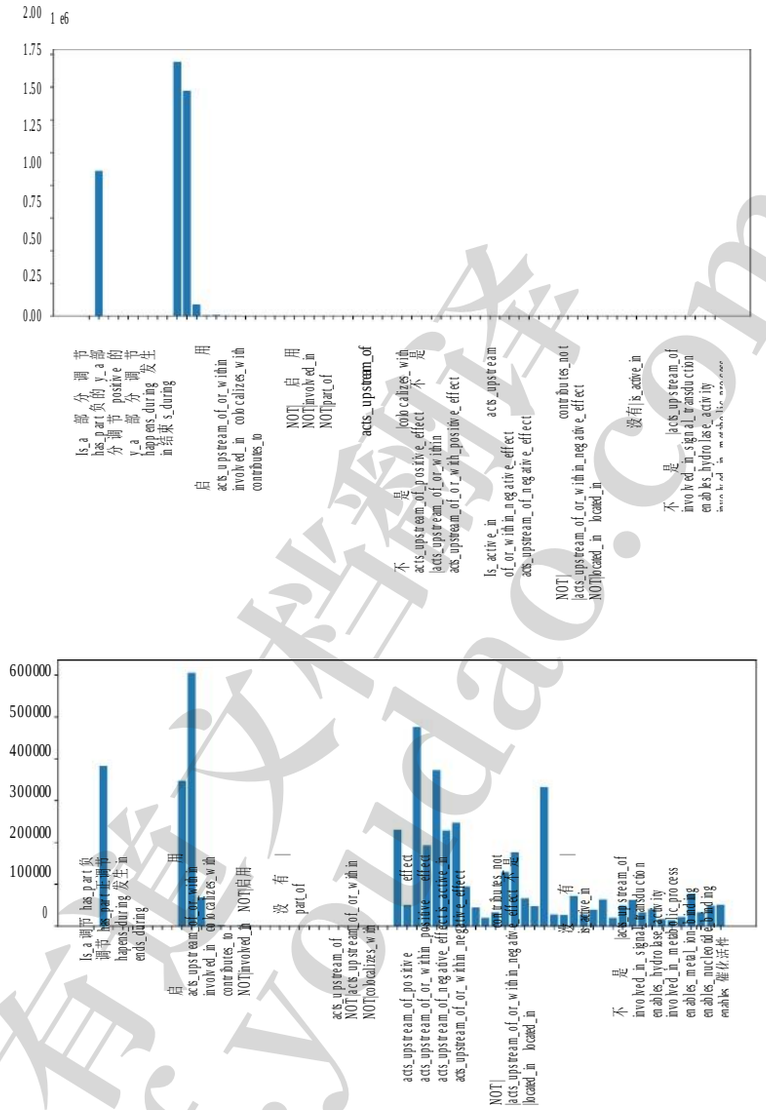


图 5:**上图**:初始关系分布。**下**:预处理后的关系分布。

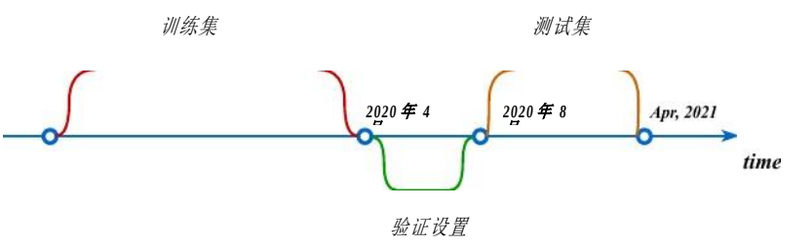


图 6:三个基因注释数据集的时间轴。为了生成蛋白质功能预测的预训练集和评估集，我们选择了三个不同时期的基因注释数据集。

有道文档翻译 pdf.youdao.com

有道文档翻译
pdf.youdao.com

实体类型	关系类型
分子功能	使能，有助于
蜂窝组件	位于的，部分的，活跃的，同处的
	在上游或内部活动，
	参与，在…的上游活动，
生物过程	起到积极作用的上游，
	扮演负面影响的上游，
	作用于或处于积极作用的上游，
	在负面影响的上游或在负面影响的范围内

表 5:GO 术语的实体类别和这些实体类别的具体关系类型。

任务	时代	批量大小	热身比	学习速率	冷冻伯特	优化器
ss3	5	32	0.08	3e-5	假	AdamW
ss8	5	32	0.08	3e-5	假	AdamW
稳定	5	32	0.08	3e-5	假	AdamW
荧光:	25	64	0.0	3e-5	真正的	AdamW
远程同源性	10	64	0.08	3e-5	假	AdamW
联系	10	8	0.08	3e-5	假	AdamW

表 6:下游任务的超参数。

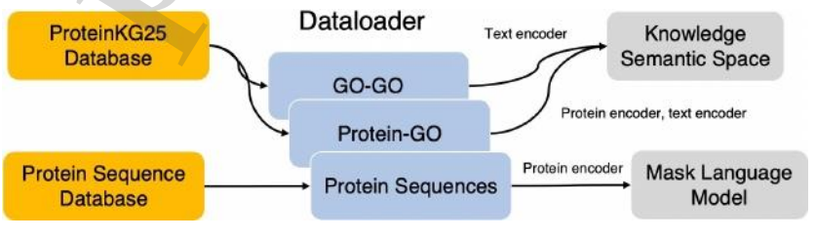


图 7:OntoProtein 的数据流。

术语	描述

有道文档翻译 pdf.youdao.com

表 7:基因本体论中的术语描述。GO 注释是通过将基因或基因产品与 GO 术语相关联而创建的。四种信息可以唯一确定一个 GO 注释:基因产物、GO 术语、参考文献、证据。而每一个 Go 术语都包含一个描述文本，这就是 Go 语句。

有道文档翻译
pdf.youdao.com