探索生物信息学神秘岛-02

我们继续探索生物信息学神秘岛。上一次讲到了孟德尔和莫尔斯。在孟德尔之后，生物学的发展突飞猛进。从瑞士人米歇尔分离出核酸，到丹麦的约翰森首次提出基因一词，再到美国的摩尔根在果蝇中发现染色体，只经历的短短的半个世纪。摩尔根因创立了染色体遗传理论而获得了 1933 年的诺贝尔奖，是现代实验生物学的奠基人！到 20 世纪中，生物学和计算机科学又同时放光。

生物学这边，在基因，染色体这些新词汇面世之后不久，美国的三位科学家通过实验证明基因和染色体是由 DNA 构成的，DNA 是生物的遗传物质。同一时期，计算机科学出现了一位天才，图灵。他是英国著名的数学家和逻辑学家，被称为计算机科学之父、人工智能之父，是计算机逻辑的奠基者。在图灵之前没有任何人清楚地说明过莱布尼兹所说的“计算机”到底是怎么一回事。直到 1936 年，图灵向伦敦权威的数学杂志投了一篇题为“论数字计算在决断难题中的应用”的论文，提出著名的“图灵机”的设想。图灵机被公认为现代计算机的原型。图灵后半生遭受迫害，不堪其辱，咬了一口被氰化物浸泡过的苹果，自杀身亡。许多年后，有一位图灵的粉丝，捡起了那个被图灵咬了一口的苹果，创建了著名的苹果公司。

之后 1944 年，美国人 Chargaff 提出了 A=T，G=C 的 Chargaff 规则。同一时期，世界上第一台现代电子计算机“埃尼阿克”，诞生于美国宾夕法尼亚大学。埃尼阿克占地面积 170 平方米、重达 30 吨。他的“绝招”是在 1 秒钟内进行 5000 次加法运算。

1951 年英国生物化学家桑格将胰岛素的氨基酸序列完整地定序出来，同时证明蛋白质具有明确构造，即，氨基酸像一条链一样排列，同一种蛋白质总是具有特定的氨基酸排列顺序。这项研究使他单独获得了 1958 年的诺贝尔化学奖。

到了 1953 年不得不提的是沃森，DNA 之父。他和克里克于 1953 年在《自然》上发表了 DNA 双螺旋结构模型。而这个模型是根据弗兰克林和弗兰克林的助手威尔金斯，于 1952 年用 X 射线衍射法获得的一张晶体照片构建的。因此 DNA 双螺旋结构的发现这四个人都功不可没。然而 1962 年的诺贝尔奖只授予了三位男士。弗兰克林并未获得诺贝尔奖，因为她在获奖前因癌症去世，而诺贝尔奖只能颁发给活着的人。尽管如此，我们还是应该记住这位伟大的女性。

在 DNA 的结构破解不久，第一个蛋白质的晶体结构也与世人见面。桑格告诉我们氨基酸是按照一定顺序排列的，而这个晶体结构告诉我们，他们们并不是一条线，而是折叠成一个具有特定形状的空间结构。这个晶体结构同样是通过 X 射线衍射法获得的。这门技术的应用，使得研究大分子的结构成为可能。

与沃森一起破解 DNA 双螺旋结构的克里克在 1958 年就提出了中心法则，并于 1970 年在《自然》上的一篇文章中重申。克里克提出的中心法则主要是说 DNA 复制形成 DNA，DNA 转录形成 RNA，RNA 再翻译形成蛋白质。今天我们知道，除了这些，病毒中的 RNA 也可以自我复制，RNA 还能逆转录成为 DNA，甚至理论上可实现遗传物质从 DNA 到蛋白质的直接转移。在中心法则提出不久，两位美国科学家破译了全部遗传密码字典的 64 个密码子并解释了密码子如何操控蛋白质合成。他们二人和提出 tRNA 三叶草结构模型的美国化学家霍利分享了 1968 年的诺贝尔奖 。

到了 20 世纪 70 年代，桑格再次登场，研究出一种称为链终止法的技术来测定 DNA 序列，又叫做双去氧终止法或桑格法。这项研究成果后来成为人类基因组计划得以展开的关键技术之一，并使桑格于 1980 年与合作者吉尔伯特获得诺贝尔化学奖。这是桑格第二次获得诺贝尔奖。1975 年真的是不同凡响的一年，这一年桑格发明了桑格测序法，而比尔盖茨于这一年成立了微软公司，更巧的是，乔布斯也于这一年成立了苹果公司。

随着测序技术的出现以及计算机科学的快速发展，1979 年美国洛斯阿拉莫斯实验室建立了 GenBank 数据库，以储存测序产生的数据。三年后，欧洲分子生物学实验室 EMBL 也建立了核酸序列数据库，之后亚洲也有了自己的核酸序列数据库 DDBJ。三大核酸序列数据库于 90 年代初实现资源共享，联合成立国际核苷酸序列数据库。随着三大核酸数据库中数据的迅猛增长，生物信息学日渐成熟，并展露出不可或缺的重要地位。1987 年美籍华人林华安博士首创了 bioinformatics 一词，並发起首届国际生物信息学系列会议，使得生物信息学一词在世界各地广为沿用。非常有趣的是，bioinformatics 这个词也有着自己的进化史，这个词最早以 compbio 出现，是 compute 和 biology 的缩写，后来发展成 bioinformatique，informatique 这个词源于法语，英语化后变成了 bio 连线 informatics。这个词用了一段时间，直到电子邮件的出现。早期的电子邮件，标题不支持连线，于是去掉连线，有了今天的 bioinformatics。