贝叶斯公式的应用

贝叶斯方法在蛋白质耐热性分类中的研究

丁彦蕊[1,2*]，蔡宇杰[2,3]，孙俊[1]，须文波[1]

（1. 江南大学 信息工程学院；江苏 无锡 214122；2. 江南大学 工业生物技术教育部重点实验室，江苏 无锡 214036；3. 江南大学 生物工程学院，江苏 无锡 214036）

摘要：氨基酸含量是影响蛋白质耐热性的主要因素。本文以氨基酸含量为特征向量，研究了贝叶斯方法预测蛋白质耐热性的准确度。结果表明，基于贝叶斯方法的局部预测率和全局预测率分别为 73.1%和 76.1%。这不仅表明贝叶斯方法适合于蛋白质耐热性的分类，而且也证明了氨基酸含量的确对蛋白质耐热性有重要作用。

贝叶斯公式的应用

- 从COG数据库中筛选到101868个常温蛋白质，3974个高温蛋白质和15187个超高温蛋白质序列，作为标准数据集。
- 把每一个蛋白质模型化为一个向量x，x的每一个维对应着一种氨基酸的含量，20种氨基酸对应20个维度，即以一个20维的氨基酸含量特征向量x来表示一个蛋白质。
- 以基于贝叶斯公式的算法的机器学习方法对每个蛋白质进行耐热性分类。

对简单的两类模式，最终目的是要确定 x 是第 I 类(ω_1)还是属于第 II 类(ω_2)[11]。利用贝叶斯定理，后验概率 $P(\omega_i|x)$可以由类别 ω_i 的先验概率 $P(\omega_i)$和 x_i 的条件概率密度 $P(x|\omega_i)$来计算，即：

$$P(\omega_i \mid x) = \frac{P(x \mid \omega_i)P(\omega_i)}{P(x)} = \frac{P(x \mid \omega_i)P(\omega_i)}{\sum_{i=1}^{2} P(x \mid \omega_i)P(\omega_i)}$$

贝叶斯公式的应用

- 从COG数据库中筛选到101868个常温蛋白质，3974个高温蛋白质和15187个超高温蛋白质序列，作为标准数据集。
- 把每一个蛋白质模型化为一个向量x，x的每一个维对应着一种氨基酸的含量，20种氨基酸对应20个维度，即以一个20维的氨基酸含量特征向量x来表示一个蛋白质。
- 以基于贝叶斯公式的算法的机器学习方法对每个蛋白质进行耐热性分类。

引伸到多类情况，类别 ω_i 的判别函数可写成：

$d_i(x) = P(x \mid \omega_i)P(\omega_i)$ （i=1,2,…, ρ ）

若对于全部 $j \neq i$ 的值，当 $d_i(x) > d_j(x)$ ，则将该模式 x 指定为 ω_i 类，即 $x \in \omega_i$ 。