认识序列

这一章我们来看生物信息学分析的一个重要内容：序列比较。无论你是研究核酸的还是蛋白质的，无论你是搞测序的还是搞结构的，甚至是编程的，都逃不掉序列的比较。

那什么是序列呢？序列的英文名字是 sequence，这个单词一定要记住。那序列长什么样子呢？s 就是一条序列：s=abcdefghijklmnopqrstuvwxyz。看了这个例子，学计算机的同学可能要笑了：“这不就是个字符串吗？我们管这个叫 string”。没错，序列就是字符串，由字符穿成的串。通常用 s_i 代表序列 s 的第 i 个字符，比如 s_4 是 s 的第 4 个字符，也就是 d。当然你的字符串是从 0 位开始计数还是从 1 位开始，自己根据需要定！还有，习惯上用 s'代表 s 的子序列。这些都是大家上计算机课已经熟知的了。

我们这里研究的序列主要是指蛋白质序列和核酸序列。蛋白质序列是由 20 个不同的字母，也就是 20 种不同的氨基酸排列组合而成。核酸序列是由 4 种不同的字母，也就是 4 种不同的碱基排列组合而成。核酸序列又分为 DNA 序列和 RNA 序列。

生物序列有自己的书写格式，而且格式很多。不同的处理软件会用到不同的格式，但是最常用的，大多数软件都识别的格式是 FASTA 格式。这个格式在第二章已经介绍过了，这里再复习一下。FASTA 格式，第一行是一个大于号“>”开头，后面紧接注释信息，比如序列的名字，编号等。因为前面有大于号，序列分析软件会自动识别这是一条序列的开始，且这一行是注释而不是序列。从第二行开始就是纯序列部分，除了序列什么都不要写。最早定义 60 个字母一行，现在这个规定不重要了，经常见到的也有 80 个一行的，或者不分行，一行写下来的，根据实际需要自己决定！再次强调，一定要记住这个 FASTA 格式！后面的章节里会经常使用这个格式的序列。而且，记住是 FASTA，不是 PASTA。PASTA 是面条。

