蛋白质序列的替换记分矩阵（1）

蛋白质的替换记分矩阵要比核酸的复杂一些。

首先，蛋白质也有纯理论用的等价矩阵，相同得 1 分，不同得 0 分。

此外，蛋白质最常用的两种矩阵是 PAM 矩阵和 BLOSUM 矩阵。PAM 矩阵基于进化原理。如果两种氨基酸替换频繁，说明自然界容易接受这种替换，那么这一对氨基酸替换的得分就应该高。PAM 矩阵是目前蛋白质序列比较中最广泛使用的记分方法之一。基础的 PAM-1 矩阵反应的是进化产生的每一百个氨基酸平均发生一个突变的量值，由统计方法得到。PAM-1 自乘 n 次，可以得到 PAM-n ，表示发生了更多次突变。我们需要根据要比较的序列之间的亲缘关系远近，来选择适合的 PAM 矩阵。如果序列亲缘关系远，也就是说序列间会有很多突变，那就选 PAM 后面跟一个大数字的矩阵。如果亲缘关系近，也就是突变比较少，序列间大多数地方都是一样的，那就选 PAM 后面跟一个小数字的矩阵。

图 1 是 PAM250 矩阵。对角线上的数值为匹配氨基酸的得分。其他位置上≥0 的得分代表对应的一对氨基酸为相似氨基酸，<0 的是不相似的氨基酸。

	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W
C	12																			
S	0	2																		
T	-2	1	3																	
P	-3	1	0	6																
A	-2	1	1	1	2															
G	-3	1	0	-1	1	5														
N	-4	1	0	-1	0	0	2													
D	-5	0	0	-1	0	1	2	4												
E	-5	0	0	-1	0	0	1	3	4											
Q	-5	-1	-1	0	0	-1	1	2	2	4										
H	-3	-1	-1	0	-1	-2	2	1	1	3	6									
R	-4	0	-1	0	-2	-3	0	-1	-1	1	2	6								
K	-5	0	0	-1	-1	-2	1	0	0	1	0	3	5							
M	-5	-2	-1	-2	-1	-3	-2	-3	-2	-1	-2	0	0	6						
I	-2	-1	0	-2	-1	-3	-2	-2	-2	-2	-2	-2	-2	2	5					
L	-6	-3	-2	-3	-2	-4	-3	-4	-3	-2	-2	-3	-3	4	2	6				
V	-2	-1	0	-1	0	-1	-2	-2	-2	-2	-2	-2	-2	2	4	2	4			
F	-4	-3	-3	-5	-4	-5	-2	-6	-5	-5	-2	-4	-5	0	1	2	-1	9		
Y	0	-3	-3	-5	-3	-7	-2	-4	-4	-4	0	-4	-4	-2	-1	-1	-2	7	10	
W	-8	-2	-5	-6	-6	-7	-4	-7	-7	-5	-3	2	-3	-4	-5	-2	-6	0	0	17

图 1. PAM250 矩阵

BLOSUM 矩阵有和 PAM 矩阵相同的地方，也有不同的地方。相同的是，BLOSUM 矩阵后面也带有一个编号，有很多种 BLOSUM 矩阵。不同的是，BLOSUM 矩阵都是通过对大量符合特定要求的序列计算而来的。这点和 PAM 矩阵不同的。PAM-1 矩阵是基于相似度大于 85%的序列计算产生的，也就是通过关系较近的序列计算出来的。那些进化距离较远的矩阵，如 PAM-250，是通过 PAM-1 自乘得到的。也就是说，BLOSUM 矩阵的相似性是根据真实数据产生的，而 PAM 矩阵是通过矩阵自乘外推而来的。和 PAM 矩阵的另一个不同之处是 BLOSUM 矩阵的编号。这些编号，比如 BLOSUM80 中的 80，代表这个矩阵是由一致度≥80%的序列计算而来的。同理，BLOSUM62 是指这个矩阵是由一致度≥62%的序列计算而来的。因此，BLOSUM 后面跟一个小数字的矩阵适合用于比较相似度低的序列，也就是亲缘关系远的序列；而 BLOSUM 后面跟一个大数字的矩阵适合比较相似度高的序列，也就是亲缘关系近的序列。

图 2 是 BLOSUM 62 矩阵.样子和 PAM 矩阵差不多，但是里面的数值是不一样的。同样，≥0 的得分代表对应的一对氨基酸为相似氨基酸，<0 的是不相似的氨基酸。

	Ala	Arg	Asn	Asp	Cys	Gln	Glu	Gly	His	Ile	Leu	Lys	Met	Phe	Pro	Ser	Thr	Trp	Tyr	Val
Ala	4																			
Arg	-1	5																		
Asn	-2	0	6																	
Asp	-2	-2	1	6																
Cys	0	-3	-3	-3	9															
Gln	-1	1	0	0	-3	5														
Glu	-1	0	0	2	-4	2	5													
Gly	0	-2	0	-1	-3	-2	-2	6												
His	-2	0	1	-1	-3	0	0	-2	8											
Ile	-1	-3	-3	-3	-1	-3	-3	-4	-3	4										
Leu	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4									
Lys	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5								
Met	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5							
Phe	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6						
Pro	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7					
Ser	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4				
Thr	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5			
Trp	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11		
Tyr	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	
Val	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4

图 2. BLOSUM62 矩阵

现在我们总结一下到底是用 PAM 几，或者 BLOSUME 几。PAM1 对应的氨基酸差异是 1%，这是基础矩阵，由实际数据计算得出。而 PAM11 是由 PAM1 自乘 11 次得到的，他对应的氨基酸差异可不是 11%，而是大约在 10%左右（图 3）。同样，PAM80 对应的差异也不是 80%，而是在 50%左右。如果你要比对的序列亲缘关系远，比如氨基酸差异在 80%左右，

那就得选 PAM 自乘次数非常多的矩阵，适合的是 PAM246。但是现成的 PAM 矩阵也不是什么号的都有，只有几个关键号的。比如这个 PAM246 就没有，有的是 PAM250。再来看 BLOSUME。BLOSUME 后面的号和 PAM 刚好相反，因为它对应的是序列的相似度。差异在 80%左右意味着相似度在 20%左右，所以这个档次上的序列适合用的 BLOSUM 矩阵就是 BLOSUM20。概括的说，PAM 后面的数体现的是序列的差异度，但不直接等于差异度，只是成对应关系而已；BLOSUM 后面的数体现是的序列的相似度并且直接等于相似度。所以我们看到，随着差异度的增大，适用的 PAM 矩阵后面的编号是增大的，而 BLOSUM 矩阵后面的编号是减小的。

氨基酸差异%	PAM	BLOSUM
1	PAM-1	BLOSUM-99
10	PAM-11	BLOSUM-90
20	PAM-23	BLOSUM-80
30	PAM-38	BLOSUM-70
40	PAM-56	BLOSUM-60
50	PAM-80	BLOSUM-50
60	PAM-112	BLOSUM-40
70	PAM-159	BLOSUM-30
80	PAM-246	BLOSUM-20

图 3. 氨基酸差异与矩阵编号对照图

进一步总结一下（图 4），亲缘关系较近的序列之间的比较，用 PAM 数小的矩阵或 BLOSUM 数大的矩阵；而亲缘关系较远的序列之间的比较，用 PAM 数大的矩阵或 BLOSUM 数小的矩阵。

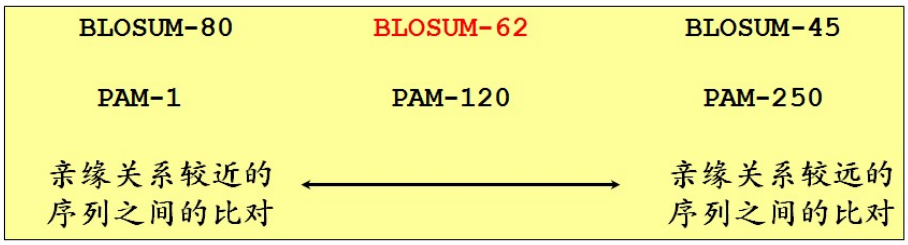


图 3. 序列亲缘关系远近与矩阵的选择

接下来，问题又来了，那到底是用 PAM 还是 BLOSUM 呢？对于关系较远的序列之间的比较，由于 PAM250 是通过矩阵自乘推算而来的，所以其准确度受到一定限制。相比之下

BLOSUM 矩阵更具优势。对于关系较近的序列之间的比较，用 PAM 或 BLOSUM 矩阵做出的比对结果，差别不大。如果关于要比较的序列你不知道亲缘关系远近，那么就闭着眼睛用 BLOSUM62 吧！至此，如果你记不住或者听不懂前面讲的种种，只记住 BLOSUM62 这个名字，也可以走遍天下全不怕！