多序列比对介绍：用途和算法

学习了双序列比对之后，我们来看多序列比对。多序列比对的定义很简单，两条以上的生物序列进行的全局比对就是多序列比对（图 1）。为了看清楚每一列的保守情况和理化性质，通常会给多序列比对根据不同的原则赋予丰富的色彩。

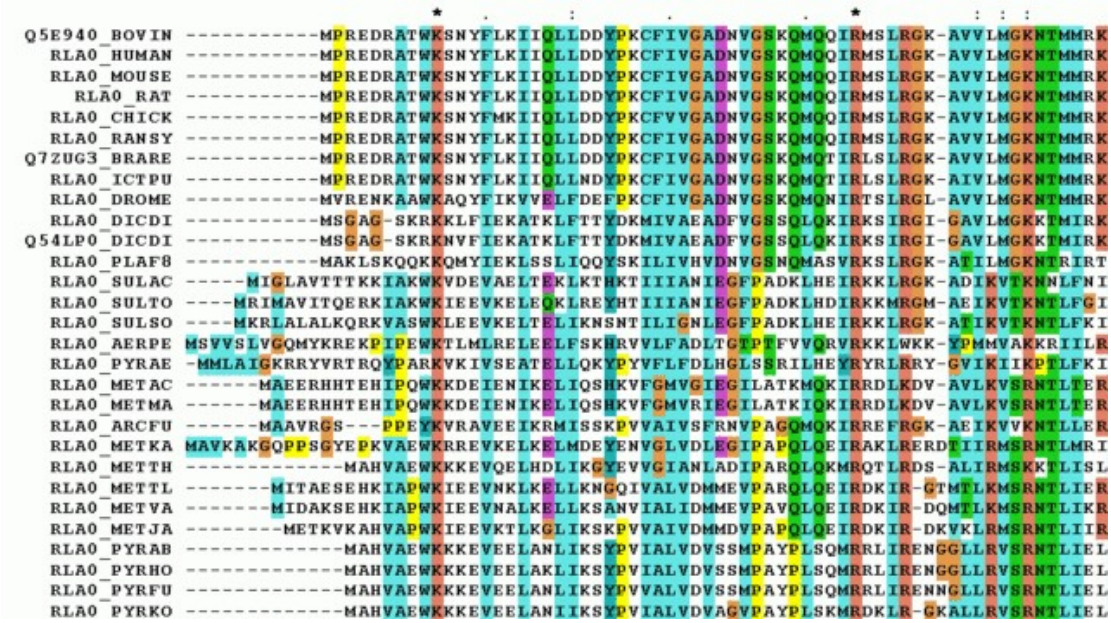


图 1. 多序列比对

在开始讲如何做多序列比对之前，我们需要先看看多序列比对的主要用途，也就是我们为什么要做多序列比对。1）我们可以通过多序列比对确定某一个未知序列是否属于某一个家族。2）可以用多序列比对构建系统发生树，查看物种间或者序列间的进化关系。事实上，做多序列比对是构建系统发生树的必要步骤之一。3）模式识别。一些特别保守的序列片段往往对应着重要的功能区。通过多序列比对，可以找到这些保守片段，并由此推测出潜在功能区。4）可以把已知的有特殊功能的序列片段通过多序列比对做出匹配模型。然后根据这个模型推测未知的序列片段是否也具有这个功能。除此之外，多序列比对在生物信息学分析的很多方面都有应用，比如用来预测蛋白质的二级结构和三级结构，预测 RNA 的二级结构等等。由此，我们可以看出，多序列比对的应用是非常广泛的。

接下来我们看一下多序列比对的算法。两条序列的比对需要构建一个二维表格，然后从右下角到左上角找出一条最优路线。如果是做 3 条序列的比对，应该做一个三维立方体，从 (0,0,0) 这个位置到 (n,n,n) 这个位置找到最优的贯穿路径。以此类推，如果是做 n 条序

列的比对，就要创建一个 n 维空间。这个 n 维空间实在是难以想象，但是有一点是明确的，就是到了 n 维我们已经没有办法再像二维那样精确的计算出比对结果了。由于计算量过于巨大，所以目前所有的多序列比对工具都是不完美的。它们都使用一种近似的算法。目的就是为了缩短计算时间，但也因此牺牲了一定的准确度。好在多序列比对并不像双序列比对对准确度要求极高。通常，我们是要从多序列比对中看到一个趋势，一个大体的位置，所以牺牲掉的这点儿准确度影响不大。我们这门课不讲具体的多序列比对算法，直接使用程序猿同志已经开发好的在线多序列比对工具。