寻找保守区域：序列标识图 WebLogo

如果用一句话来描述你究竟想从多序列比对中得到什么，答案是你想要找到序列中重要的位置。说得更专业一点，就是要找到保守区域。通过多序列比对下方的星星点点可以大致发现图 1 中两个红框中的区域比较吸引眼球，因为星星点点特别多！我们稍微回忆一下这些密码的含义：“*”代表这一列残基完全相同；“:”代表这一列残基或者相同或者相似；“.”代表这一列残基有相似的但也有不相似的；什么都没有代表这一列残基都不相似。所以我们寻找的就是星星点点特别多的区域。当然用眼睛来数星星不那么靠谱。我们仍然需要借助软件来更好的寻来保守区域。

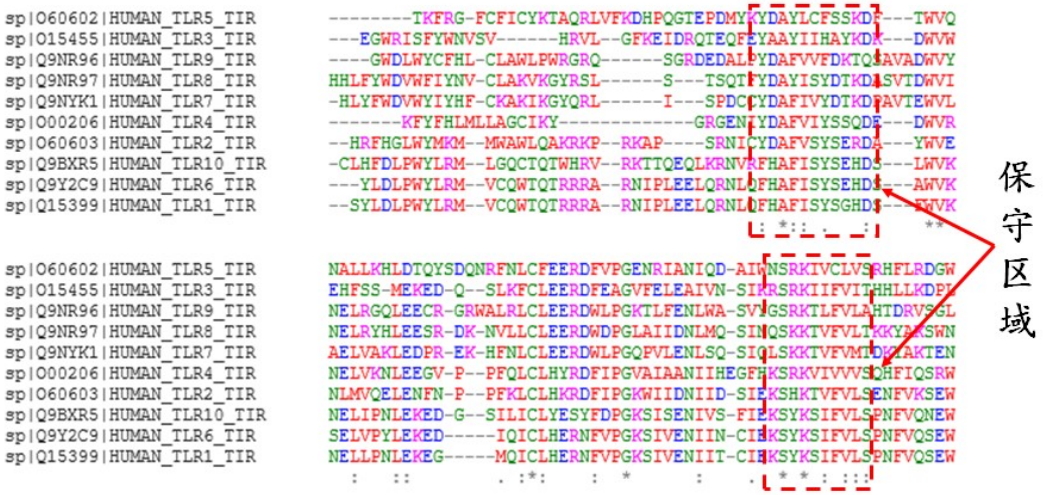


图 1.多序列比对中的保守区域

这里介绍一个新的概念，序列标识图（sequence logo）。序列标识图就是序列的 logo，它是以图形的方式依次绘出序列比对中各个位置上出现的残基，每个位置上残基的累积可以反应出该位置上残基的一致性。每个残基对应图形字符的大小与残基在该位置上出现的频率成正比。 但图形字符的大小并不等于频率百分比，而是经过简单统计计算后转化的结果。图 2 是用一款流行的软件 WebLogo 创建的序列标识图。

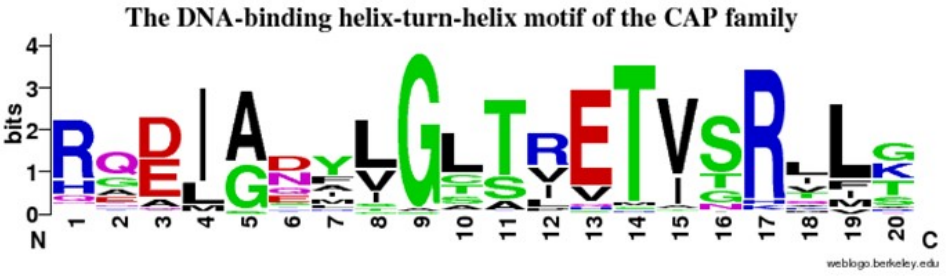


图 2. 序列标识图

要创建序列标识图，首先需要一个多序列比对。多序列比对中的一列对应序列标识图中的一个位置。然后分别计算每一列中不同残基出现的频率，再根据以下公式把频率转换成高度值，最后根据高度值写出不同残基的彩色字母图形。

对于某一列来说，每个字母的高度 $Height = f_i * R$ ，其中

$i=1,\ldots,20$ （f是出现频率）　　$R = \log_2(20) - (entropy + e_n)$

$entropy = -\sum f_i * \log_2(f_i)$　　$e_n = (20 - 1) / (2 * \ln 2 * n)$

entropy：熵　　e_n：小样本检验修正

n：序列个数　　20：残基种类，蛋白质是20，核酸是4

如果某一列非常保守，字母高度就高。反之，如果某一列没有什么特征，各种残基都有出现，杂乱无章，那么就会看到一堆比较矮的字母摞在一起。这里再次强调，字母的高度和它在某一列中出现的频率成正比，但是并不等于频率。试想一下，如果字母高度就是频率的话，那么序列标识图中每个位置上字母摞起来的总高度应该是一样的，都是 100%。但是从图 2 中可以看到，序列标识图上每个位置字母摞起来的总高度是不一样的，这是因为在字母高度的计算过程中涉及了熵值。某一列中字母出现的情况越混乱，熵值越大，字母越矮。字母出现的情况越有规律，熵值越小，字母越高。所以序列标识图可以很好的展现多序列比对中每一列的保守程度，即，它们是杂乱无章的，还有有规律可循的。并且把可循的规律图形化的展现出来。这就是我们为什么要给序列打上 logo 的原因。

WebLogo 是一款在线创建序列标识图的软件（http://weblogo.threeplusone.com/）。

主页面上点“Create your own logos”，然后输入多序列比对（图 2）。WebLogo 可以接受大多数常见的多序列比对格式。示例文件 promoter.fasta 是一组启动子序列的多序列比对，以 FASTA 格式存储。FASTA 格式的多序列比对要求把多序列比对中的每一条序列连同插入的空位一起按 FASTA 格式书写，写完一条序列再写下一条。这和之前讲过的 Clustal 格式不太一样。在序列输入框的下方可以设置不同参数，以定义序列标识图的样式，比如设置序列标识图的创建范围、定义字母的颜色方案等。保持所有参数默认，点“Create WebLogo”。

图 3 为创建出的序列标识图。从图中可以清晰的看到：输入的这些启动子序列上 TATA-Box 的共有特征序列，以及它们出现的位置。



图 2. WebLogo 输入页面

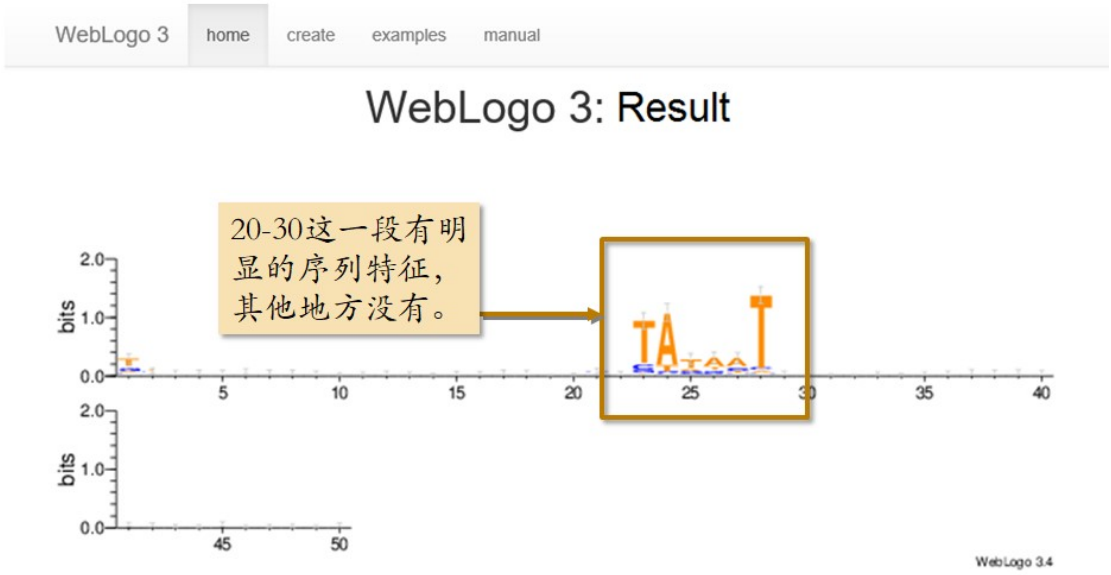


图 2. WebLogo 结果页面