在线双序列比对工具：EMBL 全局双序列比对工具

我们首先回忆一下做双序列比对的算法。为了给两条序列做全局比对，先要建立一个得分矩阵，然后根据公式计算出矩阵里面的数值，并且给这些数值标上来源箭头，再从右下角到左上角追溯箭头并标记红色，最后根据红色箭头从左上角到右下角写出最终的序列比对。有了序列比对，才能据此计算出两条序列的一致度和相似度。

这一节将给你介绍可以在线使用的双序列比对工具。目前，使用率最高的是 EMBL 网站的双序列比对工具（http://www.ebi.ac.uk/Tools/psa）。打开页面，上面有全局比对工具、局部比对工具、还有基因组比对工具。

首先看全局比对中的蛋白质序列比对工具（图 1）。输入值非常简单，把要比较的两条蛋白质序列贴在输入框里或者上传。可以使用示例文件 global.fasta 里面的两条序列。如果想要进一步设置比对的参数，可以点 More options。从这里可以选择使用哪种替换记分矩阵。按照之前讲过的原则，选择 PAM 矩阵或 BLOSUM 矩阵。如果实在不知道选哪个矩阵，就闭着眼睛选 BLOSUME62 吧！下拉菜单里默认选的就是 BLOSUM62。除了选择替换记分矩阵，这里还可以设置空位罚分，也就是 gap 的分值。这里实际上是让你选空位对字母的情况罚几分，所以显示的是正数，但在计算的过程中还是按照负数处理。这里的 gap 分好几种，具体的我们后面再说。在第一个例子里我们不改变这些参数，全部保留默认值，直接点提交。

计算机只需要用几秒钟的时间，就可以计算出结果（图 2）。在结果页面里，上部是比对使用的参数，以及得出的序列比对的长度、一致度、相似度、空位比例和比对得分。下部就是序列比对。在序列比对里，左边是两条序列的名字，因为输入的是 FASTA 格式的序列，所以程序自动识别出了序列的名字。右边的序列比对分 3 行。上下两行是序列，里面插入了许多的空位。中间这行标记出了哪些位置上下两个字母是完全相同的，用竖线表示。上下两个字母相似，用双点表示。上下不相似，用单点表示。字母对空位的情况，用空格表示。这样，我们只要数数比对结果里竖线的个数（40 个），再除以比对的长度（196 个），就可计算出一致度。再用竖线的个数加上双点的个数（40+29=69 个），除以比对长度（196 个），就是相似度。整个比对里一共插入了 65 个空位，占整个比对长度的 33%。序列两边的数是这一行中的字母在序列中的位置数，而不是这一行的长度。比如第二行是 seq1 的第 49 个字母到第 97 个字母，是 seq2 的第 27 个字母到第 75 个字母。

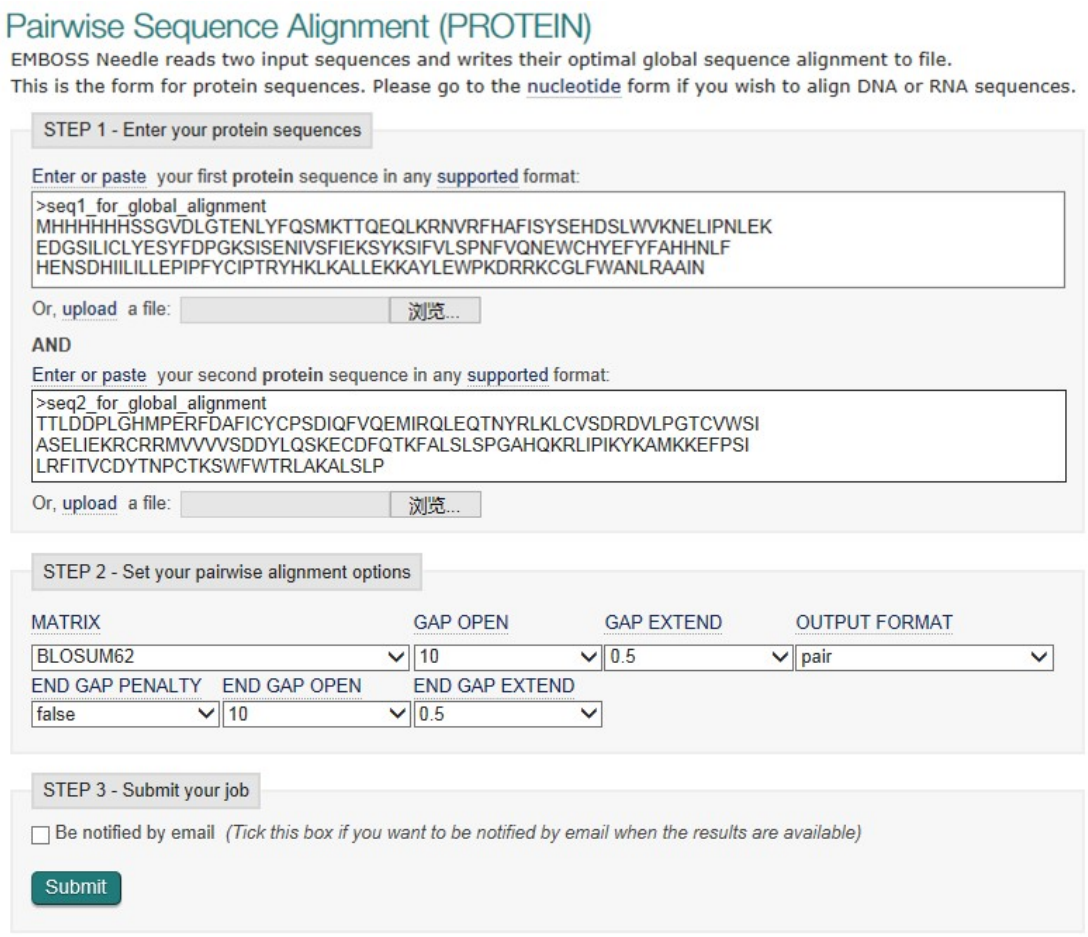


图 1. EMBL 全局双序列比对输入页面

```
#=======================================
# Aligned_sequences: 2
# 1: seq1_for_global_alignment
# 2: seq2_for_global_alignment
# Matrix: EBLOSUM62
# Gap_penalty: 1.0
# Extend_penalty: 5.0
#
# Length: 201
# Identity:      46/201 (22.9%)
# Similarity:    78/201 (38.8%)
# Gaps:          75/201 (37.3%)
# Score: 210.0
#=======================================

seq1_for_glob      1 MHHHHHHSSGVDLGTENLYFQSMKTT-QEQLKR--NVRFHAFISYSEHDS     47
                                               || .:.|..  . ||.|||.|...|
seq2_for_glob      1 ----------------------TTLDDPLGHMPE-RFDAFICYCPSD-     24

seq1_for_glob     48 L-WVKNELIPNLEKEDGSI-L-ICLYE-SYFDPGKS-IS-ENIVS-FIEK     90
                     : :|: |:|..|| :. :. | :|:.: ... || : :   :|.| .|||
seq2_for_glob     25 IQFVQ-EMIRQLE-QT-NYRLKLCVSDRDVL-PG-TCV-W-SIASELIEK     67

seq1_for_glob     91 -SYKSIFVLSPNFVQN-EWCHYEFYFAH-HNLFHENSDHI-ILI-LLEPI    135
                      ..:.:.|:|.:::|: | |.::..||   :| ...: |   .  |: ||
seq2_for_glob     68 RCRRMVVVVSDDYLQSKE-CDFQTKFA-L-SL-SPGA-H-Q-K-RLI-PI    108

seq1_for_glob    136 PFY-CIPTR-YHK-LKALLEKKA-YLEWPK-DRRKCGLFWANLRA-AIN-    178
                     . | .: .: :.. |: .: ... |.. |   . | ..||..| | |::
seq2_for_glob    109 K-YKAM-KKEFPSILR-FI-TVCDYTN-P-C-T-K-SWFWTRL-AKALSL    148

seq1_for_glob    179 -    178

seq2_for_glob    149 P    149
```

图 2. EMBL 全局双序列比对结果页面