在线双序列比对工具：Gap 的类型及分值设置

EMBL 比对工具将 gap 分为两种，一种叫“gap 开头（GAP OPEN）”，另一种叫“gap 延长（GAP EXTEND）”（图 1）。gap 开头就是连续的一串 gap 里面打头的那一个，可以当它是队长。gap 延长就是剩下的那些 gap，也就是队长后面跟着的小兵。这一串里，第一个 gap 是 gap 开头，后面的都是 gap 延长。单独的一个 gap 按 gap 开头算。gap 开头和 gap 延长可以分别定义不同的罚分。默认情况下，gap 开头罚分多，gap 延长罚分少。全局比对的例子里我们就是用这种搭配组合方案做出的比对。这次我们反过来试试，让 gap 开头罚分少，让 gap 延长罚分多。比如 gap 开头选罚 1 分，gap 延长选罚 5 分，其他参数不变，再作一次看看结果发生了什么变化。

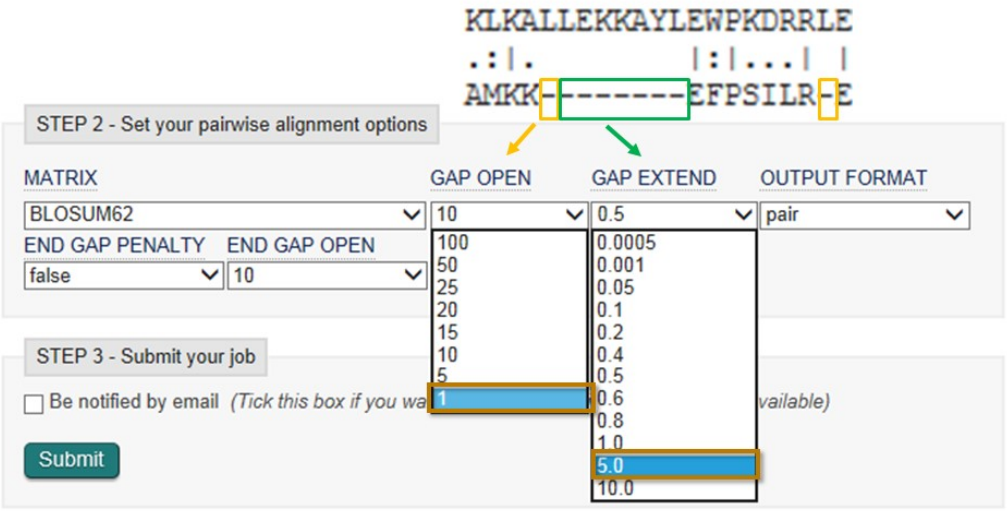


图 1. GAP OPEN 和 GAP EXTEND

当 gap 开头小，gap 延长大的时候，做出来的比对里面，gap 很分散，极少有连续长串的 gap 出现（图 2-A）。开头的一串 gap 是个例外，因为 seq2 太短， seq1 的这一段只能跟 gap 相对。其他部分的 gap 都是分散出现的。这和我们第一次做出来的比对结果是截然不同的（图 2-B）。在第一次做的结果里，也就是 gap 开头大，gap 延长小的时候，gap 很集中，有很多成长串出现的 gap。大家可以想想其中的奥妙。当 gap 开头大，gap 延长小的时候，说明在连续的字母里插入一个 gap 打开一个缺口要付出很大的代价，因为 gap 开头罚分大。但是这个缺口一旦打开了，也就是一旦有了第一个 gap，后面再接更多的 gap 就容易了，因为 gap 延长罚分小。所以这种情况下，gap 都集中连成长串出现。

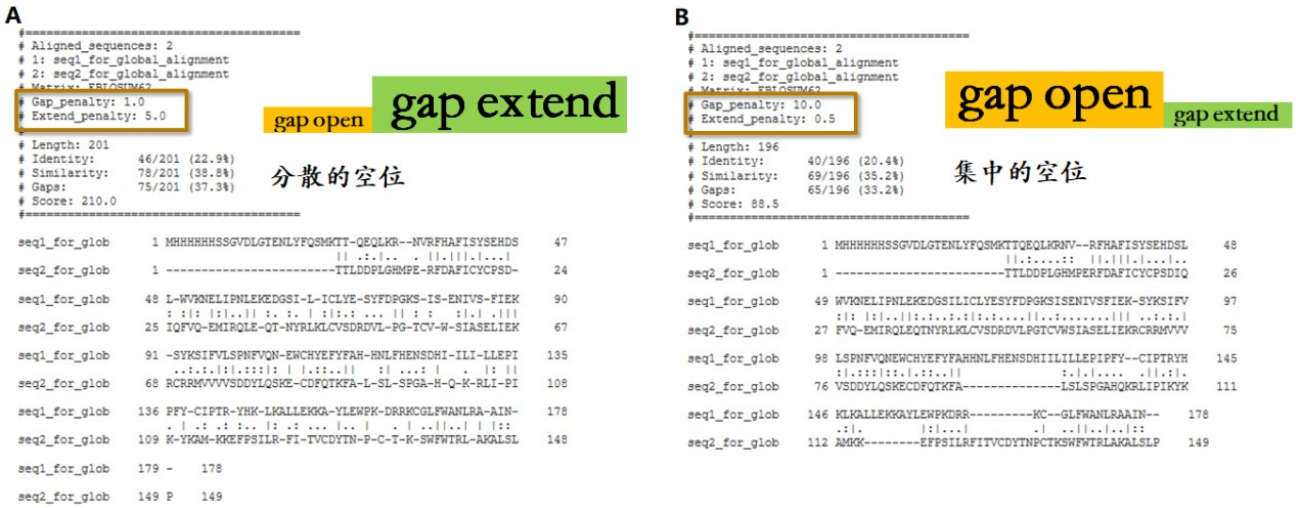


图 2. 设置不同的 GAP OPEN 和 GAP EXTEND

而反过来，当 gap 开头小，gap 延长大的时候，说明在连续的字母里插入一个 gap 打开一个缺口很容易，并不需要付出太大代价，因为 gap 开头罚分小。但是想在第一个 gap 后面再接一个 gap 就难了，因为 gap 延长罚分大。所以这种情况下很难有长串的 gap 出现，gap 每延长一个都要付出巨大代价。因此在第二次我们做的结果里（图 2-A）都是分散的 gap。除了开头一段因两条序列长短不同而不得已出现的长串 gap 外，没有其他的长串 gap 了。

这就是说，通过调整 gap 开头和 gap 延长，我们可以把序列比对做成我们期待的样子。举两个例子，看看应该怎样调整 gap 最合理。第一个例子，你知道要比对的两条序列很相似，是同源序列，所以它们的结构和功能也应该都差不多。其中一条序列的结构已知，另一条未知。你想把它们很好的比对在一起，用其中已知结构的序列做模板，来预测另一个序列的结构。这时候我们期待得到的是 gap 分散的比对结果还是 gap 集中的呢？另一例子，你知道要比对的两条序列绝大部分区域都很相似，但是其中一条序列的一个功能区在另一条序列中是缺失的。你想要通过序列比对把这个功能区找出来。这时候我们要怎么设置 gap 开头和 gap 延长呢？这两个例子告诉我们，在实际应用中，需要根据不同的情况选取不同的 gap 罚分，以满足不同的生物学意义。如果你对结果没有什么预期，那就请保持默认的参数。

除此之外，结尾的 gap 也可以划分出不同的种类并赋予不同的罚分，如果把 END GAP PENALTY 选成 true，就可以设置结尾的 gap 罚分了。结尾 gap 不太常用，特别是在做亲缘关系较近的序列比对时，是否设置结尾 gap，比对结果差别不大。