BLAST 搜索：NCBI BLASTp

我们就以 NCBI 的 BLAST 工具为例尝试一下不同算法的 BLAST 工具（http://www.ncbi.nlm.nih.gov/）。BLAST 链接在 NCBI 主页右侧很显眼的地方。我们做 BLASTp（Protein BLAST），也就是用蛋白质序列搜索蛋白质序列数据库。

在 BLASTp 输入界面里（图 1）：1）输入待搜索的蛋白质序列，这条序列可以在示例文件 blast.fasta 里面找到。2）指定搜索跟输入序列哪部分相似的序列，如果空着就是全长搜索。3）给搜索任务起一个名字，如果输入的是 FASTA 格式的序列，那么在输入框里面点一下，序列的名字就会被自动识别出来。4）如果在 Align two or more sequences 前面打勾的话，可以同时提交多个 BLAST 任务。

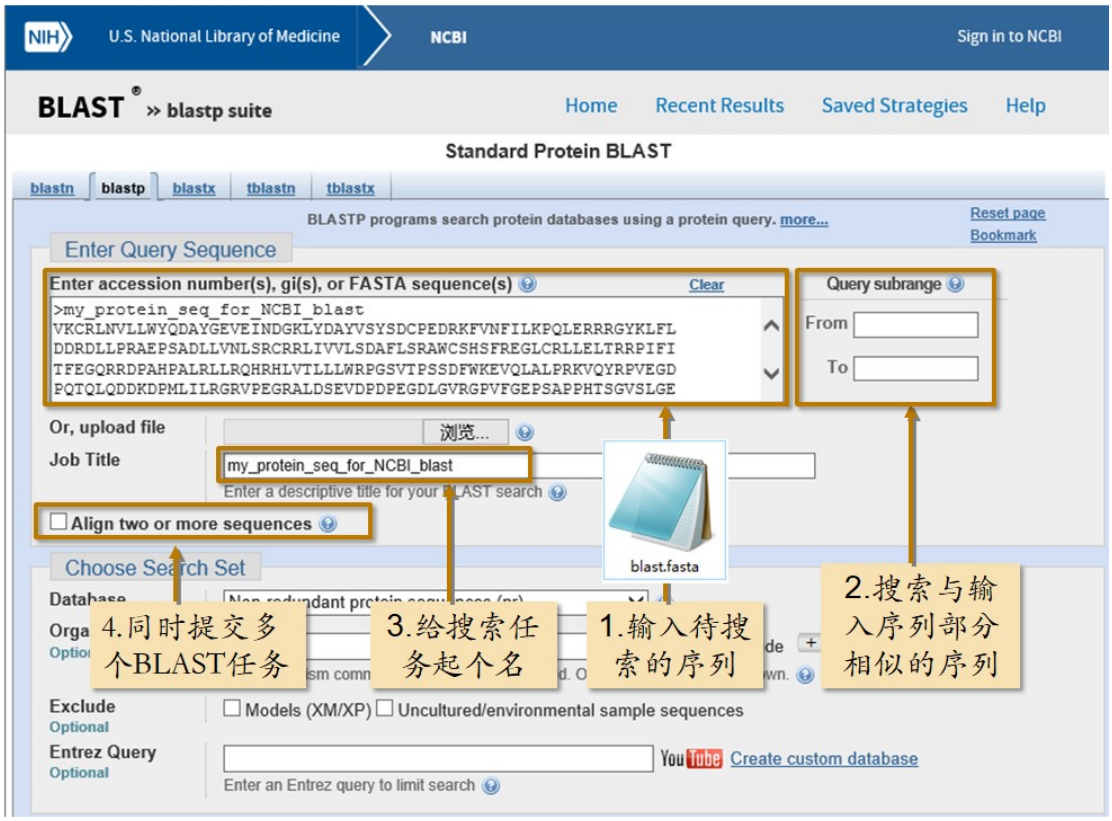


图 1. NCBI BLASTp 输入界面上半部分

在输入界面的下部（图 2）选择：1）被搜索的数据库。我们看到，虽然是 NCBI 的 BLAST 工具，可以选择的数据库却不只 NCBI 下属的数据库，还包括其他组织的数据库，比如 PDB，Swissprot。事实上，各大数据库网站的 BLAST 工具都可以实现跨平台搜索。我们这次用 NCBI 的 BLAST 工具搜索 SwissProt 数据库。2）Organism 可以把搜索范围限定在某一特定物种内，

或者排除某一物种。3）在算法选择这一栏里，有之前提到的三种不同的 BLAST 算法，标准 BLAST，PSI-BLAST 和 PHI-BLAST。这一次我们先尝试标准 BLAST。所有参数设置完毕之后，点 BLAST。

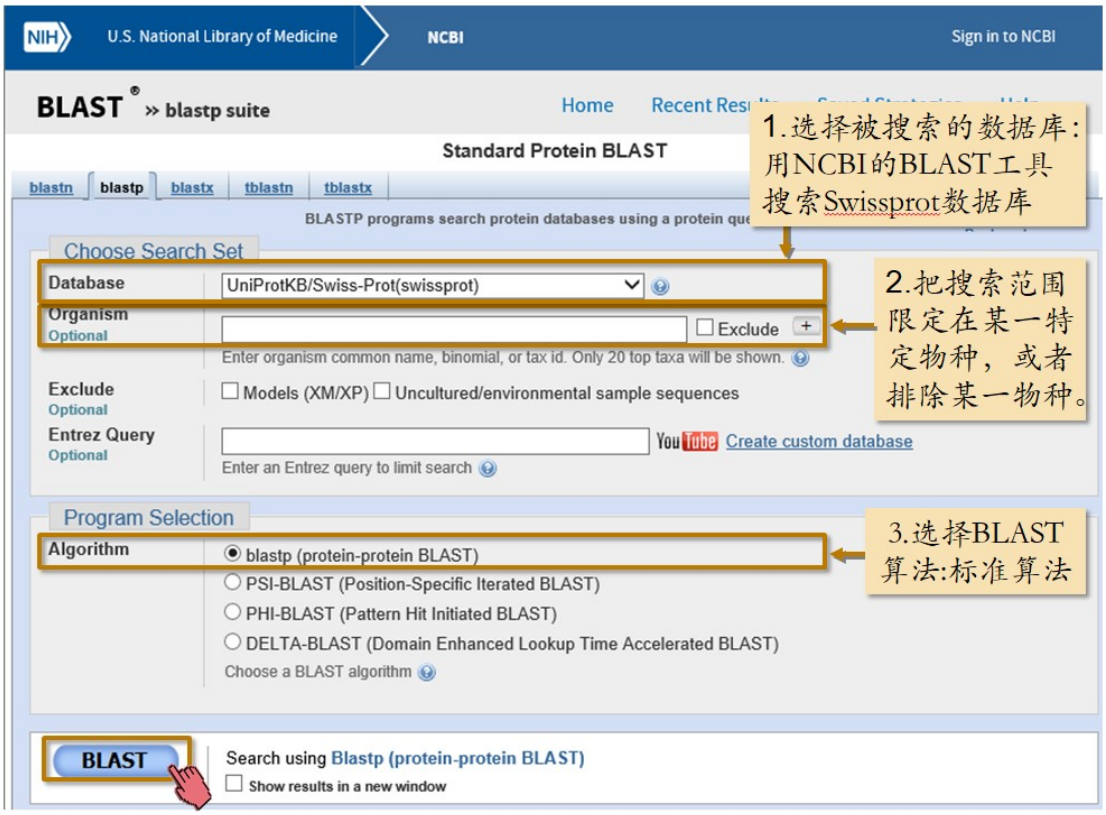


图 2. NCBI BLASTp 输入界面下半部分

做 BLAST 搜索是需要点儿耐心的，不过也不用担心，网速跟得上的话，三五分钟应该就会返回结果。

图 3 是搜索结果。最上面是第一部分搜索任务描述部分。输入界面里设置的各种参数都会在这里列出。

第二部分（Graphic Summary）是图形化搜索结果部分。在图形化搜索结果里，BLAST 工具识别出输入序列的第 25 到第 170 个氨基酸这一段属于 TIR 蛋白质家族。这部分里彩色线条构成的图告诉我们，一共从数据库中找到 50 个 hits，也就是高分匹配片段。注意这些线代表的是 50 个高分匹配片段而不是 50 条序列。一个高分匹配片段有可能是一条全长的序列，也就是全长匹配，也有可能只是某条序列的一部分，也就是局部匹配。代表这些高分匹配片段的线拥有不同颜色和不同的长短。如果把鼠标放到某一条线上，可以看到这条匹配片段的具体信息，包括他所在序列的数据库编号，序列的名字，匹配得分，期望值 E 值。匹

配得分在 200 以上的用红线表示，80 到 200 之间的用粉线，50 到 80 的绿线，40-50 的蓝线，40 以下的黑线，所以颜色反映的是匹配的好坏程度。如果某一个高分匹配片段和输入序列是从头到尾匹配，就是全长的线，比如最上面的三条红线。如果只匹配输入序列的一部分，则是一条短线，短线所在的位置就是与输入序列匹配的位置。

第三部分（Descriptions）是这 50 个高分匹配片段所在序列的详细信息列表。每条序列都有一个匹配得分和覆盖度。这两项决定了第二部分彩图中每条线的颜色和长短。除了匹配得分和覆盖度，表中还列出了其他指标。尤为重要的是 E-value。E-value 也叫做期望值或 E 值。E 值越接近零，说明输入序列与当前这条序列为同一条序列的可能性越大。第三部分的表就是根据 E 值由低到高排序的。随着 E 值增大，匹配得分是成反比逐渐降低的。但是一致度与 E 值并非完全成反比。因为我们在前面讲 BLAST 核心思想的时候说过，BLAST 没有做双序列比对，为了提高速度，它牺牲了一定的准确度。表中的一致度，是 BLAST 搜索完成后，针对搜索到的这 50 条序列专门做双序列比对而得到的。BLAST 牺牲掉的准确度对高度相似的序列，也就是亲缘关系近的序列构成不了威胁，不会把它们落掉，但是对于那些只有一点点相似，也就是远源的序列，就有点麻烦了，它们很有可能被丢掉而没有被 BLAST 发现。

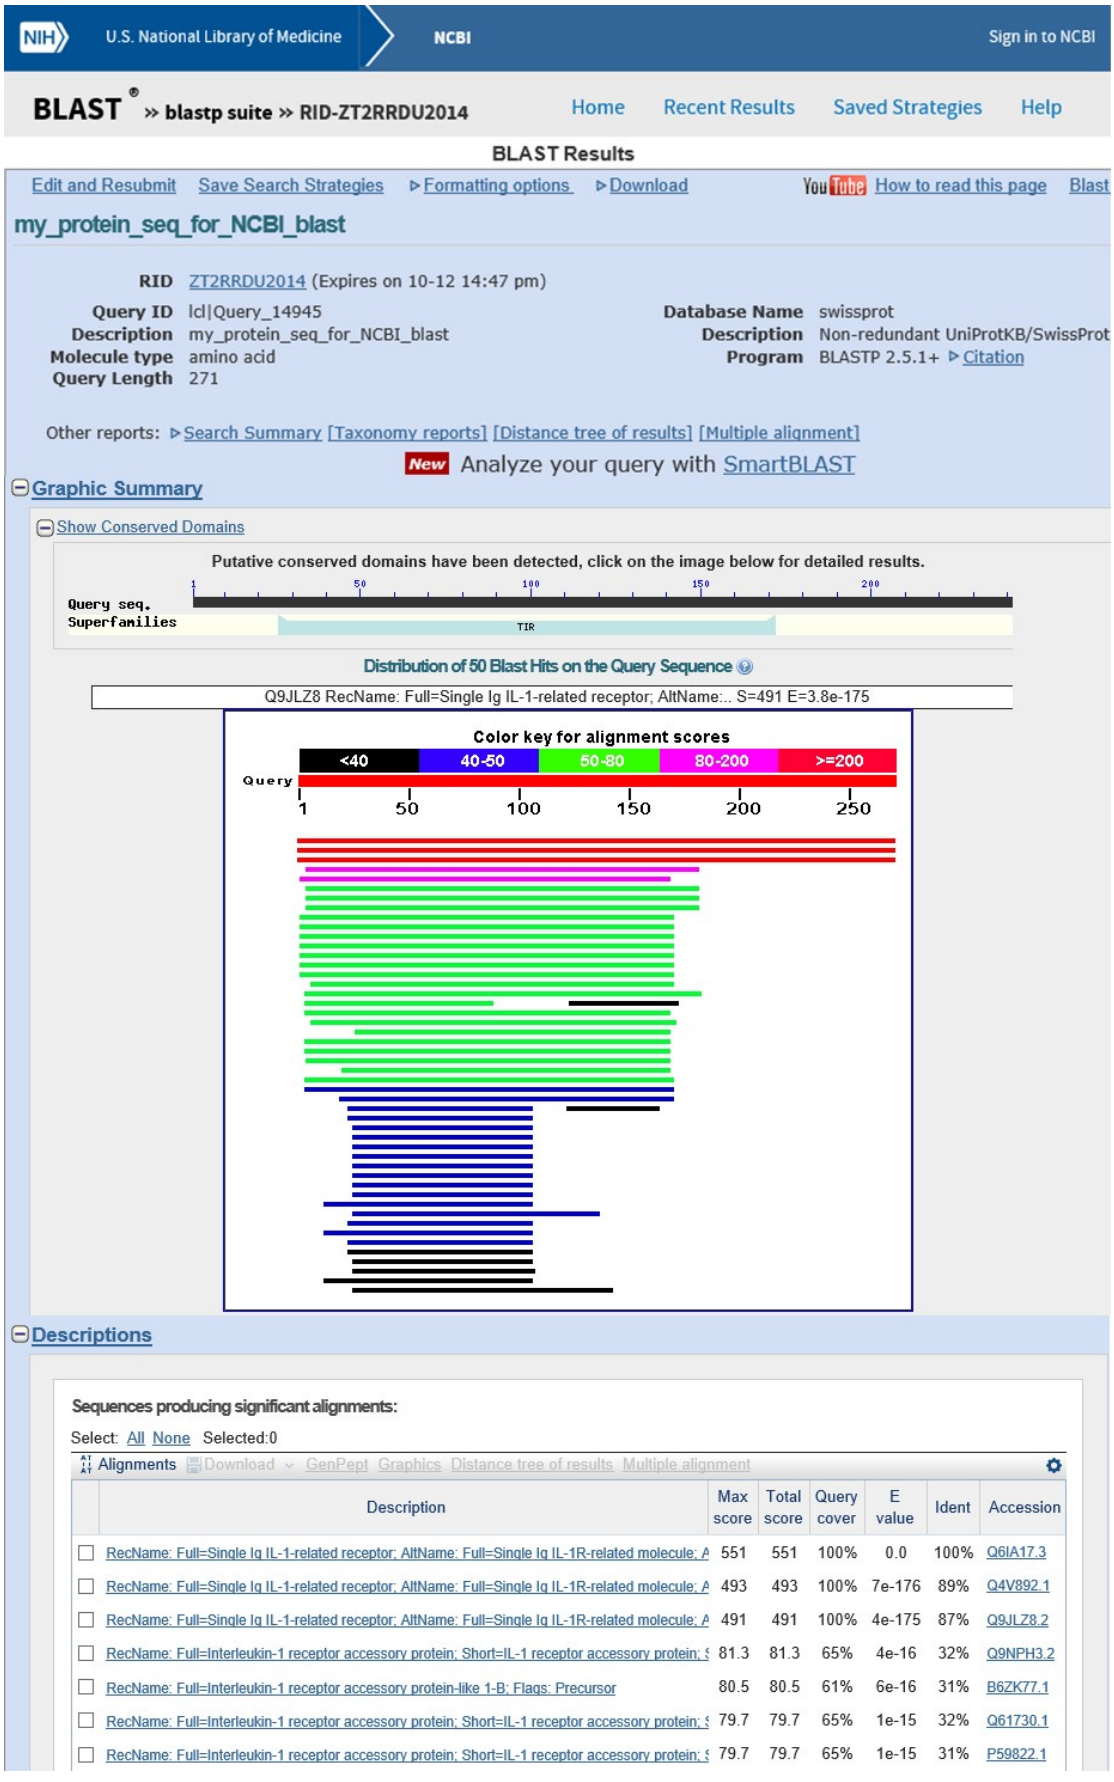


图 3. NCBI BLASTp 搜索结果