BLAST 搜索：NCBI PHI-BLAST

PHI-BLAST 和 PSI-BLAST 不同，PSI-BLAST 是撒大网搜索，而 PHI-BLAST 则是精准搜索。PHI 是 Pattern-Hit Initiated 首字母缩写，中文是模式识别。PHI-BLAST 能找到与输入序列相似的并符合某种特征模式的蛋白质序列。模式 Pattern 是对特征的描述。通俗的说，比如某个会议的会场服务人员都符合这样一个特定的模式：短发戴眼镜穿白色 T 恤的女生。换到生物领域，比如发生 N 糖基化位点的序列都符合这样一个特定的模式：发生糖基化的天冬酰胺，后面一定紧跟一个脯氨酸以外的氨基酸，再紧跟丝氨酸或者苏氨酸，再紧跟一个脯氨酸以外的氨基酸。

特定模式可通过正则表达式来表述。所谓正则表达式就是这句话的一个简约的规范性字符书写法。发生 N 糖基化位点的序列符合的特定模式翻译成正则表达式为 `N{P}[ST]{P}`。其中，N 是天冬酰胺，P 是脯氨酸，S 是丝氨酸，T 是苏氨酸。{}代表除大括号里的氨基酸以外的任意氨基酸，[]代表中括号中的任意一个氨基酸。得知这些符号的含义之后，这个正则表达式就很容易读懂了。PHI-BLAST 可以根据给入的正则表达式对搜索到的相似序列进行模式匹配，符合正则表达式的才会被作为结果输出。

我们再来熟悉一下正则表达式，{}代表除什么以外，[]代表其中之一，x 代表任意字母，(3,7)代表 3 到 7 个某字符。那么正则表达式 `{L}GEx[GAS][LIVM]x(3,7)` 的意思是，除 L 以外的任意一个字母，紧接 G，再紧接 E，再接一个任意字符，之后是 GAS 中的任意一个，再接 LIVM 中的任意一个，最后再接 3 到 7 个任意字符。据此，`VGEAAMPRI` 这条序列是符合这条正则表达式的，而 `VGEAAYPRI` 这一条则不符合。这种序列特征模式可能代表某个翻译后修饰的发生位点，也可以代表一个酶的活性位点，或者一个蛋白质家族的结构域、功能域等有重要意义的地方。

在 NCBI BLAST 工具的输入页面，当算法选择了 PHI-BLAST 之后，会自动出现模式输入框（图 1）。输入正则表达式 `S[IVFL]TPS(2)`（含义为：一个 S 后面紧接 IVFL 中的任意一个字母，再接 T，再接 P，再接两个 S）。这次搜索找到的相似序列中，只有符合该模式的才会被作为结果返回。

结果显示只有几条严格符合模式的序列被找到了（图 2）。此外，PHI-BLAST 可以和

PSI-BLAST 联合使用，以找到更多符合模式的远房亲戚们。

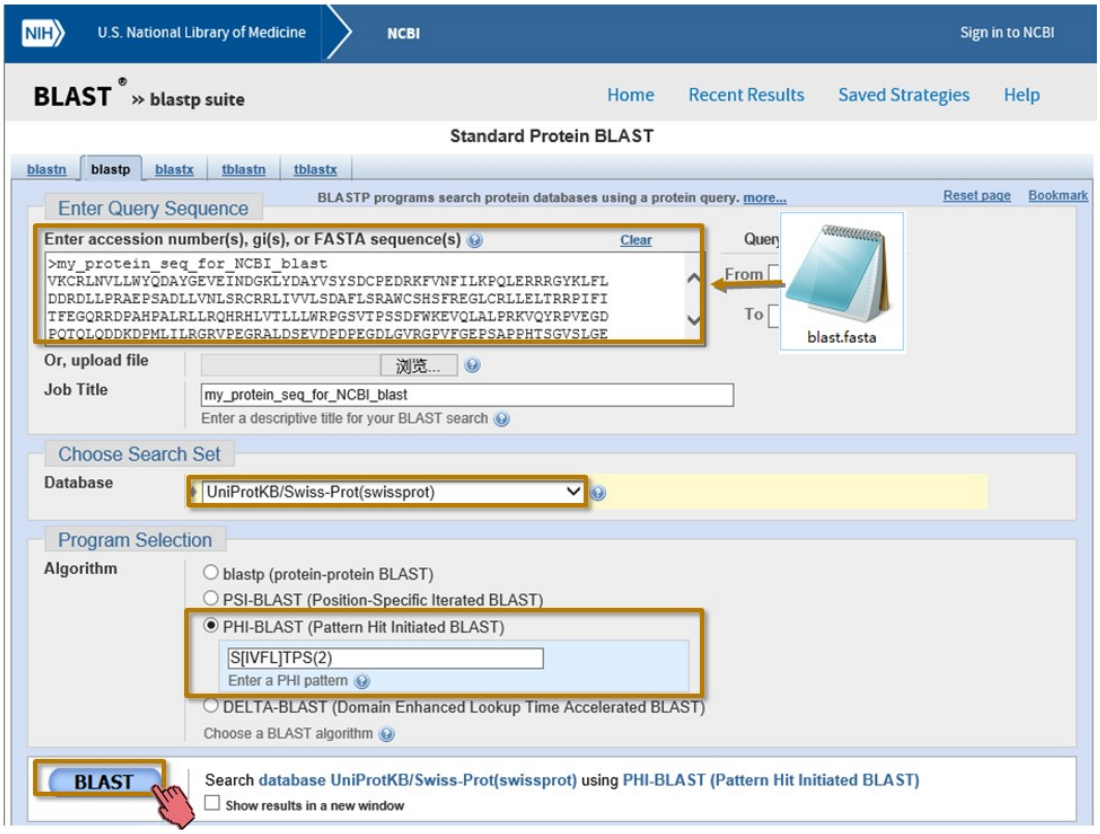


图 1. NCBI PHI-BLAST 输入界面

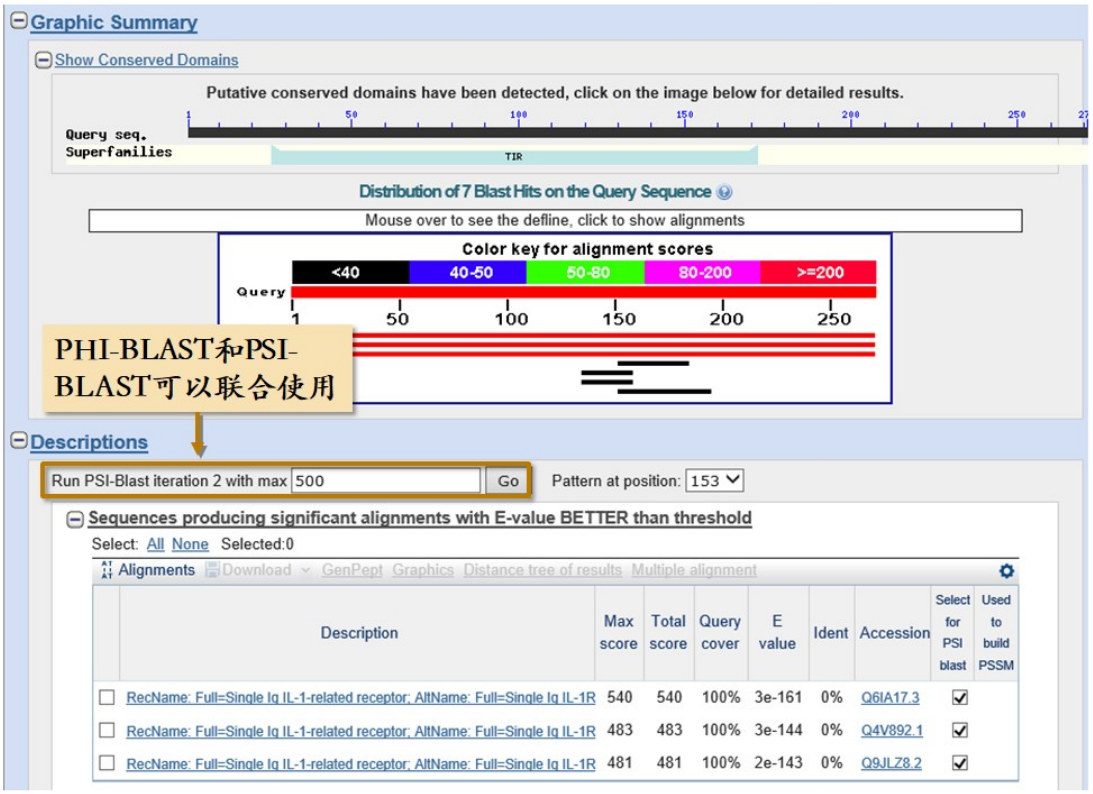


图 2. NCBI PHI-BLAST 结果界面

现在我们用一个故事来总结一下标准 BLAST，PSI-BLAST 和 PHI-BLAST 这三种 BLAST 的区别。图 3 是老师我在德国时养的一只宠物仓鼠，叫大腮帮子。在我离开德国时，它的血脉已经延续到第四代了，而且这只仓鼠还是华人论坛宠物版块评选的冠军宠物。不幸的是，这只鼠鼠有一天误食了有毒的花草，英年早逝。我很想念它，于是决定再培养一支冠军仓鼠。打开宠物网站，输入了大腮帮子的照片，想买只差不多的。标准 BLAST 返回的结果中基本都是仓鼠，但种类不同，有很像的，也有一般像的。我发现其他种类的仓鼠也挺可爱的，比如金丝熊。那干脆扩大一下范围，看看还有什么可爱的小家伙。于是进行了 PSI-BLAST，这下可好，除了仓鼠，米老鼠，老鼠玩具，鼠标什么的也都被找出了。当然除了这些不靠谱的，也有靠谱的被找到了，比如 chinchilla，龙猫！可是，太贵了，买不起，还是买个和大腮帮子一模一样的吧，至少要具备它最受欢迎的特征，这样才能成为冠军仓鼠。于是进行了 PHI-BLAST，并且输入特征模式：三线-大眼睛-长胡子-雄性。这次 PHI-BLAST 终于帮我找到了一只合适的仓鼠。只是把它买回家没过几天就生了一窝小仓鼠。天啊，系统不是说是公的嘛！希望大家通过这个小故事能够更好的掌握什么时候用什么 BLAST，用对了事半功倍！

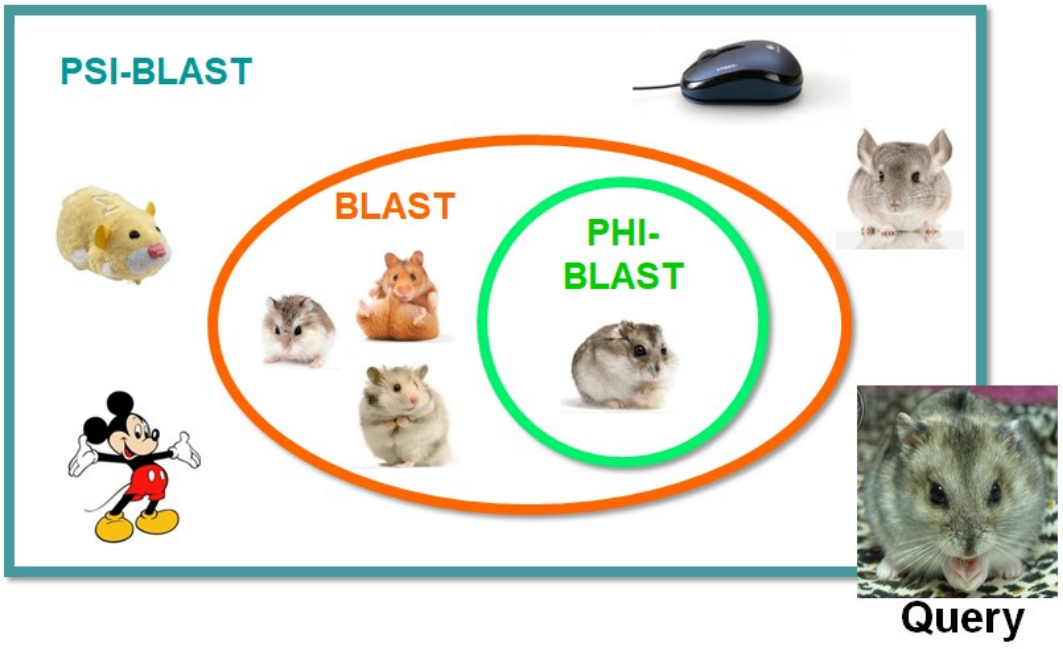


图 3. 三种 BLAST 的区别