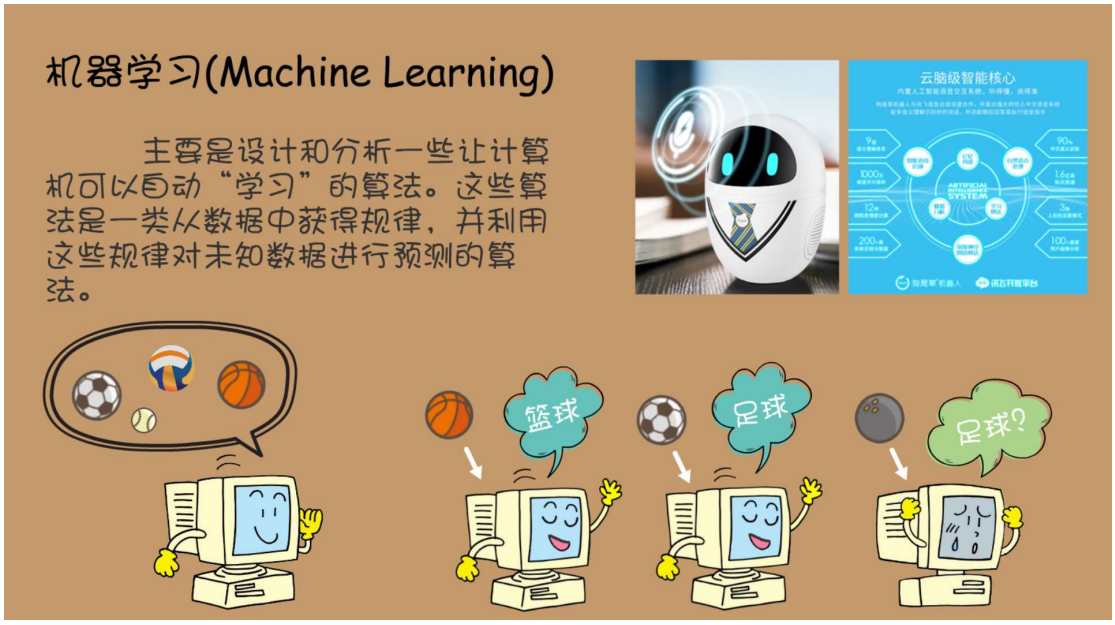
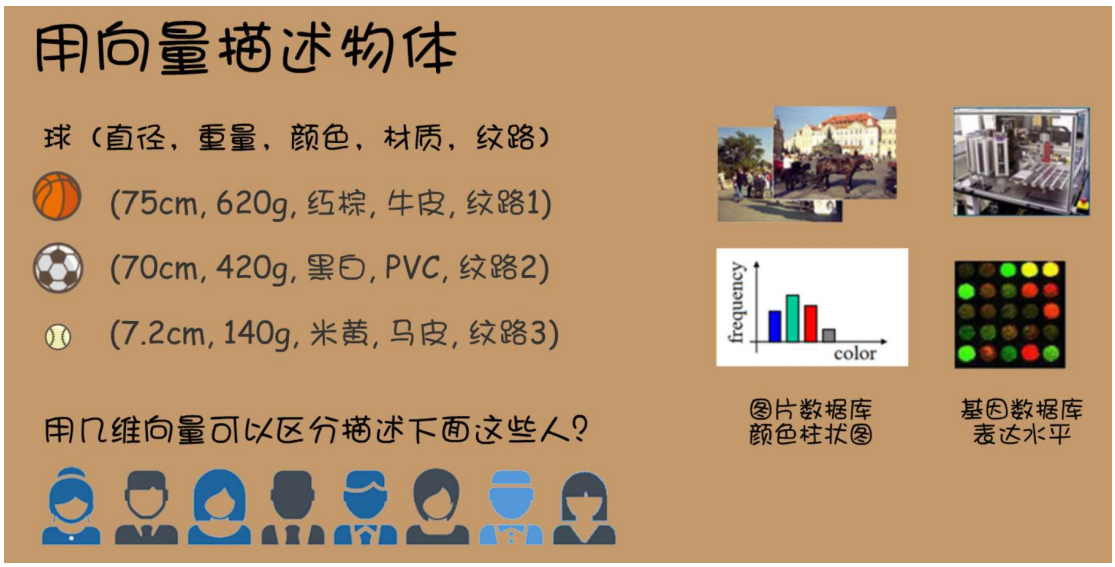
机器学习：主要任务

机器学习主要是设计和分析一些让计算机可以自动“学习”的算法。这些算法是一类从数据中获得规律，并利用这些规律对未知数据进行预测的算法。比如有台电脑，我们想让他学会辨认各种球，那么我们就拿来很多球让电脑学习，告诉它这样的球足球、这样的球是排球，这样的球是篮球，这样的球是棒球。经过大量的学习后，电脑说，我已经学会了，可以分清这四种球了。好，我们来考考他。学过的都能掌握，没学过的打死也不会，这就是机器学习。如果机器学习到了一个很高的境界，能够主动学习了，并能正确掌握学习到的东西，那就走向人工智能了。目前市面上比较火的公子小白就具备机器学习的功能，但可惜仍然是比较初级的被动学习，还没有智能到主动学习。



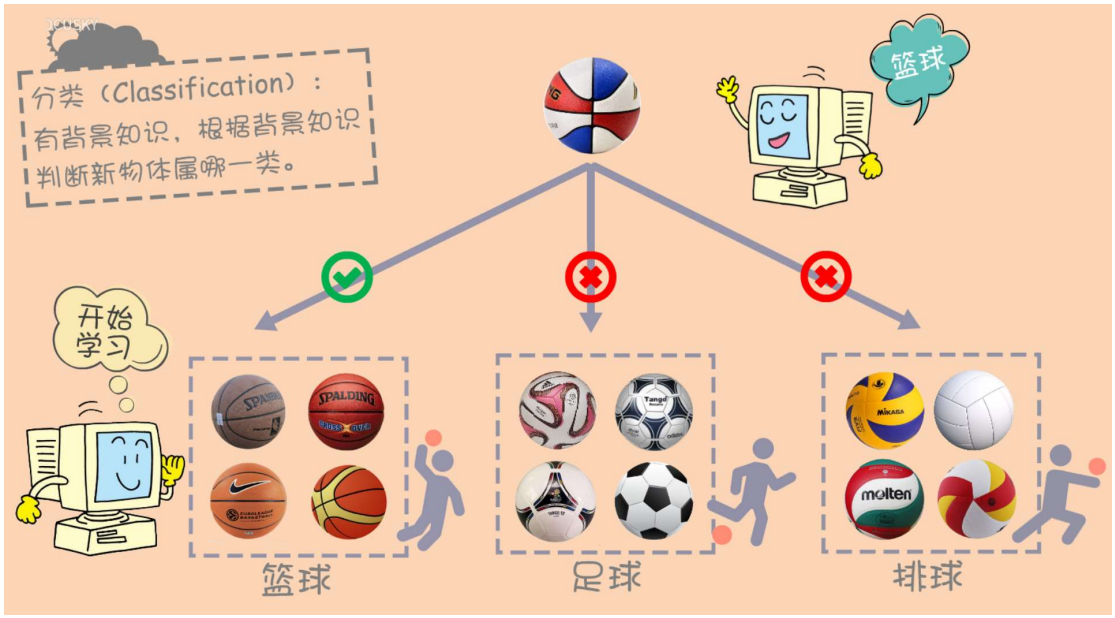
现在回到最初的问题上，看看这个电脑是怎么学会识别各种球的。电脑没有眼睛，所以我们也不是真的把球摆到电脑面前让他看。我们实际上是把电脑学习的物体转化成了向量，让电脑读取向量值，也就是用向量来描述物体。我们可以用一个 5 维的向量来描述一个球。这五个维度分别描述了球的直径、重量、颜色、材质和纹路。这样一个向量足够将各种球区分开了。几乎所有物体我们都可以把他转化成多维向量。比如图片可以转换成颜色柱状图，并由此创建一个 36 维的向量，一个维度对应一种颜色，每一维度上的值代表这种颜色在图片中出现的频率。再比如，基因表达水平，可以用描述基因芯片上每个点的颜色及深浅的向量来表示。甚至我们教室里的每一个人都可以向量化。



下面我们来看看，机器都能学些什么，也就是机器学习的任务。常见的机器学习的任务有分类、聚类和回归。分类和聚类虽然名字很像，但他们的区别还是巨大的。之前教给小电脑完成的任务就是分类任务。



分类任务要有足够的背景知识去训练电脑，告诉电脑这个样的都是篮球，这个样的都是足球，这样的都是排球。然后拿学习过的这些球以外的球，让电脑判断是哪一种球，这就是分类。

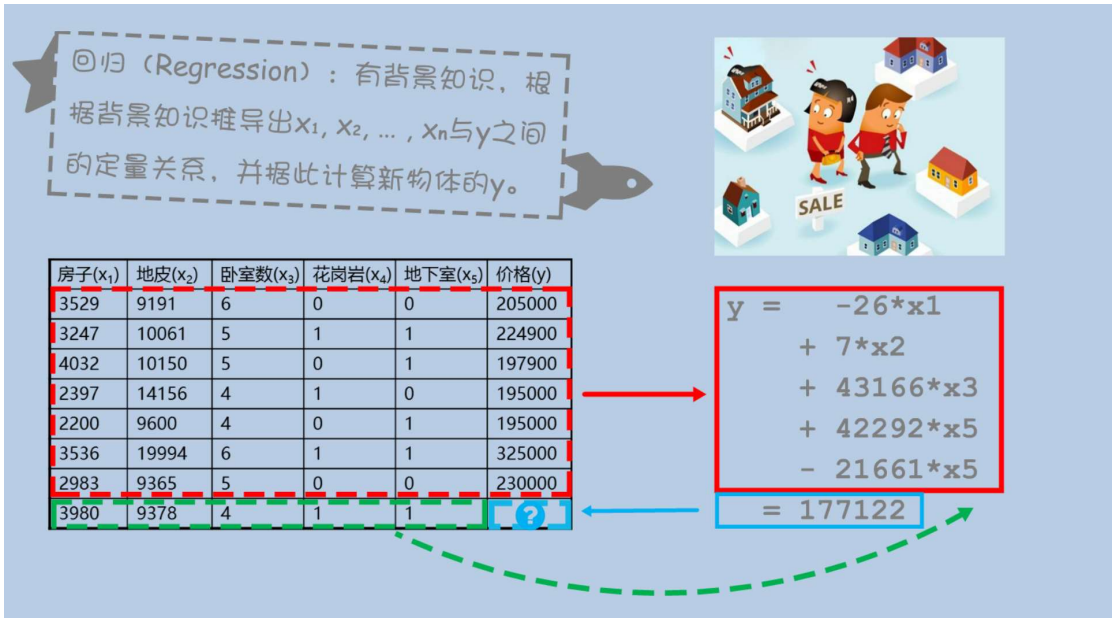


再来看聚类，要理解聚类可以设想这样一个场景，一个外星人来到地球，对球状物体非常痴迷，从地球上搜集了大量的球状物体。它不知道这些球状物都是什么，为了更好的研究它们，外星人把长得差不多的球都放在了一起，并且将它们命名为球 1、 球 2 和球 3。这个过程就叫聚类。由此可见，聚类和分类最大的区别就是聚类不需要背景知识，而分类需要。



最后看看回归。回归跟分类一样，也是通过对背景知识的学习达到预测未知的目的。只不过，这次预测的不是属于哪一类，而是预测一个具体的数值。比如房产公司可以根据房屋情况利用回归算法估算房屋价格。房产公司拥有大量已成交房屋的数据，包括房子大小、地皮大小、卧室数量、建材是否是花岗岩、有没有地下室以及房屋的最终售价。现在他们想要

让电脑学习这些数据，从而建立起房屋的各项指标和价格之间的定量关系，这样他们就能够更加准确的给待出售的房屋定价了。通过机器学习，最终返回了一个公式。公式体现了 x1、x2、x3、x4 和 x5 与 y 之间的定量关系。对于新登记的房屋，只要把 x1 到 x5 这五个指标数值带入公式，就可以估算出房屋的售价。



房子(x_1)	地皮(x_2)	卧室数(x_3)	花岗岩(x_4)	地下室(x_5)	价格(y)
3529	9191	6	0	0	205000
3247	10061	5	1	1	224900
4032	10150	5	0	1	197900
2397	14156	4	1	0	195000
2200	9600	4	0	1	195000
3536	19994	6	1	1	325000
2983	9365	5	0	0	230000
3980	9378	4	1	1	?