机器学习：K 次交叉检验

回归和分类都需要背景知识，也就是训练组数据来训练出预测模型，而聚类不需要。预测模型训练好之后还需要从训练组数据中拿出一部分作为测试组数据来测试模型的准确度。这里问题就来了。哪些数据可以用来做测试组呢？

理论上，所有已知结果的数据都应该拿来训练，这样训练才充分。可是，这些训练数据以外的都是不知道结果的，无法拿来做测试？用训练数据本身做测试，肯定不行！因为你的算法就是基于你的这组数据产生，肯定适合你的这些数据，但是换这些数据以外的数据可能就不适合了，属于过学习。那么，我们从训练组数据里拿出一小部分做测试用，用剩下的做训练，这样是否可行呢？也不行，因为有一部分知识预测模型没有学习到，属于欠学习。

这时，我们可以使用 K 次交叉检验（K-fold cross validation）。所谓 K 次交叉检验就是把所有能够搜集到的已知结果的数据，分成 K 份。我们以 4 份为例。将第一份拿出来作为测试组数据，其余 3 份作为训练组数据。用选定的算法根据训练组数据训练出一个模型。再用测试组数据测试模型的准确度。然后将第二份拿出来作为测试组数据，其余 3 份作为训练组数据。用选定的算法根据训练组数据训练出一个模型。再用测试组数据测试模型的准确度。依次类推，让每一份都作一次测试组数据。这样就会用同一种选定的算法构建出 4 个模型，进行 4 次测试，得到 4 个准确度。最后取 4 个准确度的平均值，得到的平均准确度就是用全部训练组数据训练出的最终模型的准确度。利用 K 次交叉检验可以有效避免过学习的现象。因为测试组数据并未参与相应模型的构建。同时也避免了欠学习的现象，因为所有训练组数据都学习到了。

