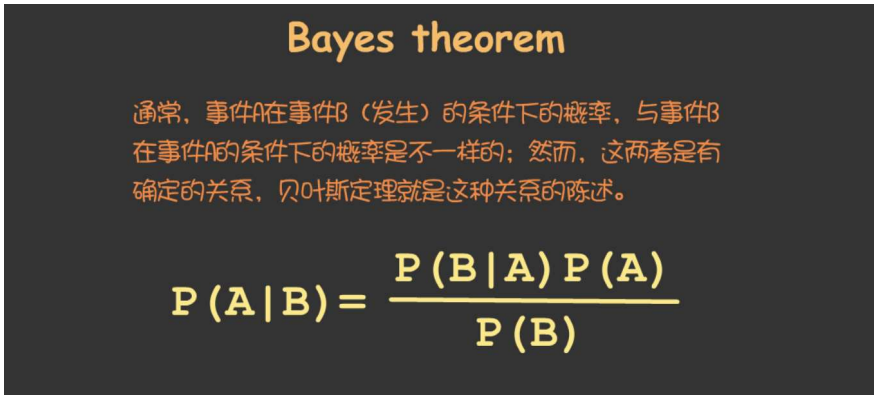
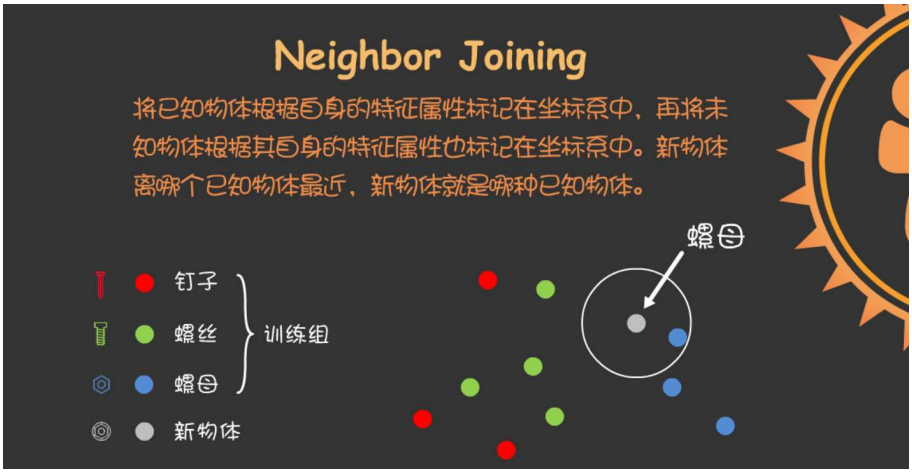
机器学习：常见算法

机器学习能完成诸如分类、聚类、回归等任务。那他是如何完成这些任务的呢？是通过各种机器学习的算法来完成的。常见的算法有贝叶斯、最近邻居、决策树、支持向量机、人工神经网络、遗传算法等。我们没有足够的时间从理论上完全掌握这些算法，但是应该从科普的角度至少知道他们是怎么回事。这里挑其中一二给大家介绍一下。

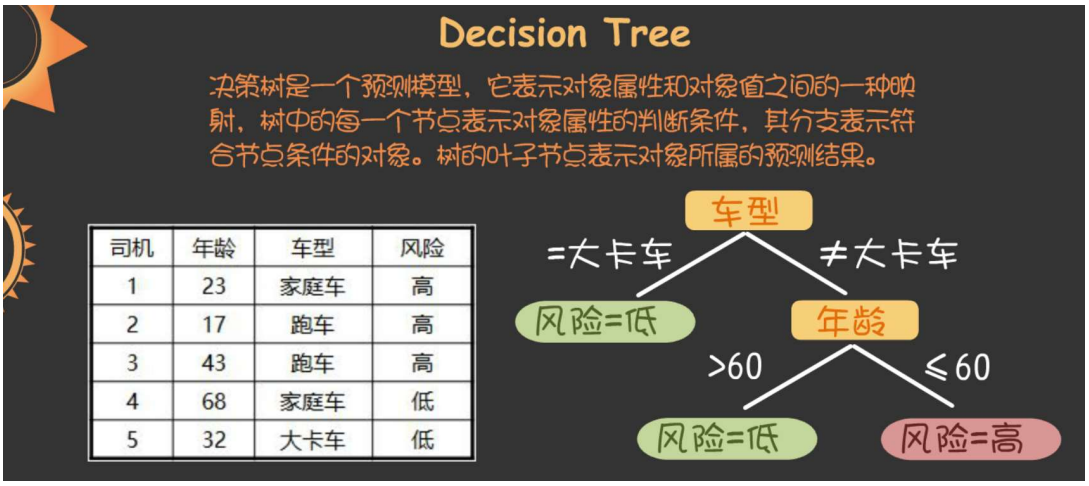
所谓贝叶斯法就是基于贝叶斯原理的一种概率统计算法。关于贝叶斯定理我们已经在前面的章节给大家详细介绍过了。这里就不多说了。



再来看最近邻居法。它是把已知物体根据它们的属性，标记在一个坐标系中。比如各种钉子根据它们的外形是红色这堆，各种螺丝是绿色这堆，蓝色这堆是各种螺母。因为螺母外形上跟钉子和螺丝差别较大，所以在坐标系中，它离另两种物体比较远。接下来我们根据新物体的外形把它也标记在坐标系中。然后看离它最近的邻居是什么，它就是什么。这里，离新物体最近的是螺母，那么新物体就应被分类为螺母。



决策树非常好理解，给大家举个例子就明白了。这是个保险公司统计的被保人所处年龄、所开车型与出险率高低的统计表。历年数据显示，23 岁开家庭车的司机风险高，17 岁开跑车的高，简直就是马路杀手，43 岁开跑车的也高，看来跑车风险就是高。68 岁开家庭车的低。32 岁开大卡车的也低。别问什么，这是德国教材上的例子。现在我们来看看保险公司利用这些数据都做了什么。他们根据这些数据画了一棵树，并利用这棵树对即将投保的人进行风险评估。先判断车型，大卡车的风险低，不是大卡车的再判断年龄，60 岁以上低，60 岁以下高。有了这棵树，只要知道新投保人的年龄和车型，就可以判断出风险高低。这就是决策树。



司机	年龄	车型	风险
1	23	家庭车	高
2	17	跑车	高
3	43	跑车	高
4	68	家庭车	低
5	32	大卡车	低

支持向量机和最近邻居差不多，也是把已知物体根据属性标记在坐标系中，然后画一条线。画的这条线要尽可能的把不同物体全部分开。新物体落在线的哪一侧就属于哪种物体。问题的关键就是这条线怎么话。绿色和蓝色两种画法肯定都没有黄色画法好。比如绿色这条线，如果新物体落在这个位置，因为他在绿线的右侧，所以他会和黄点归入一类，但实际上他跟这堆蓝点离得更近。如果，这条线画成黄线这样，就不会出现刚才的问题。所以我们要画这样一条线，首先这条线要把不同的已知物体尽可能的分开，且线两边距离线最近的物体到线的垂直距离要尽可能的大。也就是所谓的间隔最大化，也叫做最大最小距离。只有这样画出线才能成功完成任务。

