WEKA：WEKA 中的术语

机器学习听起来挺酷，但是实现起来貌似有点儿困难，特别是对非专业人士。不用担心，我将给你介绍一款做数据挖掘的傻瓜级软件 WEKA（http://www.cs.waikato.ac.nz/ml/weka/）。WEKA 的全名是怀卡托智能分析环境。WEKA 也是新西兰一种鸟的名字。WEKA 的主要开发者来自新西兰怀卡托大学。WEKA 是免费的，它可以完成各种各样的数据挖掘任务，就像傻瓜相机一样，算法的事儿完全不需要你操心，你只要输入数据，告诉 WEKA 你要完成什么样的挖掘任务，再选择现成的算法，WEKA 就会为你返回想要的结果模型。

要让 WEKA 替你完成挖掘任务，你需要先给 WEKA 你的数据。目前我们大多数人手里的数据可能都存储在 Excel 表格里。非常遗憾，WEKA 不能读取 Excel 数据。WEKA 的数据存储格式是 ARFF 格式。这种格式的文件其实就是一个纯文本文件，可以用写字板或记事本打开。在 WEKA 安装目录下的 data 文件夹里有许多 ARFF 文件。我们用记事本打开其中的 weather_numeric.arff。图 1（右）是 ARFF 数据的原始容貌。我们也可以用 WEKA 的 ARFF viewer，将这些文本样式的数据转换成表格形式图 1（左）。这组数据记录了不同的天气与是否适合打球之间的对应关系。比如晴天，温度 85，湿度 85，不刮风的时候不适合打球，而阴天，温度 80，湿度 90，不刮风的时候适合打球。

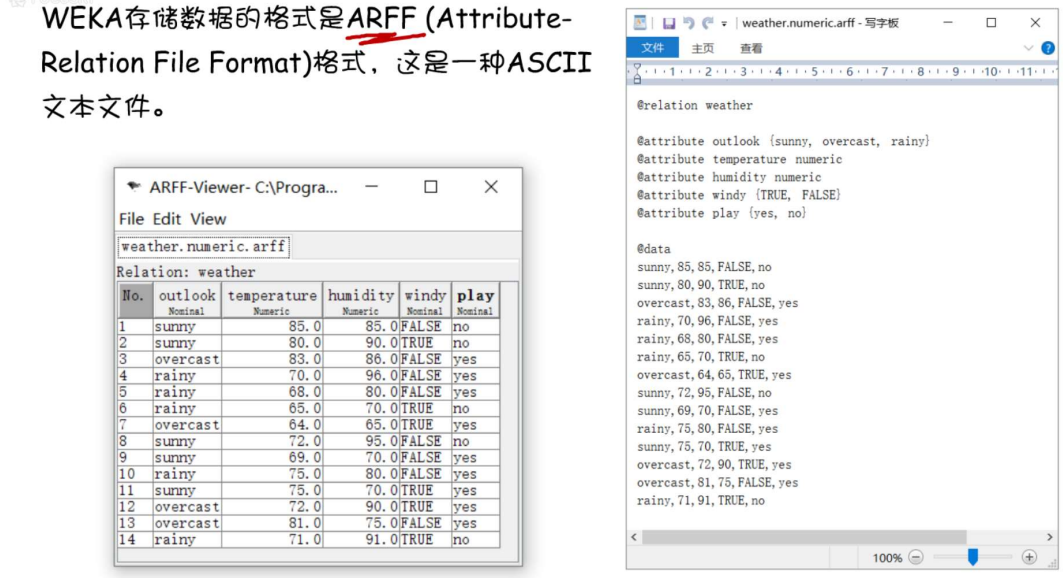
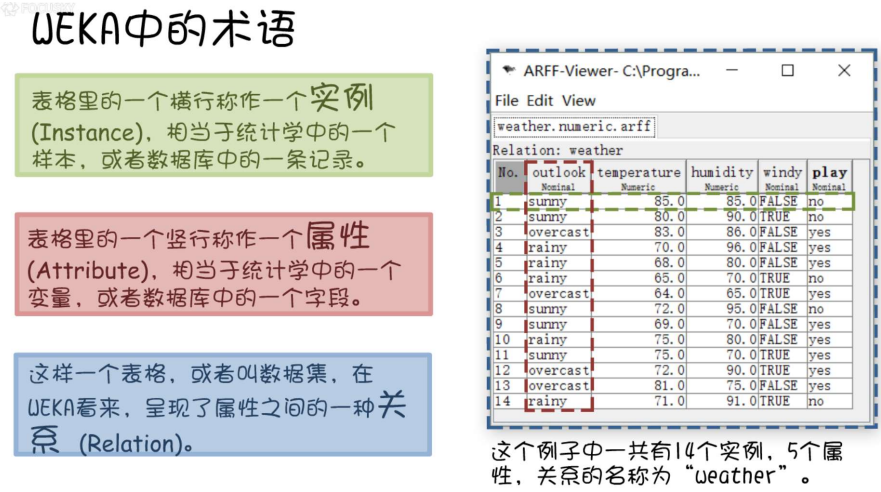
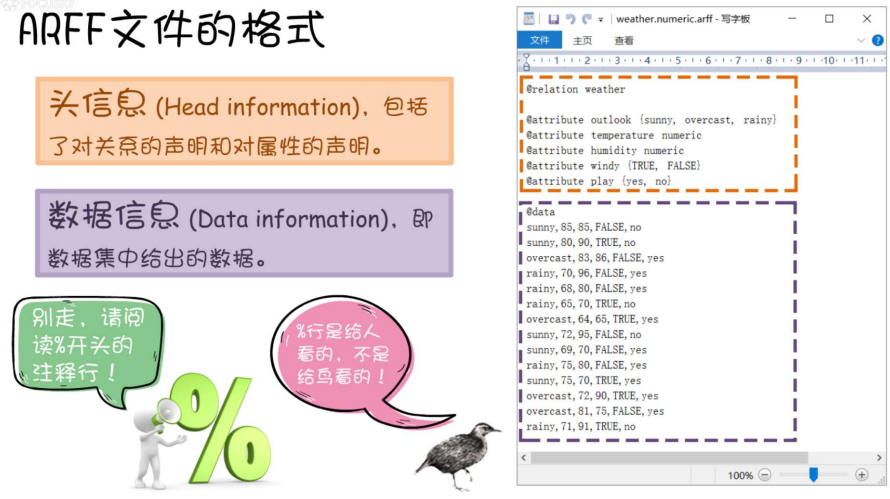


图 1. WEKA 的 ARFF 格式数据文件

WEKA 中的术语。表格里的一行叫做一个实例（Instance），相当于统计学中的一个样本，或者数据库中的一条记录。这组数据一共有 14 行，也就是 14 个实例。表格里的一列称为一个属性（Attribute），这个表格一共有 5 个属性，分别是 outlook（天气概况）、temperature（温度）、humidity（湿度），windy（是否刮风）以及 play（是否打球）。前四个属性是关于天气的描述，最后一个属性是要判断的关键性问题。这个表格实际上就是反映了前四个属性跟最后一个属性之间的关系。所以 WEKA 管一个表格叫一个关系（Relation）。这个关系的名字是 weather（天气）。



ARFF 文件的格式。WEKA 读取 ARFF 文件的重要依据是分行和空格，因此不能在这种文件里随意的断行，以及随意加入空格。空行以及全是空格的行将被忽略。打开一个 ARFF 文件，经常会看到大段%开头的内容，这些是关于数据的注释。WEKA 在读取文件时会自动忽略这些行。除去注释后，整个 ARFF 文件可以分为两个部分，第一部分头信息（head information）是对关系和属性的定义，第二部分数据信息（data information）就是数据值。



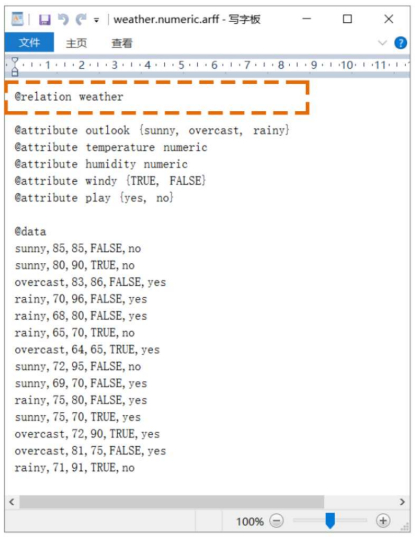
ARFF文件的格式

关系声明：

关系名称在ARFF文件的第一个有效行来定义，格式为：

`@relation <relation-name>`

其中<relation-name>是一个字符串，如果这个字符串中包含空格，它必须加上引号（指英文标点的单引号或双引号）。



ARFF文件的格式

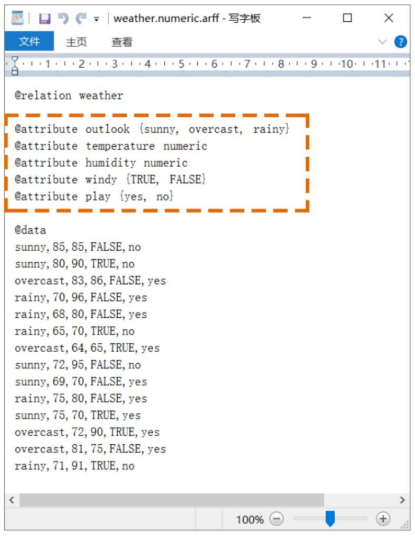
属性声明：

用以定义每一个属性的属性名称和属性类型，格式为：

`@attribute <attr-name> <attr-type>`

其中<attr-name>是必须以字母开头的字符串。和关系名称一样，如果这个字符串包含空格，它必须加上引号。

属性声明语句的顺序表明了属性在数据部分的位置。最后一个声明的属性被称作class属性。在分类或回归任务中，它是默认的目标变量。



ARFF文件的格式

数据信息：

数据信息中 `@data` 独占一行。接下来是所有实例的数据信息。每个实例占一行。实例的各属性值用逗号 `,` 隔开。如果某个属性的值是缺失值(missing value)，用问号 `?` 表示，且这个问号不能省略。

例如：

```
@data
sunny,85,85,FALSE,no
?,78,90,?,yes
```

字符串型属性和标称型属性的值是区分大小写的。若值中含有空格，必须被引号括起来。

