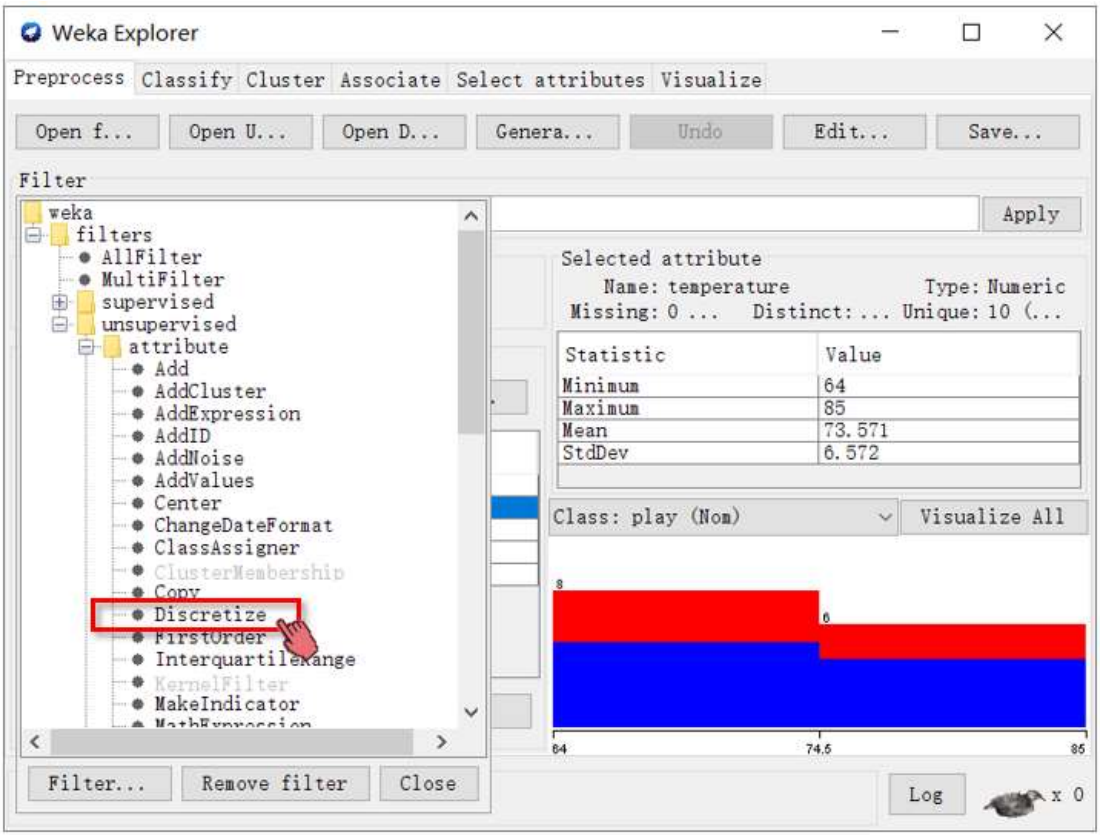
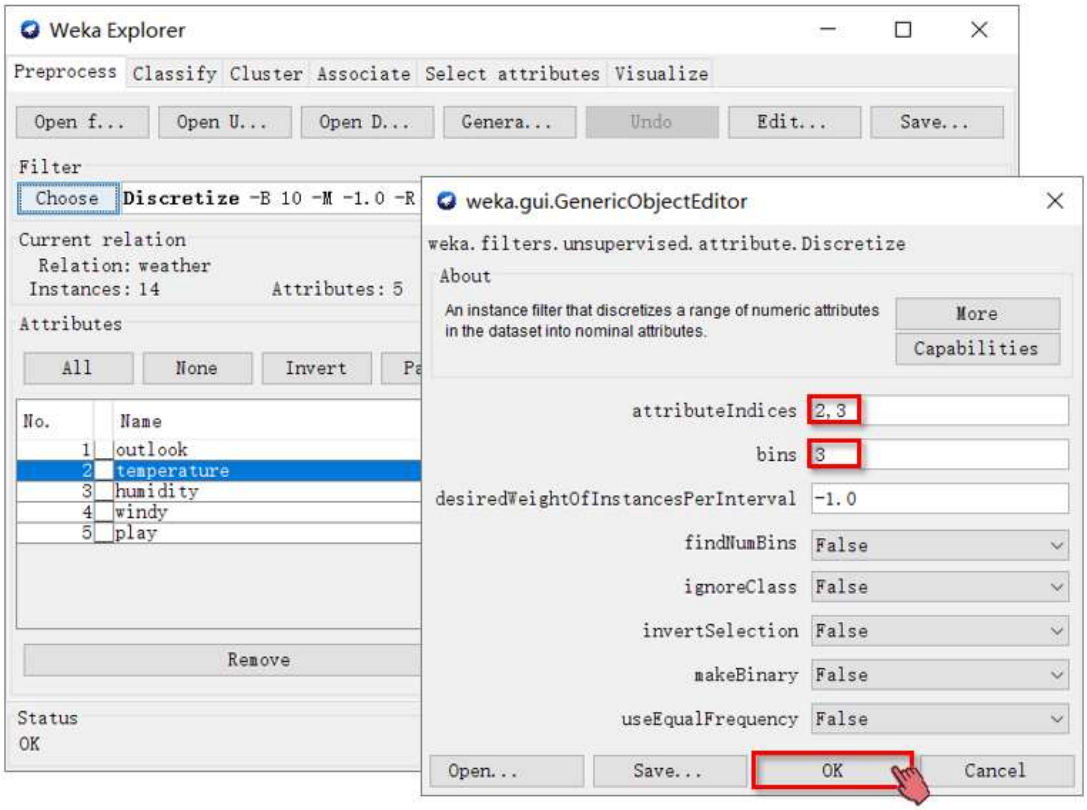
WEKA：数据预处理

在进行挖掘任务之前，通常还需要对数据进行预处理，比如更换属性类型或者增加删减属性等。这些预处理工作主要是通过 Explorer 界面下的 Filter 下拉菜单里的各种函数来实现的。比如在实际应用中，我们经常会需要把数值型的属性改成标称型的属性。这时可以用 Filter 下的 unsupervised 下的 attribute 下的 discretize 离散化函数来实现。

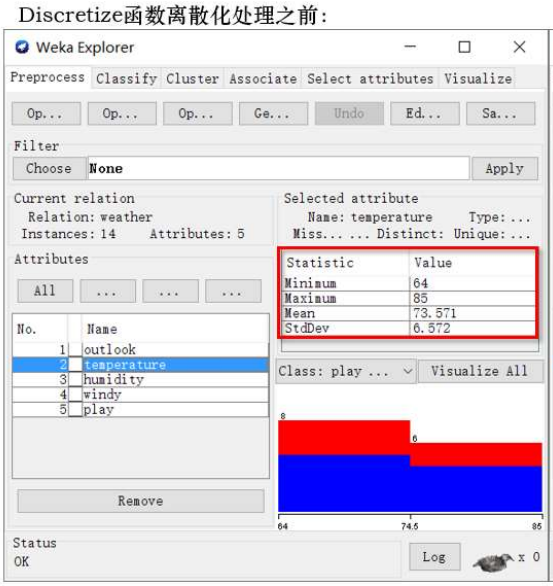


选中 discretize 函数后，点击选中后出现的参数框。弹出参数设置窗口。从 AttributeIndices（属性代号参数）指定要更改哪个属性的属性类型。比如我们更改第二个属性 temperature（温度）和第三个属性 humidity（湿度），这两个数值型的属性，那么这里就写“2，3”。discretize 函数会将所有实例中对应属性下的数值离散化成几个区段，每个区段赋予一个标称，同一区段里的数值都转化成这一区段的标称。所以我们还需要指定一下，要离散化成几个区段。这里我们定为 3 个，那么新属性将具有 3 个标称。其他参数不变，点 ok，窗口关闭，再点 apply。

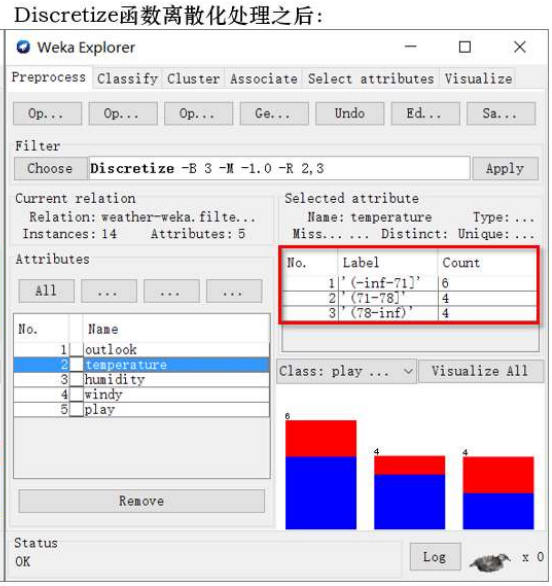


现在看一下 temperature（温度）这个属性，原来是数值型的。离散化函数处理之后，变成了标称型。函数将所有温度数值离散化成了三个区段，`'(-inf-71]'`（温度值小于 71）的都归入了第一区段，拥有第一个标称。标称的具体写法虽然怪异，但是它很清楚的告诉了我们哪些数值归入了第一个标称。`'(71-78]'`（温度值在 71 到 78 之间）的归入第二区段，拥有第二个标称；`'(78-inf)'`（温度值大于 78）的归入第三区段，拥有第三个标称。

Discretize函数离散化处理之前：

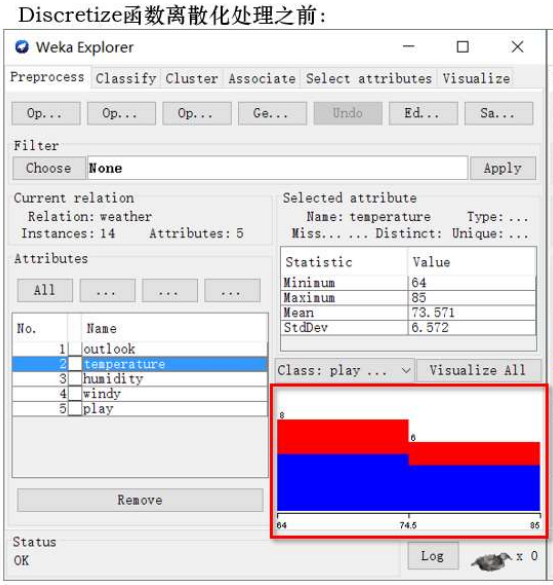


Discretize函数离散化处理之后：

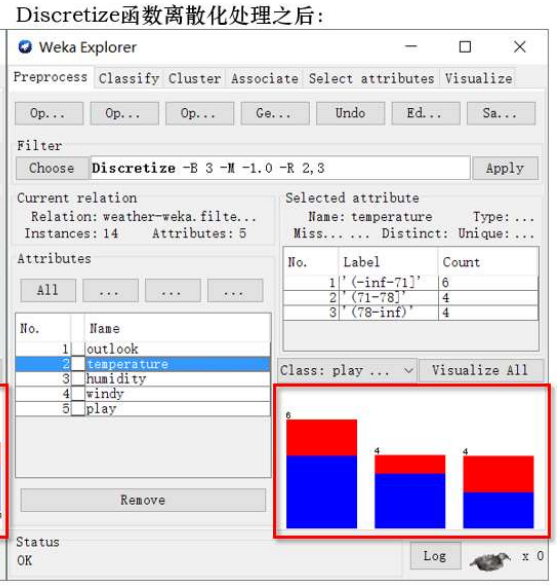


可以看到，现在标称型的温度属性的直方图已经变成三个离散的柱子了，而不再是根据平均值划分统计了。除了 discretize 离散化函数，NumericToNominal 函数也可以将数值型的属性转化成标称型。这两个函数虽然达到的最终目的是一样的，但是具体的转化方法是不一样的。究竟哪里不一样，请大家自己尝试比较一下。

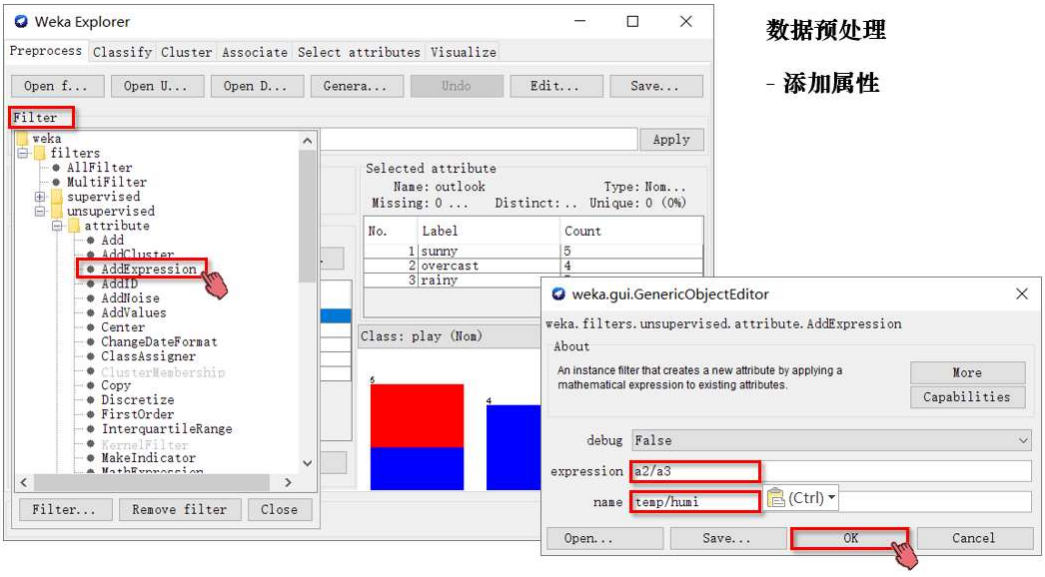
Discretize函数离散化处理之前：



Discretize函数离散化处理之后：



通过 AddExpression 函数可以增加一个属性。比如增加新属性的值等于温度除以湿度。重新打开 `weather_numeric.arff` 文件。此时，温度和湿度的属性都是数值型的。Filter →unsupervised→attribute→AddExpression。从参数设置窗口设置新属性的公式，温度除以湿度，也就是第二个属性 a2 除以第三个属性 a3，即 `a2/a3`。再定义新属性的名字为 `temp/humi`。点 ok，点 apply，新属性就产生了。注意新创建的属性都会添加在属性列表的最后，这就会影响 WEKA 对 class 属性的判断，需要手动将 class 属性重新选为 play。



数据预处理

- 添加属性