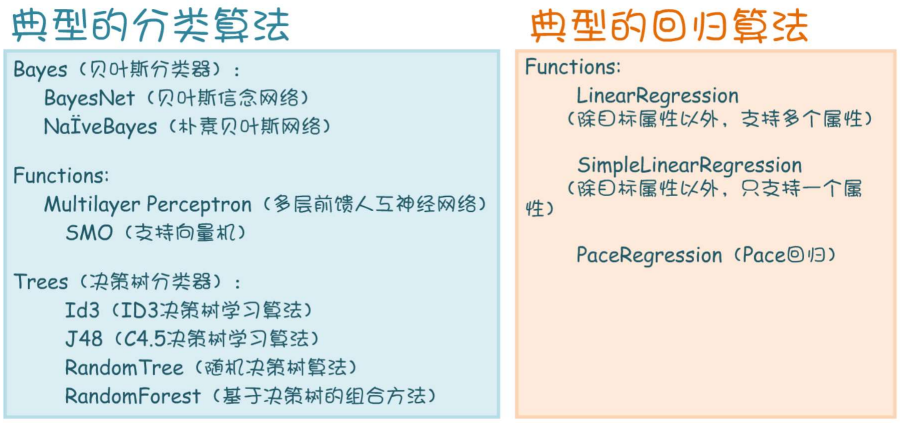
WEKA：执行挖掘任务

WEKA 把分类和回归两种挖掘任务都放在“Classify”选项卡中，是有原因的。因为这两种挖掘任务都有一个目标属性，也就是输出变量，并且都是根据实例的一组特征属性，也就是输入变量，对目标属性进行预测。比如之前讲过的分类例子是根据各种天气特征属性预测是否打球这个目标属性。回归例子里是根据房屋特征属性来预测房屋价格这个目标属性。为了实现这一目的，首先需要有一个训练数据集，这个数据集中每个实例的输入和输出都是已知的。观察训练集中的实例，可以建立起预测模型。有了这个模型，就可以对新的输出未知的数据进行预测了。衡量模型的好坏就在于预测的准确程度如何。目标属性是标称型的，就是分类任务，目标属性是数值型的就是回归任务。



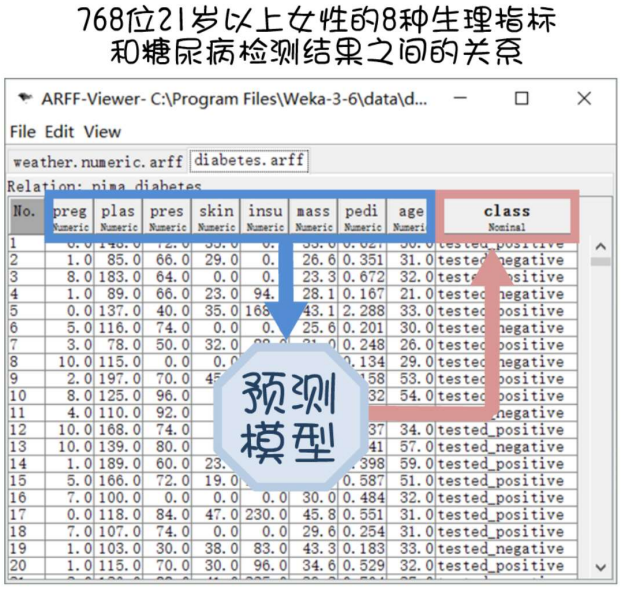
WEKA 自带的典型分类算法有贝叶斯、人工神经网络、支持向量机、决策树等等。典型的回归算法有线性回归和简单线性回归等。



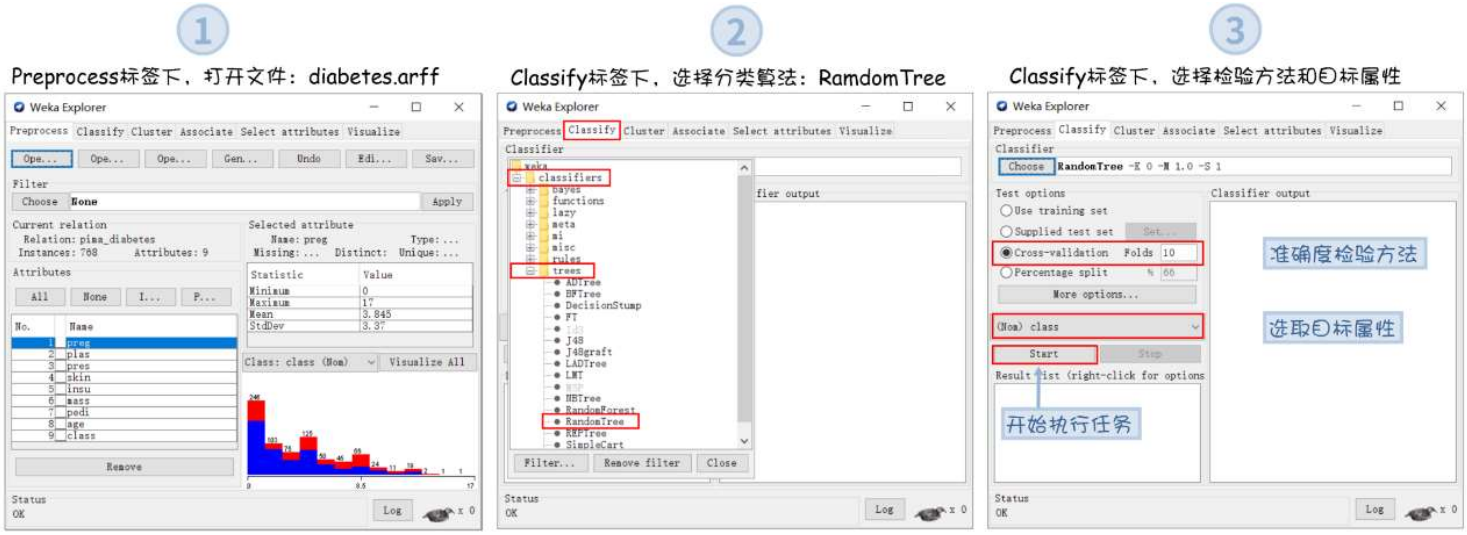
WEKA 的安装目录下有一个有关糖尿病的 ARFF 文件：WEKA 安装目录/data/diabetes.arff。里面记录了 768 位 21 岁以上女性的 8 种生理指标跟糖尿病检测结果是阴性还是阳性之间的关系。我们要用这组数据来创建一个预测模型，通过这个模型只要输入某位未做过糖尿病检测的女士的这 8 种生理指标就可以预测出她是否患有糖尿病。

数据文件：
weka安装目录下的data/diabetes.arff
768个实例，9个属性：

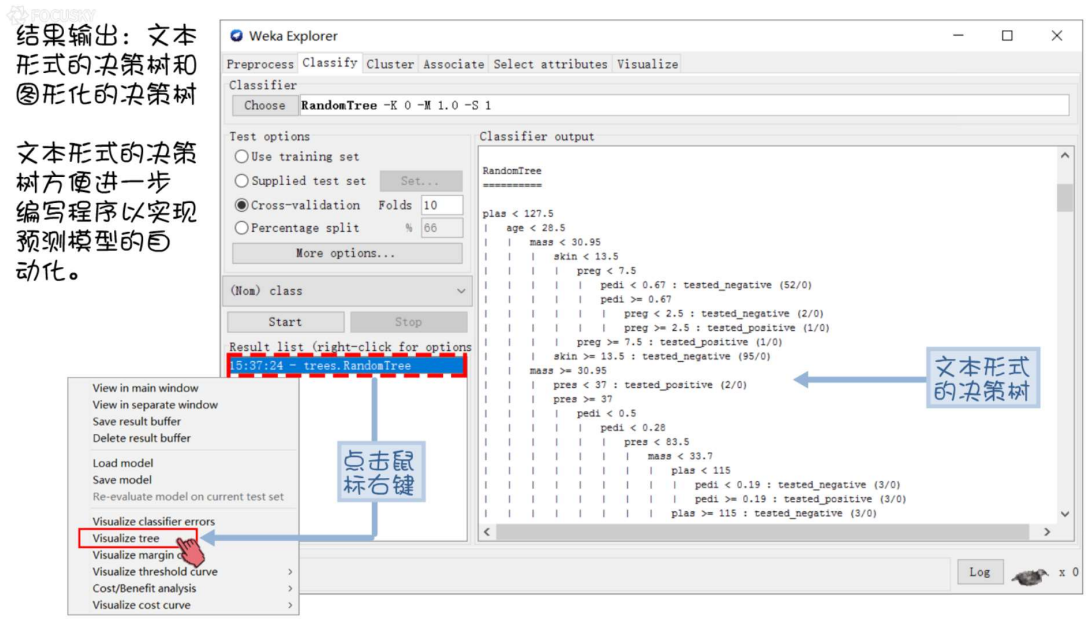
1. preg： 怀孕次数
2. plas： 2小时口服葡萄糖耐受检测中体葡萄糖含量
3. press： 血压 (mm Hg)
4. skin： 三头肌皮褶厚度 (mm)
5. insu： 2小时血清胰岛素 (mu U/ml)
6. mass： 体重除以身高的平方
7. pedi： 糖尿病家系功能
8. age： 年龄
9. class： 目标（阴性或阳性）



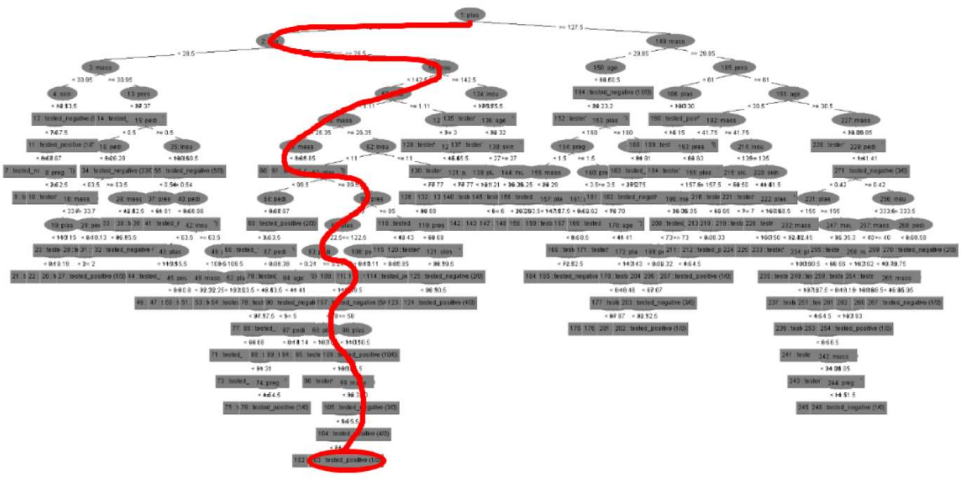
Explorer 界面下，首先从 preprocess 标签下打开，diabetes.arff 文件，导入数据。然后在 classify 标签下选择分类算法。选 classifiers→tree（决策树）→random tree（随机决策树）来创建预测模型。预测模型准确度的检验方法选 10 次交叉检验，再次确认目标属性是否选择正确。最后点 start。任务开始后会看到 WEKA 鸟走了两步又坐下了，说明任务完成。



任务完成后，output 窗口里显示出了一个文本形式的决策树。这样的决策树方便进一步编写程序以实现预测模型的自动化。此外，还有图形样式的决策树。从任务列表里找到刚刚完成的任务，右键点击，选 Visualize Tree。这时一棵图形化的决策树就出现了。因为树太大，窗口又太小，所以全都挤在一起了。为了看清楚，可以放大窗口，再右键点击，选 fit to screen 将树放大。



有了这棵树，我们只需要输入 8 种生理指标，就可以从树根开始一层一层的判断直到末端的叶子。叶子上写的总是目标属性，也就是预测的糖尿病检测结果是阴性还是阳性。



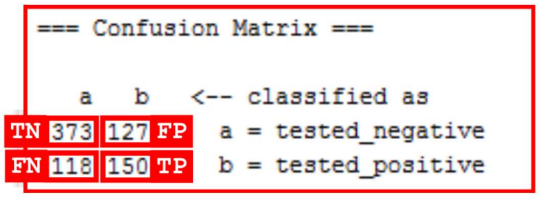
有了预测模型只是第一步，我们还需要知道预测模型的准确度如何，也就是判断模型是否可信。10 次交叉检验的返回结果告诉我们，交叉检验下，68%的实例能够预测出正确结果，32%的预测结果是错误的。除此之外，还提供了其他很多准确度衡量参数。交叉检验后得出

的 Confusion Matirx 是个很有用的矩阵。它提供了 TPFPTNFN 的统计值，用以计算上述的各种准确度衡量参数。



这个矩阵告诉我们，原本 class 属性是 test_negative 的实例被标记为 a，原本 class 属性是 test_positive 的实例被标记为 b。原本 class 属性是 positive 的实例，被正确分类为 positive 的有 150 个。原本 class 属性是 positive 的实例，被错误分类为 negative 的有 118 个。原本 class 属性是 negative 的实例，被正确分类为 negative 的有 373 个。原本 class 属性是 negative 的实例，被错误分类为 positive 的有 127 个。Confusion Matirx 告诉我们的还不只这些。如果把 class 属性为"tested_positive"的结果认定为阳性结果，把"tested_negative"的结果认为是阴性结果，那么：预测结果为阳性，且预测正确的（TP，真阳性），150 个。预测结果为阳性，且预测错误的（FP，假阳性），127 个。预测结果为阴性，且预测正确的（TN，真阴性），373 个。预测结果为阴性，且预测错误的（FN，假阴性），118 个。

原本class属性是positive的实例(b):
被正确分类为positive (b)的有150个
被错误分类为negative (a)的有118个
原本class属性是negative的实例(a):
被正确分类为negative (a)的有373个
被错误分类为positive (b) 的有127个



如果把class属性为"tested_positive"的结果认定为阳性结果，把"tested_negative"的结果认为是阴性结果，那么：

预测结果为阳性（P），且预测正确（T），这就是TP（true positive，真阳性）= 150个
预测结果为阳性（P），且预测错误（F），这就是FP（flase positive，假阳性）= 127个
预测结果为阴性（N），且预测正确（T），这就是TN（true negative，真阴性）= 373个
预测结果为阴性（N），且预测错误（F），这就是FN（flase negative，假阴性）= 118个

由此得出的TP、FP、TN、FN可以带入公式计算各种准确度衡量参数，包括 sensitivity 和 specificity。当把 test_negative 定义为阳性结果，test_positive 定义为阴性结果的时候，会得出另外一套 TP、FP、TN、FN，从而计算出另一套准确度衡量参数。两次统计结果可分别体现出目标属性中每个标称的预测质量。

