系统发生树的构建

构建系统发生树的方法很多。最常用的有基于距离的构建方法，包括非加权分组平均法（Unweighted Pair Group Method with Arithmetic mean，UPGMA），最近邻居法（Neighbor-Joining method，NJ），最小二乘法（Generalized Least Squares，GLS）等。还有最大简约法（Maximum Parsimony，MP），最大似然法（Maximum Likelihood，ML），贝叶斯推断法（Bayesian Inference，BI）等。我们并不打算一一讲解这些方法的具体原理。你只要掌握何时选用何种方法就可以了，算法的事自由软件替你搞定。从计算速度来看，最快的是基于距离的方法，几十条序列几秒钟即可完成。其次是最大简约法。最大似然法就要慢得多。最慢的是贝叶斯法。但是从计算准确度来看，算得最慢的贝叶斯法确是最准确，而算得最快的基于距离法结果确是最粗糙。从实用的角度，建议使用最大似然法。因为这种方法无论从速度还是准确度都比较适中。最近邻居法虽然算得快，但是当序列多，彼此差别小的时候，这种方法不适合。最大简约法，似乎是个掉空里的方法，高不成低不就，所以很少有人使用。贝叶斯法不是所有的建树软件都提供，算法开发上还有待提高，而且计算时间过长。

目前流行的建树软件（表 1），比如 PHILIP 和 MEGA，基本能够包括上述所有算法。如果想要构建 ML 树，也可以尝试专门构建 ML 树的 PHYML。贝叶斯的算法以 MrBayes 为代表，只是计算速度比较慢。如果构建的系统发生树要用于发表生物信息学领域的文章，需要两种以上的构建方法锁定同一个结果才能审稿通过。如果是用于发表以生物实验为主的文章用一种构建方法就可以了。

软件	说明	网址
PHYLIP	免费的、集成的进化分析工具	http://evolution.genetics.washington.edu/phylip.html
MEGA	图形化、集成的进化分析工具	http://www.megasoftware.net/
PAUP	商业软件，集成的进化分析工具	http://paup.csit.fsu.edu/
PHYML	最快的 ML 建树工具	http://www.atgc-montpellier.fr/phyml/
MrBayes	基于贝叶斯方法的建树工具	http://mrbayes.csit.fsu.edu/

表 1. 构建系统发生树的软件

虽然软件可以快速自动地完成系统发生树的构建,但是对于基本算法的了解还是必不可少的。以非加权分组平均法(UPGMA 法)为例,介绍如何通过计算所有序列两两间的距离,再根据距离远近构建系统发生树。序列两两间的距离可以用双序列比对得出的一致度/相似度代表,或用其他简化值代替。

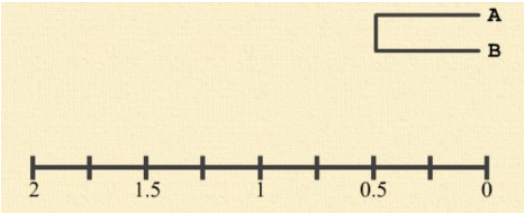
比如,有如下 A、B、C、D 四条序列:

A: TAGG
B: TACG
C: AAGC
D: AGCC

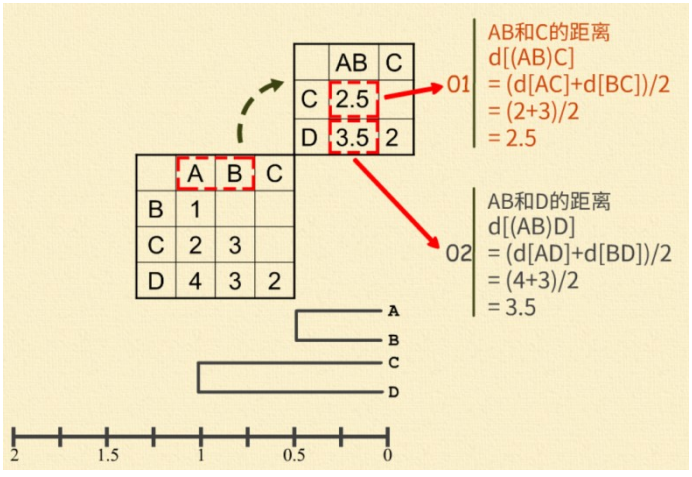
在接下来的例子里,我们用序列间不同的碱基数目作为序列间遗传距离的度量。首先,计算出每两条序列间有几个碱基不同,并以用矩阵的形式记录下这些距离。

	A	B	C
B	1		
C	2	3	
D	4	3	2

找出距离最小的一对序列。A 和 B 之间的距离最小,d[AB]=1。然后将 A 与 B 合并聚集,其分支点为 d[AB]/2=1/2=0.5。即,A、B 之间的距离等于 1,从中间折叠后每边各 0.5。

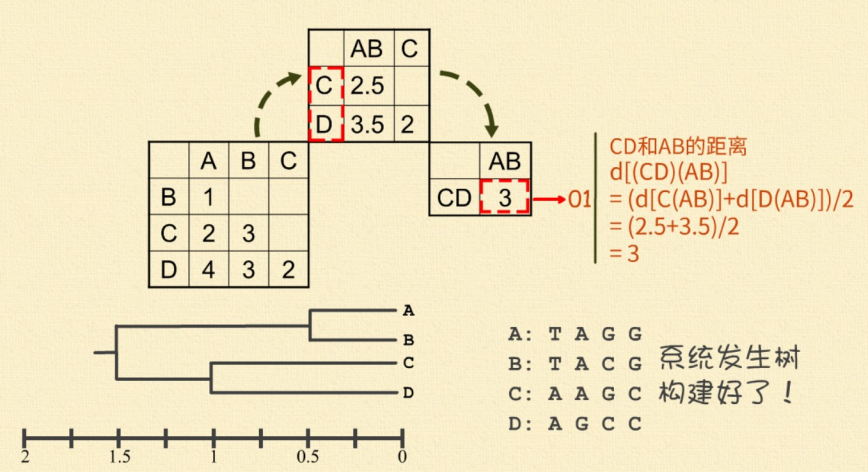


现在,把(AB)看成一个整体,分别计算它们与 C 和 D 的距离。(AB)和 C 的距离等于 A 和 C 的距离加上 B 和 C 的距离除以 2,即,d[(AB)C]=(d[AC]+d[BC])/2=(2+3)/2=2.5。同样,(AB)和 D 的距离等于 A 和 D 的距离加上 B 和 D 的距离除以 2,即,d[(AB)D]=(d[AD]+d[BD])/2=(4+3)/2=3.5。据此,计算出新的距离矩阵,并找出新矩阵中最小的距离。C 和 D 之间的距离最小,d[CD]=2。将 C 和 D 进行合并聚集,其分支点为 d[CD]/2=2/2=1。



接下来,把(CD)看成一个整体,计算它们与(AB)之间的距离。(CD)与(AB)之间的距离等于 C 和(AB)的距离加上 D 和(AB)的距离除以 2,即,d[(CD)(AB)]=

(d[C(AB)]+d[D(AB)])/2=(2.5+3.5)/2=3。最后，将(AB)与(CD)进行合并聚集，归为一类，分支点为d[(CD)(AB)]/2=3/2=1.5。这样，A、B、C、D四条序列的系统发生树就构建好了。树上，枝的长短直接反应了它们与共同祖先的距离。



分子进化的研究对象是核酸和蛋白质序列。如果要研究某个基因的进化，是应该选用它的DNA序列，还是翻译后的蛋白质序列呢？序列的选取要遵循以下原则：1）如果DNA序列两两间的一致度≥70%，选用DNA序列。因为，如果DNA序列都如此相似，它们对应的蛋白质序列会相似到几乎看不出区别。这对于构建系统发生树是不利的。所以这种情况选用DNA序列，而不选蛋白质序列。2）如果DNA序列两两间的一致度<70%，DNA序列和蛋白质序列都可以选用。