

协同过滤



刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

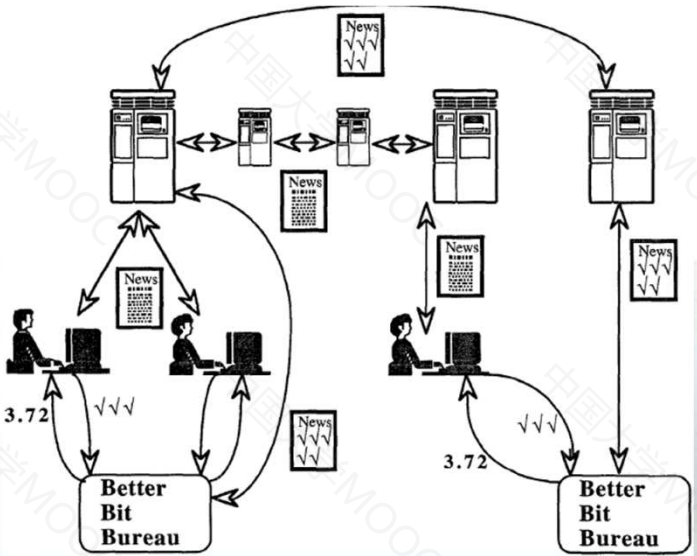


北京大学

经典系统

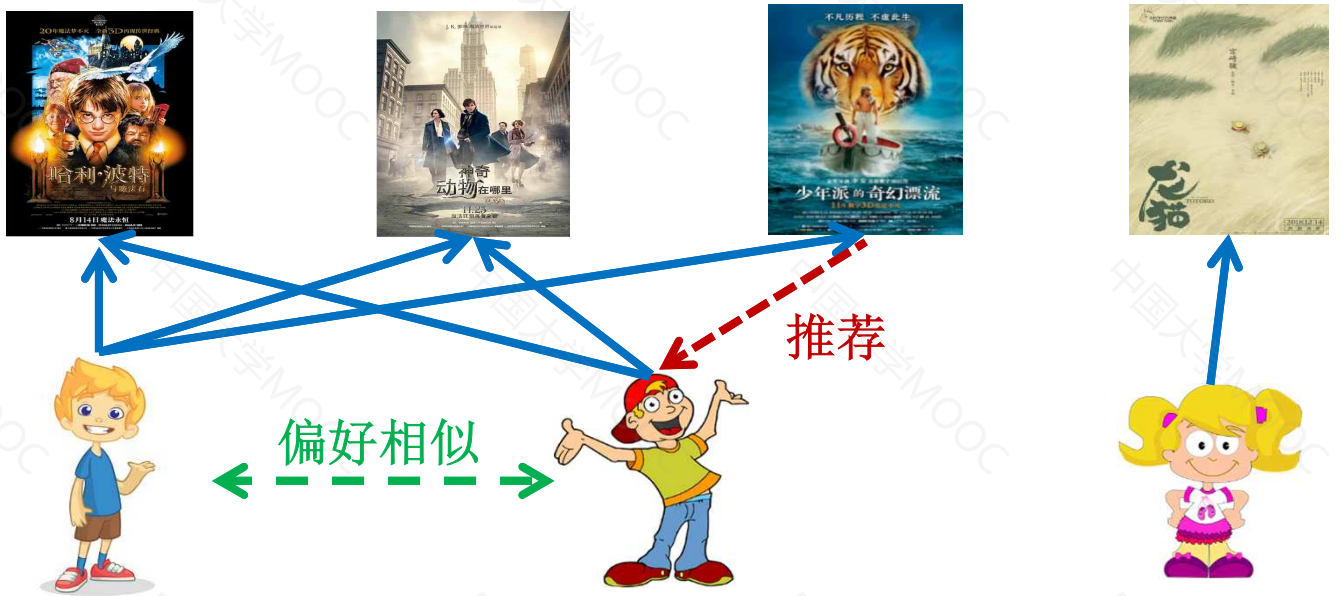
- 1992年：Tapestry系统是公开的最早的应用CF进行信息过滤的系统
  - 施乐公司为解决其Palo Alto研究中心内部的资讯过载问题
  - 利用其他用户的显式反馈(标注是否有用)，帮助用户过滤新闻组邮件
- 1994年：基于协同过滤CF的跨网络新闻推荐系统GroupLens
  - 由MIT和明尼苏达大学共同推出
  - 根据相似用户对新闻的评分（1分~5分）预测目标用户对新闻的评分并做出推荐
- 其他不同领域的协同过滤系统
  - 电影推荐MovieLens、音乐推荐Ringo、书籍（商品）推荐Amazon





基本思想

- 协同过滤（Collaborative Filtering，CF）：
  - 利用集体智慧，借鉴相关人群的观点进行推荐



- 基本假设：
  - 过去兴趣相似的用户在未来的兴趣也会相似
  - 相似的用户会产生相似的（历史）行为数据



北京大学

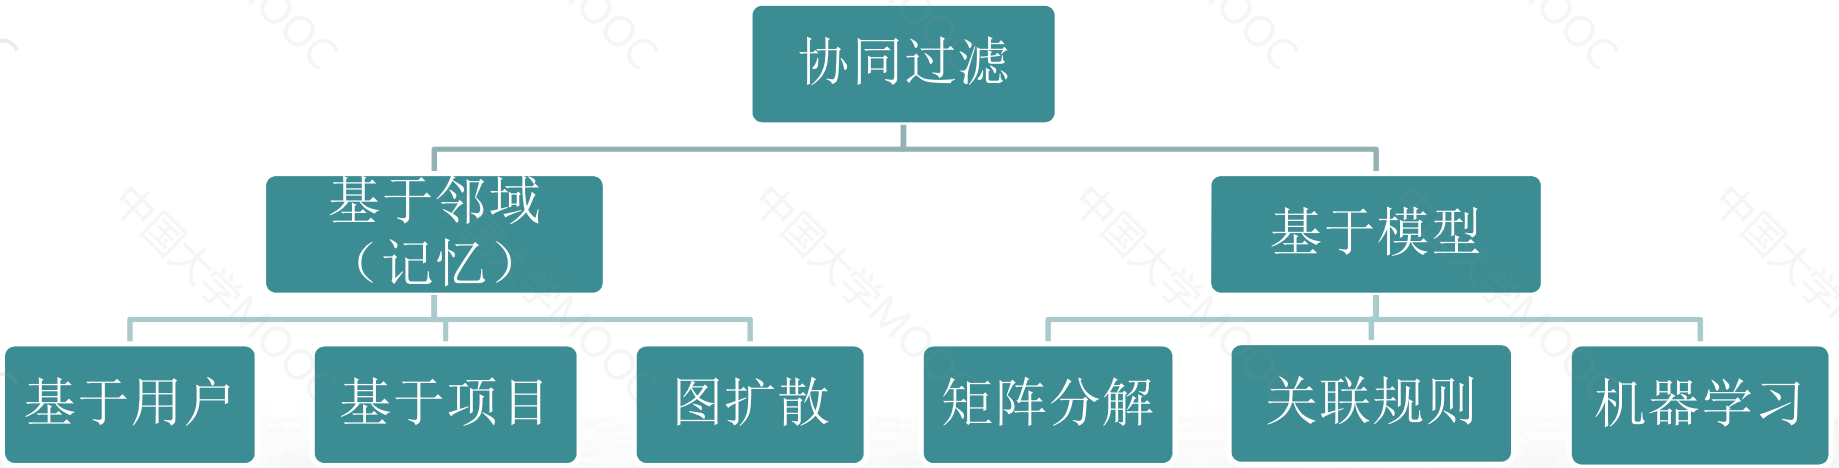
算法分类

- Top-N推荐 vs. 评分预测
  - 输入（输出）：隐式的0-1偏好 vs. 显式的评分





- 基于邻域的方法 vs. 基于模型的方法
  - 利用局部（邻域）信息 vs. 基于全局信息
  - 在内存中存储（记忆）整个数据集 vs. 训练出抽象模型



北京大学

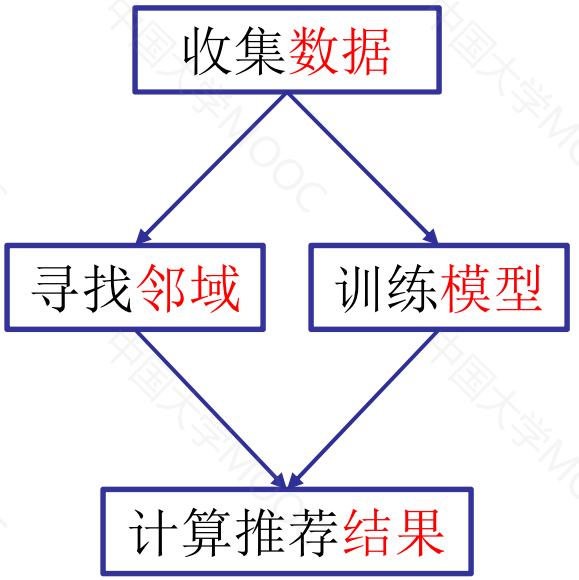
协同过滤的一般步骤

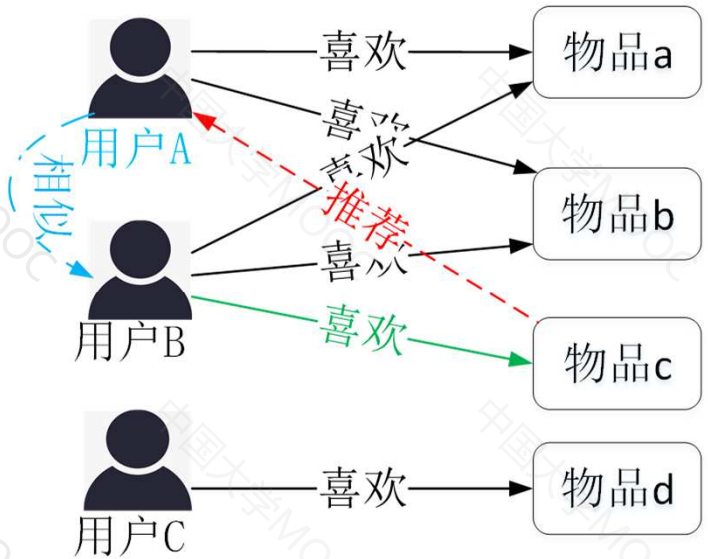
- 收集数据
  - 目标：收集能反映用户偏好的数据

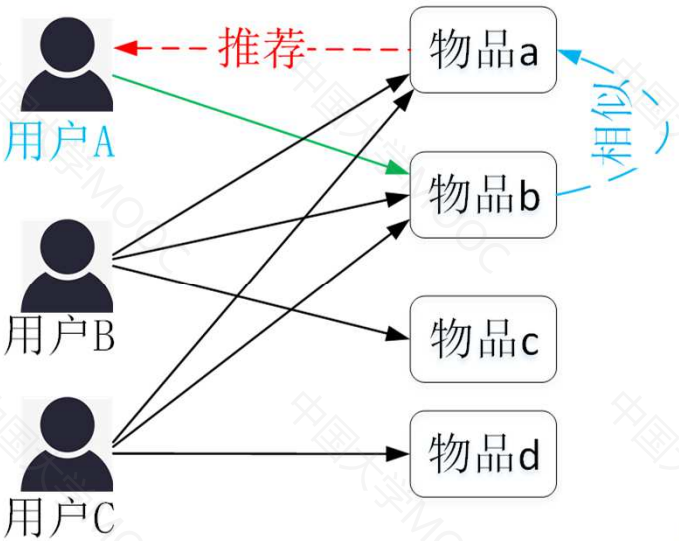




- 寻找邻域：相似的用户（或项目）
- 计算推荐结果：根据邻域信息计算推荐结果









收集用户行为数据

用户行为	类型	特征	作用
评分	显式	整数，取值 [0, n]	精确的用户偏好
点击流	隐式	一组用户点击	一定程度上反映用户的注意力和喜好
页面停留时间	隐式	一组时间信息	一定程度上反映用户的注意力和喜好
保存书签	隐式	布尔值，取值0或 1	较精确的用户偏好
标记标签 (Tag)	隐式	一些词语	可以分析出用户的情感和兴趣
购买	隐式	布尔值，取值0 或 1	明确的用户兴趣

显式反馈：用户主动地向系统表达其偏好，一般需要用户在消费完项目后进行额外反馈

隐式反馈：隐含用户对项目偏好的行为数据，是用户在探索或消费项目过程中正常操作

对比分析： 数量、质量









示例

- 用户购买行为数据：
  - 用户 A 购买过项目{b, d}
  - 用户 B 购买过{a, b, c}
  - 用户 C 购买过项目{a, b, d}
  - 用户 D 购买过项目{a, e}
- 目标：
  - 为用户A推荐项目

用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e

北京大学