

协同过滤：User-CF

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

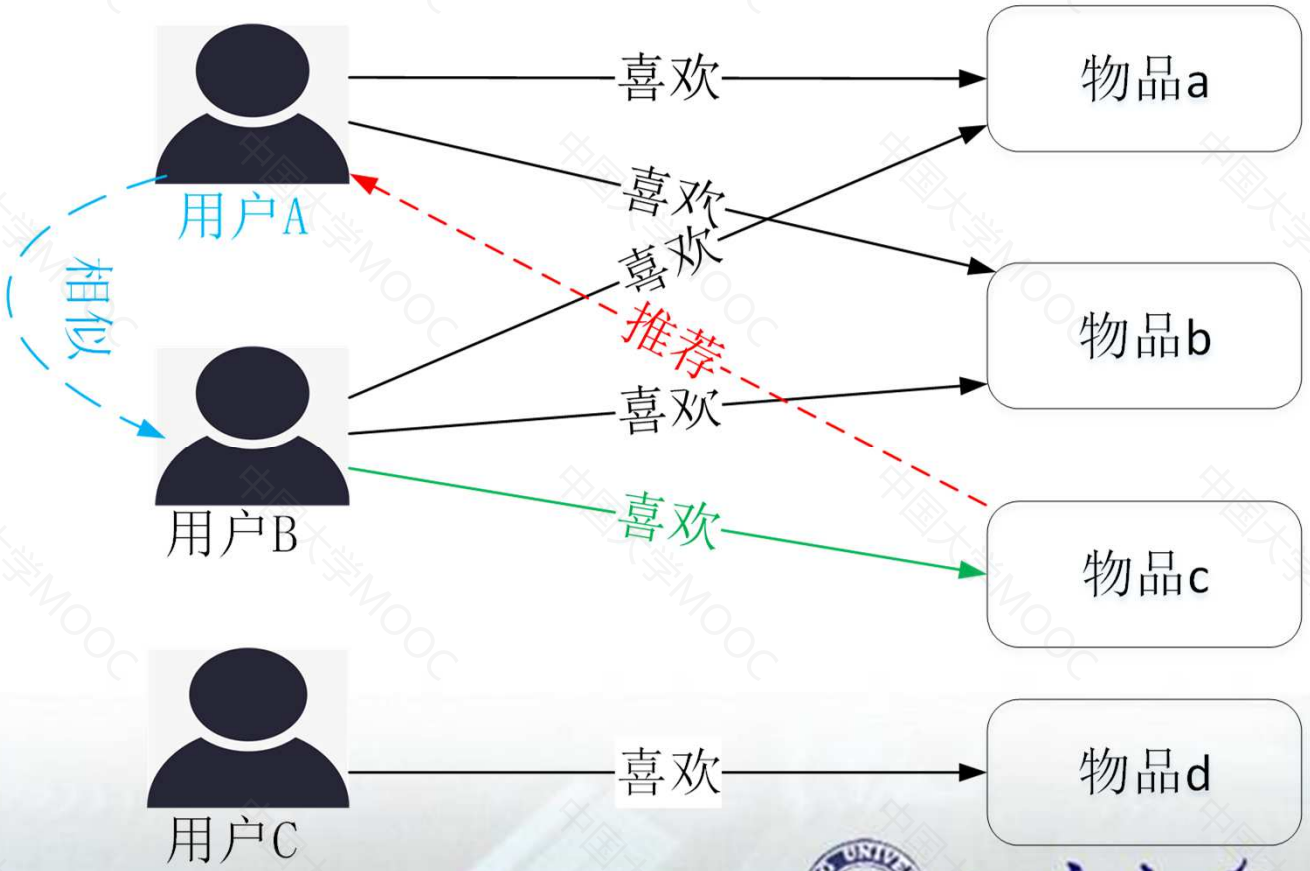
北京大学 软件与微电子学院

中国大学MOOC

基于用户的CF（User-CF）

- 基本思想：
  - 基于用户对项目的历史偏好找到相邻（相似）的用户
  - 将邻居（相似）用户喜欢的项目推荐给当前用户

假设：与我兴趣相似的用户喜欢的项目，我也会喜欢



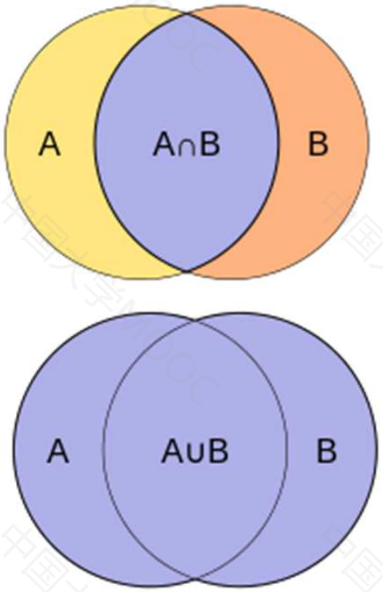
关键：

- 寻找相似用户
- 用户相似度度量

北京大学

用户相似度

- 设 $N(u)$ 为用户 u 有过正回馈的项目集合
- 设 $N(v)$ 为用户 v 有过正回馈的项目集合
- u 和 v 的兴趣相似度



➢ Jaccard公式：$\omega_{uv} = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$

➢ 余弦相似度：$\omega_{uv} = \frac{|N(u) \cap N(v)|}{\sqrt{|N(u)||N(v)|}}$

用户/项目	项目a	项目b	项目c	项目d	项目e
用户A	?	√	?	√	?
用户B	√	√	√		
用户C	√	√		√	
用户D	√				√

北京大学

用户相似度：示例计算

假设：用户A购买过项目{b, d}，用户B购买过{a, b, c}，…

用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e

利用Jaccard相似度计算可得：

用户A和用户B的兴趣相似度为

$$\omega_{AB} = \frac{|\{b,d\} \cap \{a,b,c\}|}{|\{b,d\}| \cup |\{a,b,c\}|} = \frac{1}{4}$$

同理，

$$\omega_{AC} = \frac{2}{3} = \frac{2}{3}$$

$$\omega_{AD} = \frac{0}{2} = 0$$

$$\omega_{uv} = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$$

北京大学

兴趣度预测

- 计算用户 u 对邻域用户购买过项目 i 的感兴趣程度$p(u,i)$
- 输入：
  - $S(u,K)$: 表示和用户u最相似的K个用户（K-近邻）
  - w_{uv}: 表示用户u和用户v的兴趣相似度
  - r_{vi}: 表示观测到的用户v对项目i的兴趣度 (有正反馈为1，否则为0)
- 兴趣度：邻域用户的兴趣度的加权求和

$$p(u,i)=\sum_{v\in S(u,K)}\omega_{uv}*r_{vi}$$

用户/项目	项目a	项目b	项目c	项目d	项目e
用户A	?	√		√	
用户B	√	√	√		
用户C	√	√		√	
用户D	√				√

北京大学

User-CF：计算推荐结果

假设：用户A购买过项目{b, d}，用户B购买过{a, b, c}，…
目标：为用户A推荐项目

用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e

- 寻找邻域：最相似的K个用户$S(u,K)$
  - $S(A,2)$ = {C，B}
- 候选项目集(邻域用户购买过项目): {a, c}
- 计算用户的感兴趣程度：
  - $p(A,a) = \frac{1}{4}+\frac{2}{3} = \frac{11}{12}$
  - $p(A,c) = \frac{1}{4}$
- 推荐排序：
  - $p(A, a) > p(A, c) > p(A, e)$

	项目a	项目b	项目c	项目d	项目e
用户A	?	√	?	√	
用户B	√	√	√		
用户C	√	√		√	
用户D	√				√

$$p(u,i) = \sum_{v \in S(u,K) \cap N(i)} \omega_{uv} * r_{vi}$$

北京大学

基于User-CF的推荐系统

- 离线预处理：
  - 计算用户之间的相似度
  - 并据此确定每个用户的邻域 （K 近邻）
- 在线推荐：针对当前活跃（目标）用户 u，计算推荐列表
  - 确定候选项目集：$C(u) = \{i | i \notin N(u) \ \& \ i \in N(v) \ \& \ v \in S(u,K)\}$
  - 预测兴趣度并生成推荐列表：$p(u,i) = \sum_{v \in S(u,K) \cap N(i)} \omega_{uv} * r_{vi}$

历史行为数据

用户	购买项目
A	b, d
B	a, b, c
C	a, b, d
D	a, e

用户相似度 (Jaccard)

	A	B	C	D
A	1	1/4	2/3	0
B	1/4	1	1/2	1/4
C	2/3	1/2	1	1/4
D	0	1/4	1/4	1

用户邻域(K=2)

用户	邻域
A	B, C
B	A, C
C	A, B
D	B, C

示例

历史行为数据

用户	购买项目
A	b, d
B	a, b, c
C	a, b, d
D	a, e

用户相似度 (Jaccard)

	A	B	C	D
A	1	1/4	2/3	0
B	1/4	1	1/2	1/4
C	2/3	1/2	1	1/4
D	0	1/4	1/4	1

用户邻域(K=2)

用户	邻域
A	B, C
B	A, C
C	A, B
D	B, C

用户	推荐列表
A	a
B	d
C	c
D	b

推荐列表(N=1)

用户	兴趣度
A	a:11/12, c:1/4
B	d:3/4
C	c:1/2
D	b:1/2, c:1/4, d:1/4

用户兴趣度

用户	候选项目
A	a, c
B	d
C	c
D	b, c, d

候选项目集

北京大学

用户相似度改进：IUF

- 下面哪一组用户更相似？
  - 用户A和B都买过《新华字典》
  - 用户C和D都买过《 Recommender Systems Handbook 》
- 逆用户频率(Inverse User Frequency)
  - 基本思想：惩罚热门项目
  - 两个用户对冷门项目有过同样行为更能说明他们兴趣相似
- 计算：
  - 惩罚系数：$f_i = \log(n/n_i)$
  - n 表示总用户数；n_i 表示对项目i有过正反馈的用户数

$$\omega_{uv} = \frac{\sum_{i \in N(u) \cap N(v)} log \frac{n}{n_i}}{|N(u) \cup N(v)|}$$

$$\omega_{uv} = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$$

北京大学

User-CF的缺点

- 难以形成有意义的邻域集合
  - 很多用户两两之间只有很少的共同反馈
  - 而仅有的共同反馈的项目，往往是热门项目（缺乏区分度）
- 随着用户行为数据的增加，用户间相似度可能变化很快
  - 离线 (offline) 算法难以瞬间更新推荐结果

$$\omega_{uv} = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|} \qquad \omega_{uv} = \frac{|N(u) \cap N(v)|}{\sqrt{|N(u)||N(v)|}}$$

北京大学