

协同过滤：Item-CF

刘宏志 博士、副教授

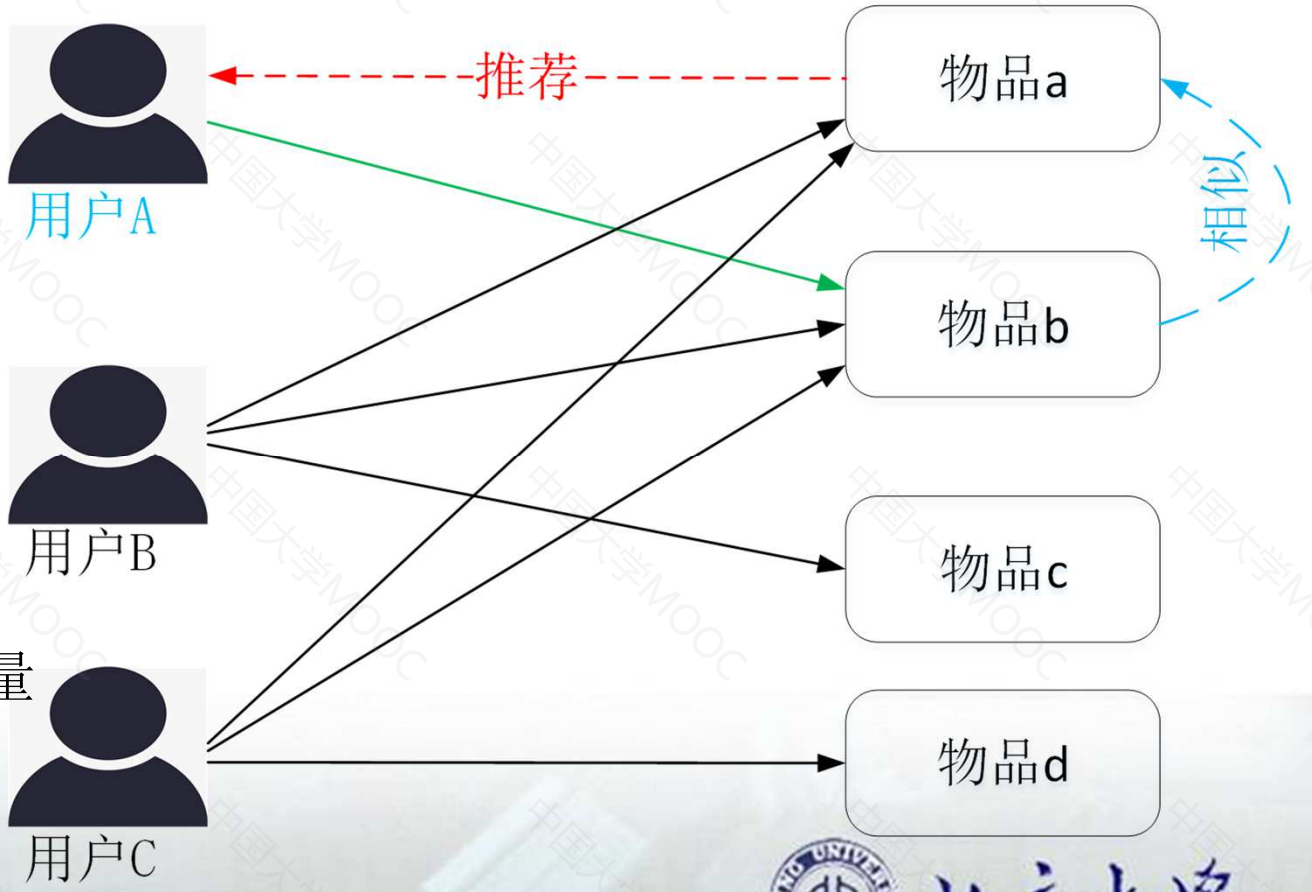
liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

基于项目的CF（Item-CF）

- 基本思想：
  - 基于用户对项目的反馈（偏好）寻找相似（相关）的项目
  - 根据用户的历史反馈（偏好）行为，给他推荐相似的项目



假设：我过去喜欢某类项目，将来还会喜欢类似（相关）项目

关键：

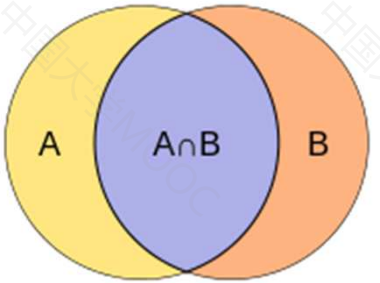
- 寻找相似(相关)项目
- 项目相似(相关)度度量

北京大学

项目相似度

- 项目 i 与项目 j 的Jaccard相似度:

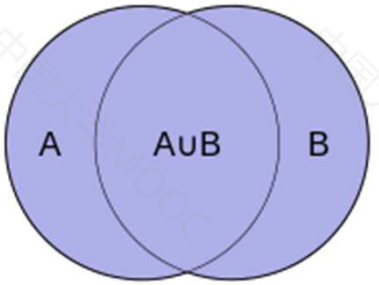
$$\omega_{ij} = \frac{|N(i) \cap N(j)|}{|N(i) \cup N(j)|}$$



  - $N(i)$: 表示点击(或购买)过项目 i 的用户集

- 余弦相似度:

$$\omega_{ij} = \frac{|N(i) \cap N(j)|}{\sqrt{|N(i)||N(j)|}}$$



- 条件概率相似度:

$$\omega_{ij} = P(j|i) = \frac{|N(i) \cap N(j)|}{|N(i)|}$$

  - $N(i) \cap N(j)$: 表示同时点击(或购买)过项目 i 和项目 j 的用户集

北京大学

项目相似度：示例计算

假设：用户A购买过{b, d}；用户B购买过项目{a, b, c}；…

用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e



依此构建用户-项目倒排表：项目a被用户B、C、D购买过，…

项目	用户列表
a	B, C, D
b	A, B, C
c	B
d	A, C
e	D

项目相似度：

Jaccard	a	b	c	d	e
a	1	1/2	1/3	1/4	1/3
b	1/2	1	1/3	2/3	0
c	1/3	1/3	1	0	0
d	1/4	2/3	0	1	0
e	1/3	0	0	0	1

兴趣度预测

- 计算用户 u 对候选项目 i 的感兴趣程度$p(u,i)$
- 输入：
  - $S(i,K)$: 表示和项目 i 最相似的K个项目
  - $N(u)$: 表示用户 u 有过正反馈的项目集合
  - w_{ij} : 表示项目 i 和项目 j 的相似（相关）度
  - r_{uj} : 表示观测到的用户u对项目 j 的兴趣度 (有正反馈为1，否则为0)
- 兴趣度：已反馈的项目的兴趣度的加权求和

$$p(u,i) = \sum_{j \in N(u)} I\big(i \in S(j,K)\big) * \omega_{ij} * r_{uj}$$

用户/项目	项目a	项目b	项目c	项目d	项目e
用户A	?	√		√	
用户B	√	√	√		
用户C	√	√		√	
用户D	√				√

北京大学

基于Item-CF的推荐系统

- 离线预处理：
  - 计算项目之间的相似（相关）度
  - 并据此确定每个项目的邻域（K 近邻）
- 在线推荐：针对当前活跃（目标）用户 u，计算推荐列表
  - 确定候选项目集：$C(u) = \{i | i \notin N(u) \ \& \ i \in S(j,K) \ \& \ j \in N(u)\}$
  - 生成推荐列表：$p(u,i) = \sum_{j \in N(u)} I\big(i \in S(j,K)\big) * \omega_{ij} * r_{uj}$

用户-项目倒排表

项目	用户列表
a	B, C, D
b	A, B, C
c	B
d	A, C
e	D

项目相似度 (Jaccard)

	a	b	c	d	e
a	1	1/2	1/3	1/4	1/3
b	1/2	1	1/3	2/3	0
c	1/3	1/3	1	0	0
d	1/4	2/3	0	1	0
e	1/3	0	0	0	1

项目邻域(K=3)

项目	邻域
a	b, c, e
b	a, c, d
c	a, b
d	a, b
e	a

北京大学

示例

历史行为数据

用户	购买项目
A	b, d
B	a, b, c
C	a, b, d
D	a, e

用户-项目倒排表

项目	用户列表
a	B, C, D
b	A, B, C
c	B
d	A, C
e	D

项目相似度 (Jaccard)

	a	b	c	d	e
a	1	1/2	1/3	1/4	1/3
b	1/2	1	1/3	2/3	0
c	1/3	1/3	1	0	0
d	1/4	2/3	0	1	0
e	1/3	0	0	0	1

项目邻域(K=3)

项目	邻域
a	b, c, e
b	a, c, d
c	a, b
d	a, b
e	a

用户	推荐列表
A	a
B	d
C	c
D	b

推荐列表(N=1)

用户	兴趣度
A	a:3/4, c:1/3
B	d:2/3, e:1/3
C	c:2/3, e:1/3
D	b:1/2, c:1/3

用户兴趣度

用户	候选项目
A	a, c
B	d, e
C	c, e
D	b, c

候选项目集

$$C(u) = \{i | i \notin N(u) \ \& \ i \in S(j,K) \ \& \ j \in N(u)\}$$

$$p(u,i) = \sum_{j \in N(u)} I\left(i \in S(j,K)\right) * \omega_{ij} * r_{uj}$$

北京大学

项目相似度改进

- 惩罚活跃用户
  - 基本思想：越活跃(反馈行为越多)的用户，其对项目相似度的贡献越小
  - 惩罚系数：$f_u = \log(m/m_u)$

    m 表示总项目数；m_u 表示用户u有过正反馈（例如：购买过）的项目数
  - 修正Jaccard相似度：

$$\omega_{ij} = \frac{\sum_{u \in N(i) \cap N(j)} log \frac{m}{m_u}}{|N(u) \cup N(v)|}$$

$$\omega_{ij} = \frac{|N(i) \cap N(j)|}{|N(i) \cup N(j)|}$$

- 惩罚热门项目
  - 修正后的条件概率相似度：

$$\omega_{ij} = P(j|i) = \frac{|N(i) \cap N(j)|}{|N(i)||N(j)|^{\alpha}}$$

$$\omega_{ij} = P(j|i) = \frac{|N(i) \cap N(j)|}{|N(i)|}$$

  - α 的取值范围：[0, 1]

北京大学