

协同过滤：基于邻域的评分预测

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

评分预测

- 输入：用户的显式评分
  - 例如：1星～5星



- 输出：用户 u 对项目 i 的期望评分 $\hat{r}_{ui}$

用户\项目	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

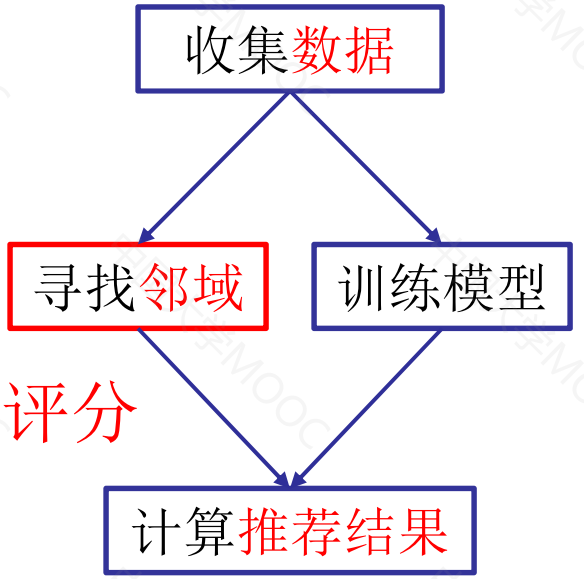
北京大学

协同过滤的一般步骤

- 收集数据
  - 目标：收集能反映用户偏好的数据



- 寻找邻域：相似的用户（或项目）
- 计算推荐结果：根据邻域信息计算预测评分



User-CF:

$$\hat{r}_{ui} = \frac{\sum_{v \in N_i(u)} \omega_{uv} r_{vi}}{\sum_{v \in N_i(u)} |\omega_{uv}|}$$

Item-CF:

$$\hat{r}_{ui} = \frac{\sum_{j \in N_u(i)} \omega_{ij} r_{uj}}{\sum_{j \in N_u(i)} |\omega_{ij}|}$$

北京大学

余弦相似度（用户）

用户 u 和 v 的余弦相似度：

用户u 和 v都有过评分的项目集合

用户u对项目i的评分

$$\omega_{uv} = \frac{\sum_{i \in J_{uv}} r_{ui} r_{vi}}{\sqrt{\sum_{i \in J_u} r_{ui}^2 \sum_{j \in J_v} r_{vj}^2}}$$

用户u 有过评分的项目集合

$$\cos(\vec{x}, \vec{y}) = \frac{\vec{x} \cdot \vec{y}}{||\vec{x}|| \times ||\vec{y}||} = \frac{\sum_{i \in I_{xy}} r_{x,i} r_{y,i}}{\sqrt{\sum_{i \in I_x} r_{x,i}^2} \sqrt{\sum_{i \in I_y} r_{y,i}^2}}$$

用户	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

基于User-CF的评分预测

- 寻找邻域：相似的用户
  - 选定相似度度量标准，计算用户之间的相似度

$$\omega_{uv} = \frac{\sum_{i \in J_{uv}} r_{ui} r_{vi}}{\sqrt{\sum_{i \in J_u} r_{ui}^2 \sum_{j \in J_v} r_{vj}^2}}$$

$$\omega_{AB} = \frac{5*3+3*1+3*1}{\sqrt{(5^2+3^2+3^2)*(3^2+1^2+1^2+2^2)}} \approx 0.827$$

$$\omega_{AC} = \frac{5*3+3*3+3*3}{\sqrt{(5^2+3^2+3^2)*(3^2+3^2+3^2+3^2)}} \approx 0.839$$

  - 选择最相似的一组用户集（*K*-近邻）

$S(A, 1) = \{C\}$; $S(A, 2) = \{B, C\}$

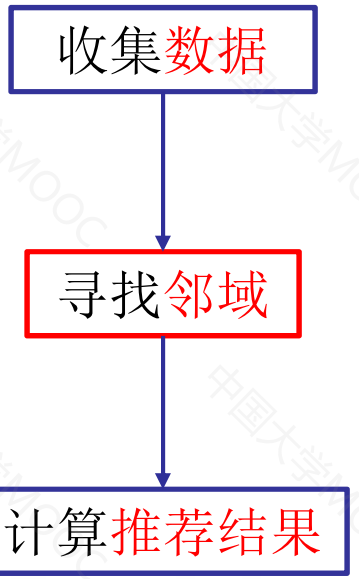
- 计算推荐结果

$$\hat{r}_{ui} = \frac{\sum_{v \in N_i(u)} \omega_{uv} r_{vi}}{\sum_{v \in N_i(u)} |\omega_{uv}|}$$

  - 根据邻域信息计算推荐结果（预测评分）

K=1: $\hat{r}_{Ad} = 3$

K=2: $\hat{r}_{Ad} = \frac{3*0.839+2*0.827}{0.839+0.827} \approx 2.50$



用户	a	b	c	d
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

Pearson相似度（用户）

用户 u 和 v 的Pearson相似度：

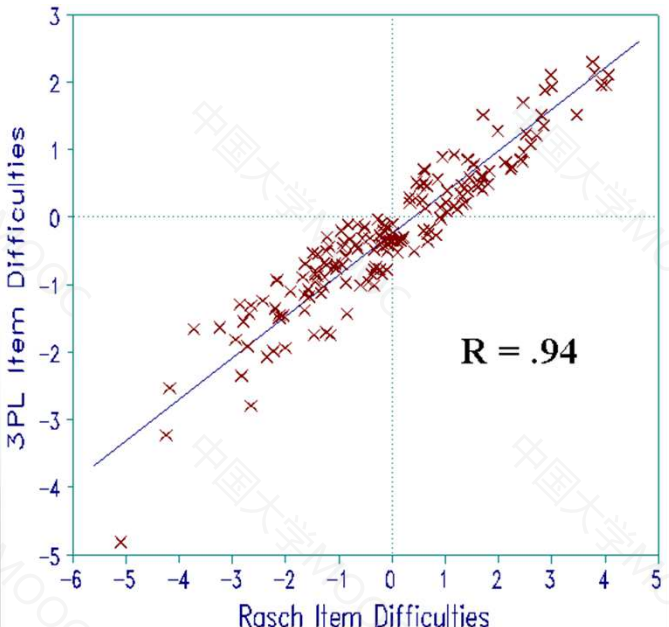
用户u对项目i的评分

用户u的评分平均值

$$\omega_{uv} = \frac{\sum_{i \in J_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in J_{uv}} (r_{ui} - \bar{r}_u)^2 \sum_{i \in J_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

用户u 和 v都有过评分的项目集合

$$\rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\mathrm{Var}(Y)}} = \frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sqrt{\mathrm{Var}(X)\mathrm{Var}(Y)}}$$



Pearson相似度（用户）

- 计算出用户A、B和C的评分平均值分别为：

$$\bar{r}_A = \frac{5+3+3}{3} \approx 3.667;\ \bar{r}_B = \frac{3+1+1+2}{4} = 1.75;\ \bar{r}_C = \frac{3+3+3+3}{4} = 3$$

- 用户A和用户B的皮尔逊相似度为：

$$\omega_{AB} = \frac{1.333 * 1.25 + (-0.667) * (-0.75) + (-0.667) * (-0.75)}{\sqrt{(1.333^2 + (-0.667)^2 + +(-0.667)^2) * (1.25^2 + (-0.75)^2 + +(-0.75)^2)}} \approx 0.996$$

- 用户A和用户C的皮尔逊相似度不存在，即$\omega_{AC} = 0$

$$\omega_{uv} = \frac{\sum_{i \in J_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in J_{uv}} (r_{ui} - \bar{r}_u)^2 \sum_{i \in J_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

用户	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

预测修正

- 基于用户的CF

$$\hat{r}_{ui} = \frac{\sum_{v \in N_i(u)} \omega_{uv} r_{vi}}{\sum_{v \in N_i(u)} |\omega_{uv}|} \qquad \hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_i(u)} \omega_{uv} (r_{vi} - \bar{r}_v)}{\sum_{v \in N_i(u)} |\omega_{uv}|}$$

- 基于项目的CF

$$\hat{r}_{ui} = \frac{\sum_{j \in N_u(i)} \omega_{ij} r_{uj}}{\sum_{j \in N_u(i)} |\omega_{ij}|} \qquad \hat{r}_{ui} = \bar{r}_i + \frac{\sum_{j \in N_u(i)} \omega_{ij} (r_{uj} - \bar{r}_j)}{\sum_{j \in N_u(i)} |\omega_{ij}|}$$

用户\项目	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

北京大学

评分预测：示例

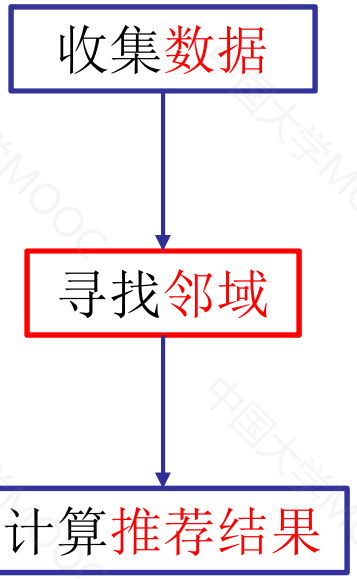
- 计算用户之间的皮尔逊相似度

  $\omega_{AB} \approx 0.996$;　　$\omega_{AC} = 0$

- 寻找目标用户A的邻域：
  - 设用户邻域集合大小为$K = 1$，则$S(A, 1) = \{B\}$

- 计算评分预测值：

$$\hat{r}_{Ad} = \bar{r}_A + \frac{\sum_{v \in N_d(A)} \omega_{Av}(r_{vd} - \bar{r}_v)}{\sum_{v \in N_d(A)} |\omega_{Av}|} = 3.667 + \frac{0.996 * (2 - 1.75)}{0.996} \approx 3.917$$



用户\项目	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

北京大学