

协同过滤：基于二部图的CF

刘宏志 博士、副教授

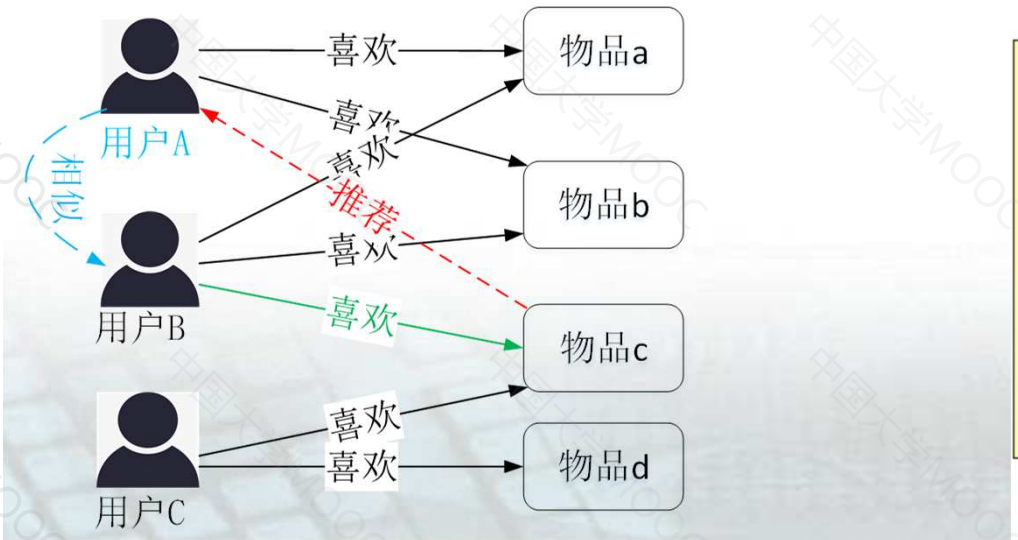
liuhz@ss.pku.edu.cn

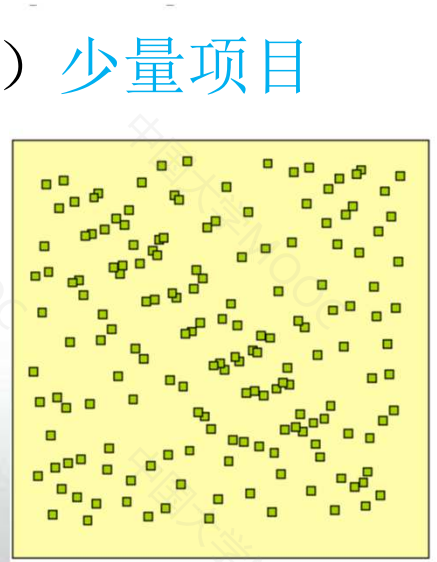
北京大学 软件与微电子学院

中国大学MOOC

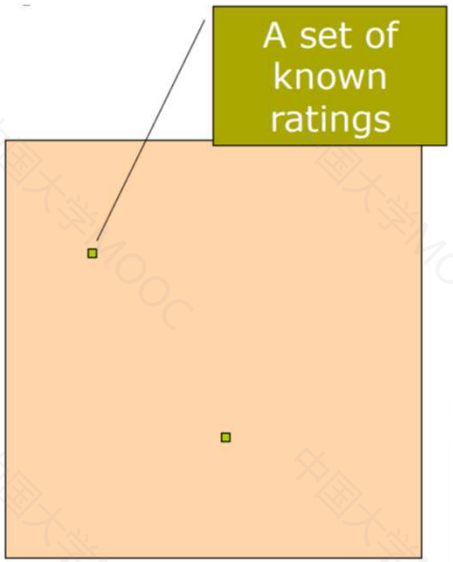
传统邻域方法的缺点

- 范围限制问题：
  - 只考虑和用户有过共同评价（或购买）项目的相邻用户
- 计算空间复杂度较大：
  - 需在内存中保存整个用户-项目反馈（评分）集合（矩阵）
- 数据稀疏/冷启动问题：
  - 用户一般只会评价（或购买）少量项目





94% sparsity

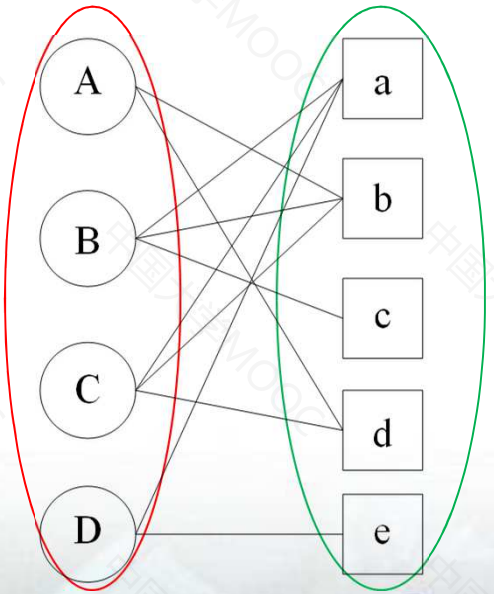


99,9% sparsity

基于二部图的协同过滤

- 隐式反馈行为数据集：（u, i）二元组集合（点击、购买等）
- 用户行为数据可以表示成（二部）图的形式
  - 不相交的两个顶点子集：U 和 I（用户集合和项目集）
  - 每条边(u, i) 关联的两个顶点u 和i 属于两个不同的顶点子集($u \in U, i \in I$)
- 推荐类型：top-N推荐 （推荐用户最感兴趣的N个项目）

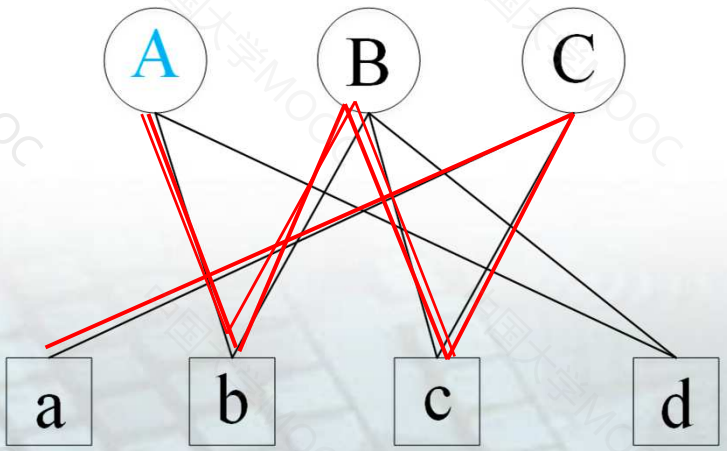
用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e



北京大学

激活扩散

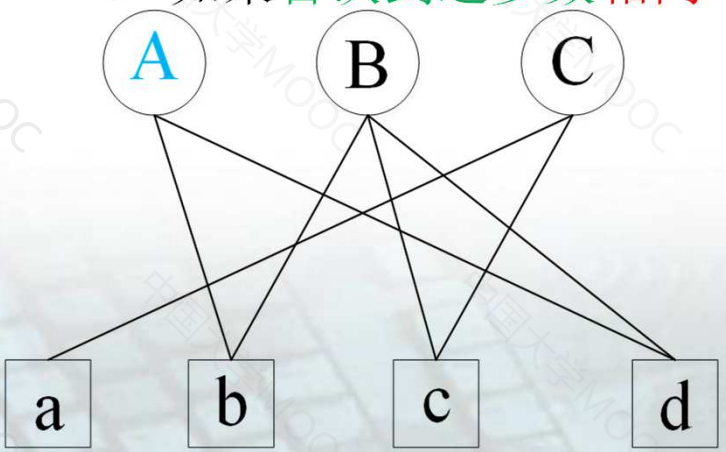
- 假设：
  - 用户反馈过的项目都具有用户偏好的某种属性
  - 用户偏好可以在图中节点间传递
- 基本思想：
  - 根据用户偏好的传递性来挖掘用户潜在偏好信息
- 标准的协同过滤：路径长度=3，U_A-I_b-U_B-I_c
- 扩展路径长度，例如：路径长度=5，U_A-I_b-U_B-I_c-U_C-I_a



用户/项目	a	b	c	d
A	--	1	--	1
B	--	1	1	1
C	1	--	1	--

激活扩散：给定目标用户

- 图扩散：
  - 从目标用户节点出发，沿图中边进行扩散
  - 直至达到给定的最大扩散步长
- 确定候选项目集：
  - 扩散过程中到达过的所有项目，去除目标用户有过正反馈的项目
- 项目排序：
  - 排序依据：首次到达步数和到达次数
  - 如果首次到达步数相同（设为k），则根据k步到达次数做进一步的排序



北京大学

激活扩散：系统角度

- 数据表示：用户的反馈行为数据可用一个矩阵$\boldsymbol{R}$表示

$$r_{ui} = \begin{cases} 1 & \text{用户}u\text{对项目}i\text{有过正反馈} \\ 0 & \text{其他} \end{cases}$$

$$\boldsymbol{R} = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}$$

- 图扩散：用矩阵乘法表示$\boldsymbol{S}^{(2k+1)} = \boldsymbol{R} * (\boldsymbol{R}^T * \boldsymbol{R})^k$

$$\boldsymbol{S}^{(3)} = \boldsymbol{R} * \boldsymbol{R}^T * \boldsymbol{R} = \begin{bmatrix} 3 & 5 & 1 & 4 & 0 \\ 6 & 6 & 3 & 3 & 1 \\ 6 & 7 & 2 & 5 & 1 \\ 4 & 2 & 1 & 1 & 2 \end{bmatrix} \quad \boldsymbol{S}^{(5)} = \boldsymbol{R} * \boldsymbol{R}^T * \boldsymbol{R} * \boldsymbol{R}^T * \boldsymbol{R} = \begin{bmatrix} 24 & 30 & 9 & 21 & 3 \\ 37 & 39 & 15 & 24 & 7 \\ 40 & 45 & 15 & 30 & 7 \\ 20 & 17 & 7 & 10 & 6 \end{bmatrix}$$

- 确定候选项目集：针对每个用户，扩散到达但还未反馈过的项目
- 项目排序：根据首次到达步数和到达次数对候选项目排序，生成推荐列表

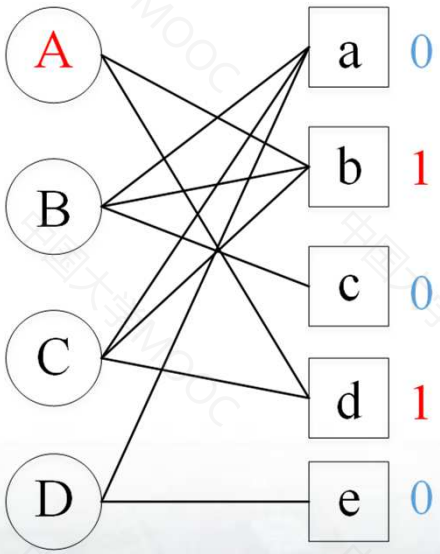
用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e

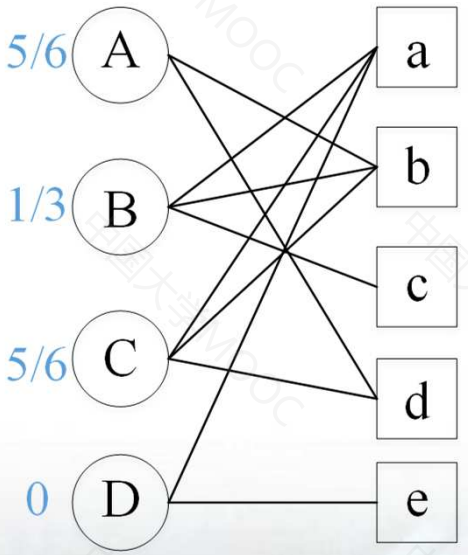
步数\用户	A	B	C	D
3	a, c	d, e	c, e	b, c, d
5	a, c, e	d, e	c, e	b, d, c

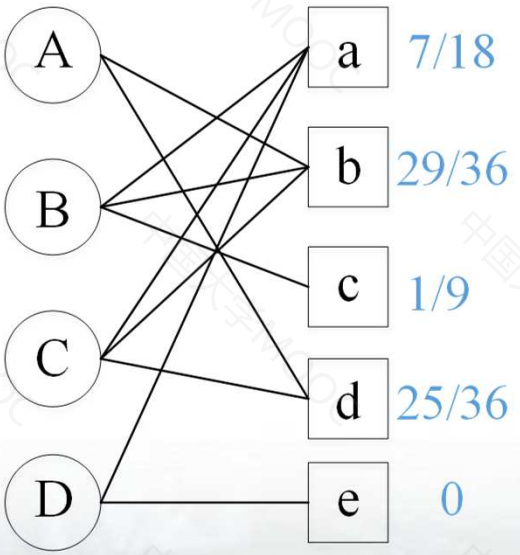
北京大学

物质扩散

- 假设：
  - 扩散过程中每条边的影响不完全相同
  - 可避免活跃用户或热门项目偏置的问题
- 基本思想：
  - 将用户的偏好属性表示为节点所拥有的资源（或能量）
  - 每个节点平均地将自己拥有的物质分享给相邻的节点，满足守恒律



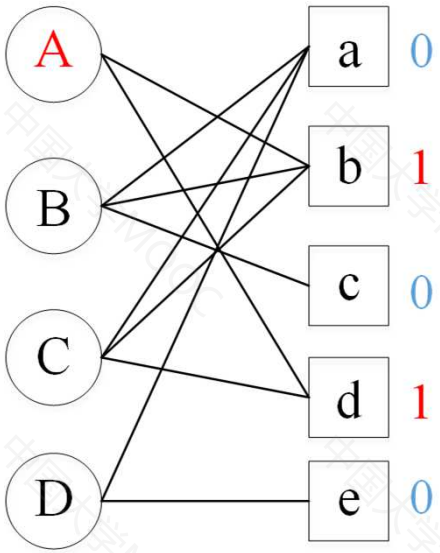


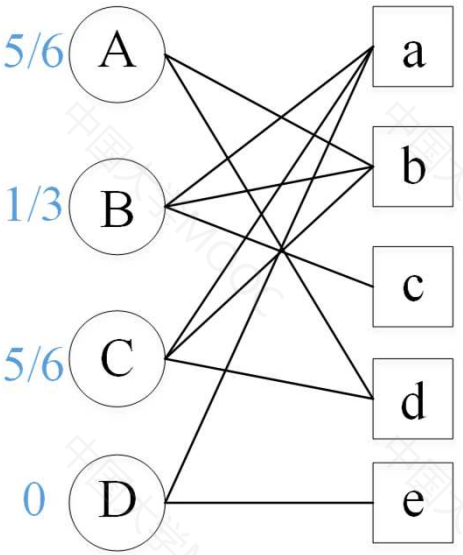


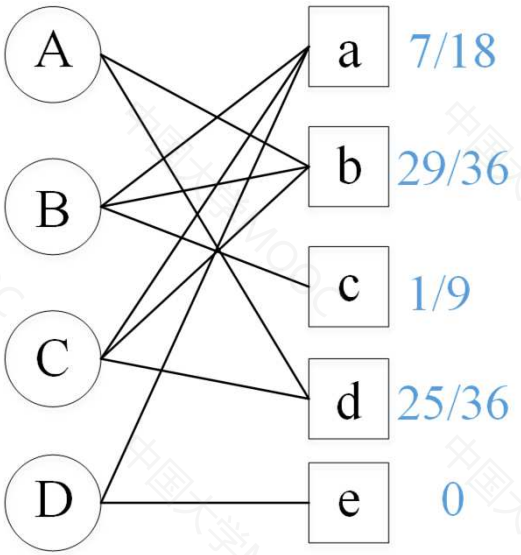
北京大学

物质扩散

- 主要步骤：针对给定目标用户
  - 资源初始化分配：有过正反馈的所有项目节点分配一个资源
  - 资源扩散：根据邻接关系，按照平均分配的方式迭代传递资源
  - 生成推荐列表：依据资源拥有量从大到小对候选项目进行排序







$$b_u = \sum_{j=1}^{n} r_{uj} \frac{s_j}{k(I_j)}$$

$S = (s_1, s_2, s_3, \ldots\ldots, s_n)$表示项目节点的资源分配

$k(I_i)$表示项目节点i的（出）度

b_u表示用户节点u获得的资源

物质扩散：系统角度

- 矩阵表示：用户的反馈行为数据可用矩阵$\boldsymbol{R}$表示

$$r_{ui}=\begin{cases}1 & \text{用户}u\text{对项目}i\text{有过正反馈}\\ 0 & \text{其他}\end{cases}$$

- 图扩散：用矩阵乘法表示$\boldsymbol{S}^{(k)}=\boldsymbol{S}^{(0)}*(\boldsymbol{W})^{k}$
  - 资源分配初始化：$\boldsymbol{S}^{(0)}=\boldsymbol{R}$
  - w_{lj}表示一轮迭代(“项目-用户-项目”)从项目节点l上资源转移到项目j上的比例

$$w_{lj}=\frac{1}{k(I_l)}\sum_{u=1}^{m}\frac{r_{ul}r_{uj}}{k(U_u)}$$

  - “项目-用户”扩散：每个项目节点把自己的资源平均分配给与其相邻的用户

$$b_u=\sum_{j=1}^{n}r_{uj}\frac{s_{uj}}{k(I_j)}$$

  - “用户-项目”扩散：每个用户节点把自己的资源平均分配给与其相邻的项目

$$s'_{uj}=\sum_{u=1}^{m}r_{uj}\frac{b_u}{k(U_u)}=\sum_{j=1}^{n}s_{ul}w_{lj}$$

北京大学

物质扩散：示例

用户	项目列表
A	b, d
B	a, b, c
C	a, b, d
D	a, e

- 初始状态：$\boldsymbol{S}^{(0)} = \boldsymbol{R} = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}$
- 图扩散：用矩阵乘法表示$\boldsymbol{S}^{(k)} = \boldsymbol{S}^{(0)} * (\boldsymbol{W})^k$

$$w_{lj} = \frac{1}{k(I_l)} \sum_{u=1}^{m} \frac{r_{ul} r_{uj}}{k(U_u)}$$

$$\boldsymbol{W} = \begin{bmatrix} 7/18 & 2/9 & 1/9 & 1/9 & 1/6 \\ 2/9 & 7/18 & 1/9 & 5/18 & 0 \\ 1/3 & 1/3 & 1/3 & 0 & 0 \\ 1/6 & 5/12 & 0 & 5/12 & 0 \\ 1/2 & 0 & 0 & 0 & 1/2 \end{bmatrix}$$

- 扩散结果：

$$\boldsymbol{S}^{(1)} = \begin{bmatrix} 0.39 & 0.81 & 0.11 & 0.69 & 0 \\ 0.94 & 0.94 & 0.56 & 0.39 & 0.17 \\ 0.8 & 1.03 & 0.22 & 0.81 & 0.17 \\ 0.89 & 0.22 & 0.11 & 0.11 & 0.17 \end{bmatrix} \quad \boldsymbol{S}^{(2)} = \begin{bmatrix} 0.48 & 0.73 & 0.17 & 0.56 & 0.06 \\ 0.91 & 0.92 & 0.40 & 0.53 & 0.24 \\ 0.82 & 0.98 & 0.27 & 0.71 & 0.21 \\ 0.78 & 0.37 & 0.16 & 0.21 & 0.48 \end{bmatrix}$$

- 推荐项目排序：

$$\boldsymbol{S}^{*} = \begin{bmatrix} 0.58 & 0.62 & 0.20 & 0.42 & 0.18 \\ 0.90 & 0.90 & 0.30 & 0.60 & 0.30 \\ 0.89 & 0.91 & 0.30 & 0.61 & 0.29 \\ 0.63 & 0.57 & 0.20 & 0.37 & 0.24 \end{bmatrix}$$

迭代\用户	A	B	C	D
1	a, c	d, e	c, e	b, c, d
2	a, c, e	d, e	c, e	b, d, c
收敛	a, c, e	d, e	c, e	b, d, c

图扩散

- 物质或能量的扩散：满足守恒律，常称作为物质扩散（Mass Diffusion）
  - 物质（能量）分享：每个节点平均地将自己拥有的物质分享给相邻的节点
- 热的扩散：设有恒温热源驱动，不满足守恒律，也称热传导(Heat Spreading)
  - 平均影响：每个节点的热量（温度）是其所有相邻节点热量（温度）的平均值
- 带重启的随机游走：
  - 每次迭代以一定的概率α向前随机游走（扩散$\boldsymbol{W}$），以概率(1- α)回到初始状态

$$\boldsymbol{S}^{(k+1)} = (1-\alpha)\boldsymbol{S}^{(0)} + \alpha\boldsymbol{S}^{(k)}\boldsymbol{W}$$

