基于模型的协同过滤



刘宏志 博士、副教授

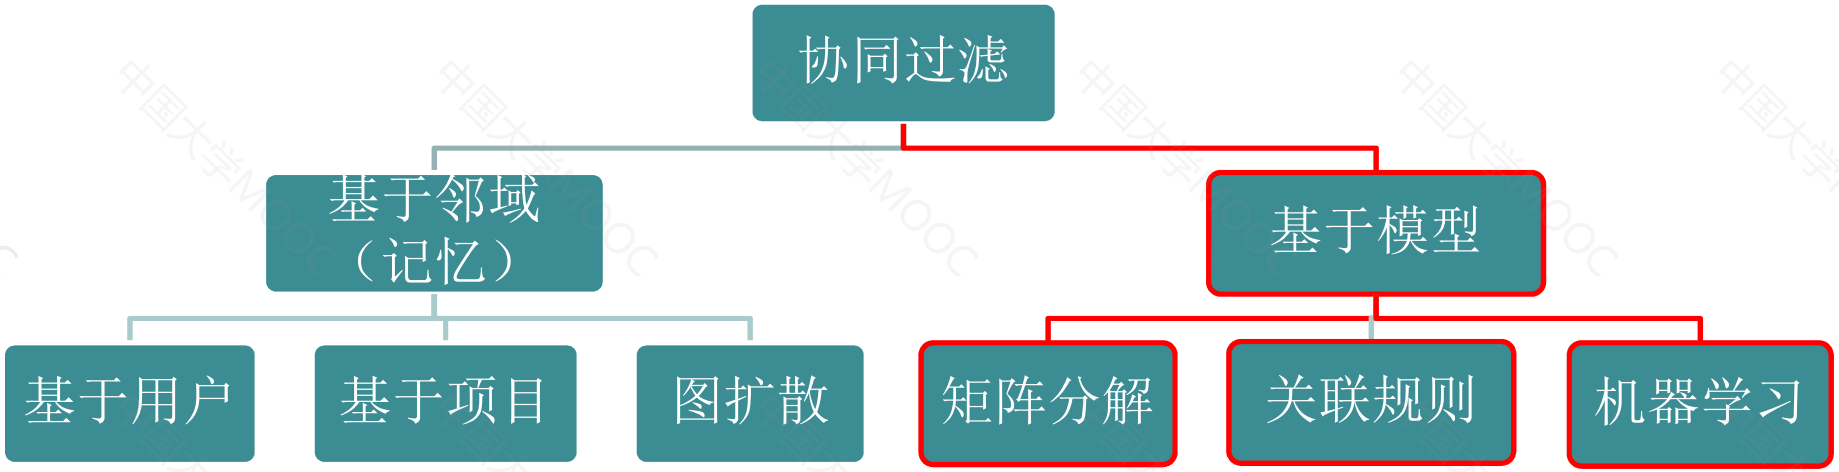
liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

协同过滤算法分类

- 基于邻域的方法 vs. 基于模型的方法
  - 利用局部（邻域）信息 vs. 基于全局信息
  - 在内存中存储（记忆）整个数据集 vs. 训练出抽象模型



基本思想：利用集体智慧，借鉴相关人群的观点进行推荐

北京大学



基于关联规则的协同过滤



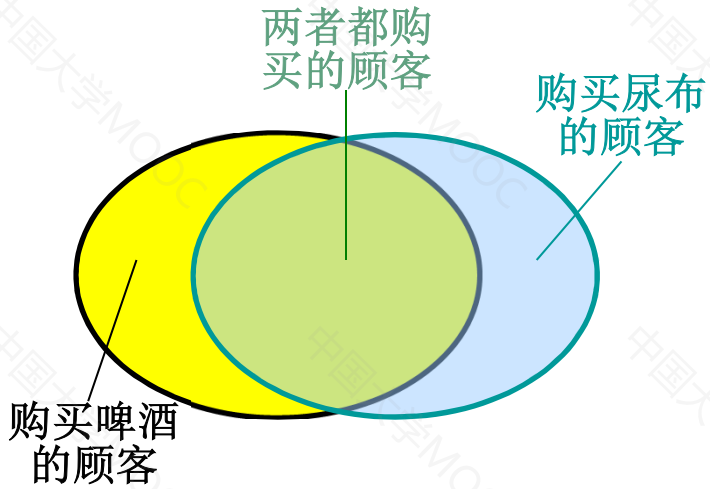


关联规则

- 关联：
  - 自然界中两个事件同时或先后发生的一种联系
  - 可分为：简单关联、时序关联、因果关联

- 关联规则
  - 描述在交易中项目之间同时出现的规律的知识模式
  - 通过量化的数字描述项目A 的出现对项目B 的出现有多大的影响
  - 形如 $A \Rightarrow B$的蕴含式, A 和B 为不相交的项集，例: {尿布} $\Rightarrow$ {啤酒}





基本概念

- 全项集 $I = \{i_1, i_2, ..., i_m\}$
- 事务 $T \subseteq I$
- 关联规则 $A \Rightarrow B$

  $A \subset I, B \subset I, A \cap B = \varnothing$
- 事务数据集 (如右图)

TID	Items
1	i_1, i_2, i_3
2	i_1, i_3
3	i_1, i_4
4	i_2, i_5, i_6

- 事务标识 TID： 每一个事务关联着一个标识

北京大学

关联规则度量

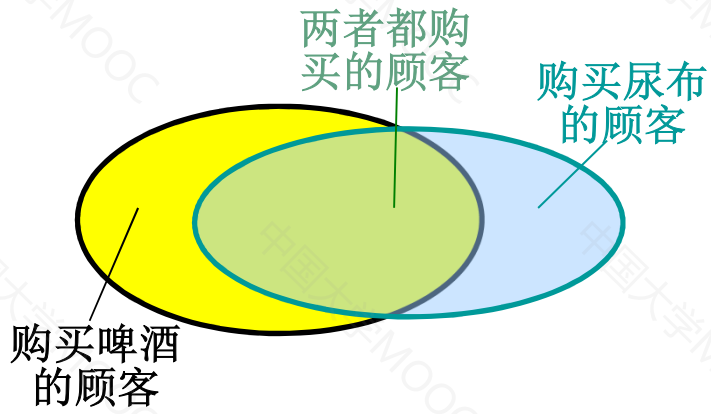
规则：$A \Rightarrow B$

名称	描述	公式
置信度	A出现的前提下，B出现的概率	P(B|A)
支持度	A、B同时出现的概率	$P(A \cup B)$
期望可信度	B出现的概率	P(B)
改善度	置信度对期望可信度的比值	P(B|A)/P(B)

{尿布} ⇒ {啤酒} ？

{牛奶} ⇒ {面包} ？





关联规则度量

- 置信度：confidence$(A \Rightarrow B)$
  - 交易数据集D中同时包含项集A和B的事务数与包含项集A的事务数的比值

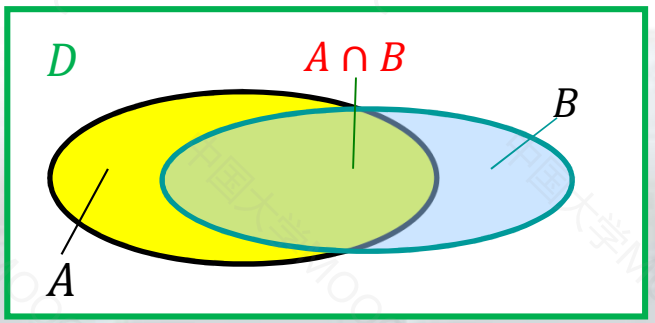
$$\text{confidence}(A => B) = \text{P}(B|A) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|\{T \in D | A \subseteq T\}|}$$

  - 置信度是对关联规则准确度的衡量，度量关联规则的强度

- 支持度：support$(A \Rightarrow B)$
  - 交易数据集D中同时包含项集A和 B 的事务数与总的事务数的比值

$$\text{support}(A => B) = \text{P}(A \cup B) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|D|}$$

  - 支持度是对关联规则重要性的衡量，反映关联是否是普遍存在的规律



关联规则度量：示例

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

规则: $\{\text{Milk}, \text{Diaper}\} \Rightarrow \text{Beer}$

$$s = \frac{\sigma(\text{Milk}, \text{Diaper}, \text{Beer})}{|\text{D}|} = \frac{2}{5} = 0.4$$

$$c = \frac{\sigma(\text{Milk}, \text{Diaper}, \text{Beer})}{\sigma(\text{Milk}, \text{Diaper})} = \frac{2}{3} = 0.67$$

规则: $\{\text{Diaper}\} \Rightarrow \text{Beer}$ ？

$$\text{support}(A => B) = \text{P}(A \cup B) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|D|}$$

$$\text{confidence}(A => B) = \text{P}(B|A) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|\{T \in D | A \subseteq T\}|}$$

北京大学

关联规则挖掘

- 目标：
  - 给定一个交易数据集D
  - 产生支持度和置信度分别大于给定阈值的关联规则
- 两个参数：
  - 最小支持度阈值：*min_support*；最小置信度度阈值: *min_conf*
- 两个基本步骤
  - 找出频繁项集：　　核心：$\text{support}(A => B) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|D|}$
    - 支持度(S(*I*))大于最小支持度阈值的所有项集
  - 找出强关联规则
    - 由频繁项集生成关联规则
    - 保留置信度大于最小置信度阈值的关联规则

$$\text{confidence}(A => B) = \text{P}(B|A) = \frac{|\{T \in D | A \cup B \subseteq T\}|}{|\{T \in D | A \subseteq T\}|}$$

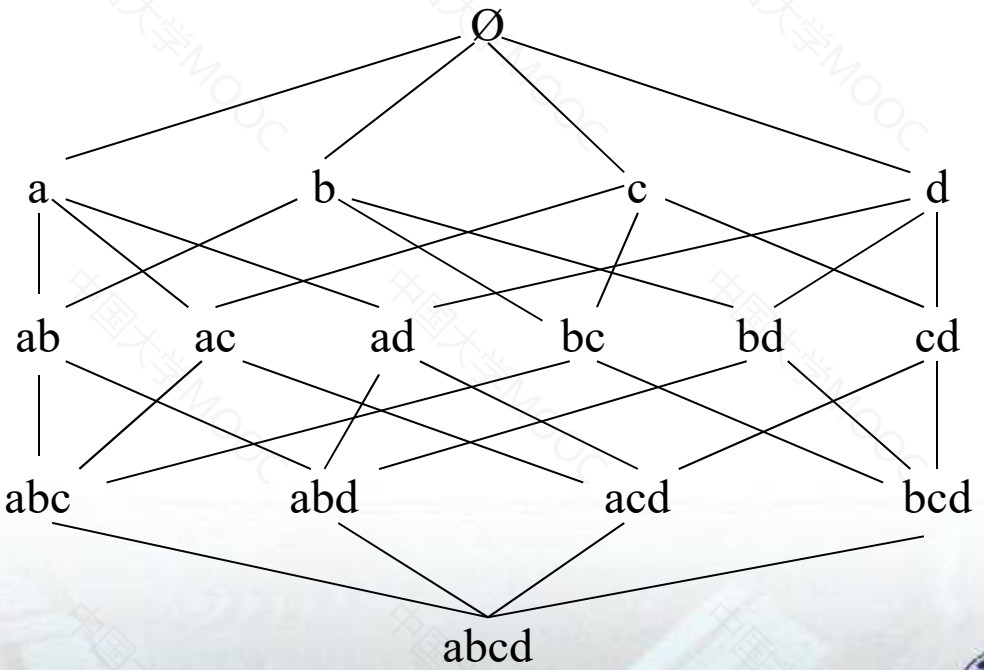
北京大学

生成频繁项集

- Naïve algorithm： Brute-force approach

  计算每个可能项集的支持度: O($n \cdot 2^m$)

  1. 把格结构中每个项集作为候选项集 : O(2^m)， m表示总项数
  2. 针对每个候选项集，和每个事务比较以确定支持度计数: O(n)，n表示总事务数

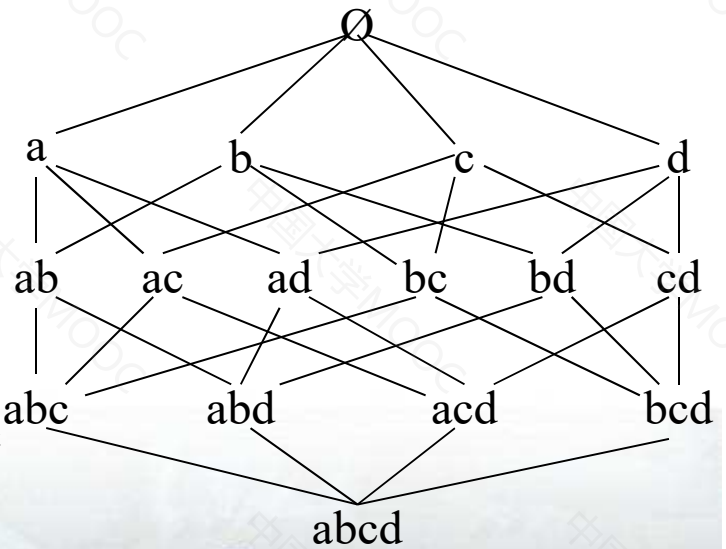


{a，b，c，d}项目集的格结构

北京大学

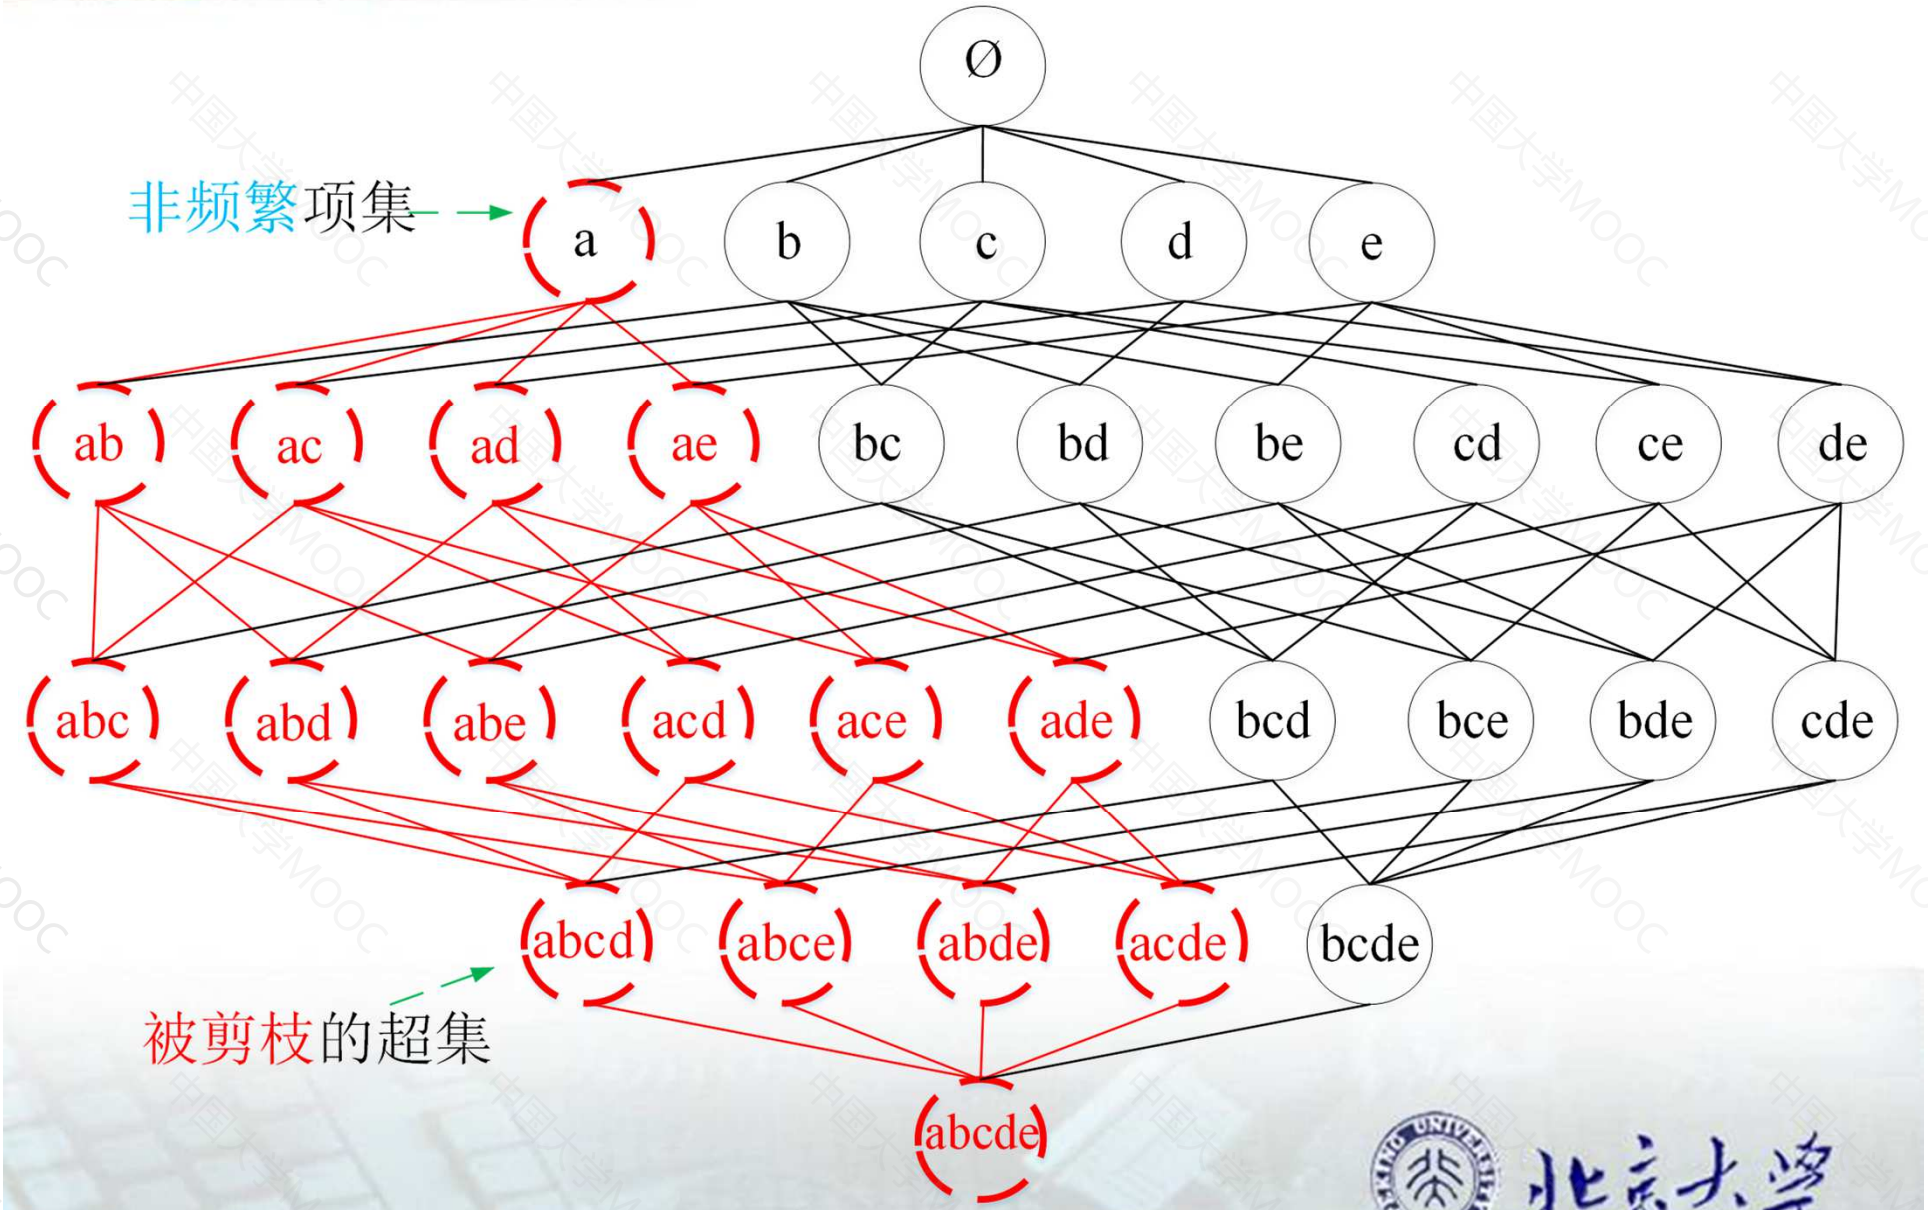
Apriori算法

- 基本思想：
  - 利用先验 (Apriori) 原理减少候选项集的数量
  - 迭代搜索：由频繁 (k-1)-项集构建候选 k-项集
- 先验原理（Apriori Principle）
  - 若A是一个频繁项集, 则A的每一个子集都是一个频繁项集
  - 若A是非频繁项集, 则A的所有超集都是非频繁项集
- 方法： 逐层（level-wise ）搜索
  - 初始化：找到所有的频繁1-项集
  - 迭代：
    - 扩展频繁(k-1)-项集得到候选 k-项集
    - 剪枝：剪除不满足最小支持度的候选项集



北京大学

基于支持度的剪枝：示例



北京大学

Apriori 算法：示例

事务数据集

TID	项目
1	b, d
2	a, b, c
3	a, b, d
4	a, e

计算支持度 →

C_1

项集	支持度
{a}	3
{b}	3
{c}	1
{d}	2
{e}	1

剪枝 →

L_1

项集	支持度
{a}	3
{b}	3
{d}	2

C_2

项集
{a, b}
{a, d}
{b, d}

← 计算支持度

C_2

项集	支持度
{a, b}	2
{a, d}	1
{b, d}	2

← 剪枝

L_2

项集	支持度
{a, b}	2
{b, d}	2

C_3

项集
{a, b, d}

计算支持度 →

L_3

项集	支持度
{a, b, d}	1

设 *min_support* = 2

$\{a\} \Rightarrow \{b\}$
$\{b\} \Rightarrow \{a\}$
$\{b\} \Rightarrow \{d\}$
$\{d\} \Rightarrow \{b\}$

北京大学

关联规则的相关分析

- 强关联规则不一定有价值
- 候选规则：
  - {b} ⇒ {a}
  - 支持度 = 50%，　置信度 ≈ 67% => 强关联规则
- 规则的误导：
  - 整体购买{a}的可能性是75%（期望可信度），比67%还大
  - 事实：{b} 和 {a} 是负相关的

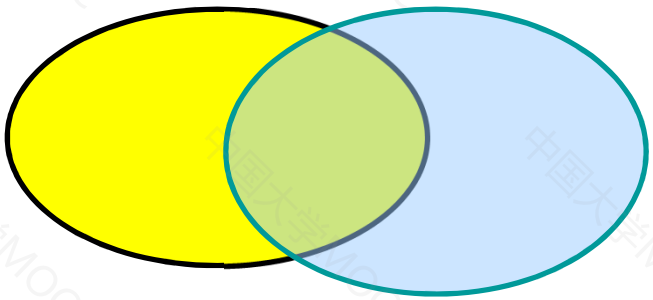
TID	项目
1	b, d
2	a, b, c
3	a, b, d
4	a, e

→

项集	支持度
{a}	3
{b}	3
{d}	2

→

项集	支持度
{a, b}	2
{b, d}	2



提升度与相关度

- 候选规则 {b} ⇒ {a}：支持度 = 50%， 置信度 ≈ 67% （强关联规则）
- 改善度（提升度）：$\text{lift}(A => B) = \frac{\text{confidence}(A=>B)}{P(B)} = \frac{P(A \cup B)}{P(A)*P(B)}$
  - $\text{lift}(\{b\} => \{a\}) = \frac{\text{confidence}(\{b\}=>\{a\})}{P(\{a\})} = \frac{0.67}{0.75} < 1$
- 相关度：$\text{corr}(A,B) = \text{lift}(A => B) = \text{lift}(B => A) = \frac{P(A \cup B)}{P(A)*P(B)}$

$\text{corr}(A,B)$: <1，负相关 （规则无意义！）
=1，A和B是独立的
>1，正相关，每一个出现蕴涵另一个出现

TID	项目
1	b, d
2	a, b, c
3	a, b, d
4	a, e

→

项集	支持度
{a}	3
{b}	3
{d}	2

→

项集	支持度
{a, b}	2
{b, d}	2

北京大学

基于关联规则的推荐

- 寻找有效的强关联规则：（离线）
  - 依据支持度寻找频繁项集（Apriori算法），并生成候选关联规则
  - 依据置信度和提升度过滤弱的或无效的关联规则，保留有效强关联规则
- 确定候选项目集：（在线）
  - 基于用户刚加购物车或刚购买的项目集合
  - 依据有效的强关联规则，确定候选项目集
- 排序推荐：
  - 根据规则的置信度（加和）对候选项目进行排序，并生成推荐列表

