

# 基于模型的协同过滤：矩阵分解

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

# 矩阵分解

- 基本假设：
  - 基于观察到的所有用户历史行为数据
  - 可以推测出用户和项目的潜在特征表示（画像）
- 基本思想：
  - 将历史行为数据表示为矩阵：隐式反馈矩阵 vs 评分矩阵
  - 通过矩阵分解挖掘（学习）用户和项目的潜在表示，降低数据维度
- 理论依据：
  - 奇异值分解（Singular Value Decomposition，SVD）

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 3 | | | 5 | | | | 4 | |
| | 5 | 4 | | | 4 | | 2 | 1 | 3 |
| 2 | | 1 | 2 | | 3 | | 3 | 5 | |
| | 4 | | 5 | | | 4 | | 2 | |
| | 4 | 3 | 4 | 2 | | | | 2 | 5 |
| 1 | 3 | | 3 | | | 2 | | 4 | |

~

| | | |
|---|---|---|
| 1.3 | -1.3 | 1.6 |
| -0.5 | -2.4 | 1.7 |
| 2.5 | -0.1 | 0.5 |
| 1.2 | -2.1 | -1.1 |
| 0.9 | -1.9 | -0.3 |
| 1.5 | -1.4 | 1.0 |

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 0.8 | 0.1 | 0.3 | 0.8 | -0.6 | 1.0 | 0.4 | 1.1 | 1.9 | 2.3 |
| 0.3 | -2.0 | -1.5 | -1.7 | -1.7 | -1.1 | -1.5 | -0.5 | -0.3 | -1.6 |
| 0.2 | 0.1 | 0.3 | -0.5 | 2.2 | 1.1 | -.5 | 0.7 | 0.7 | 0.2 |

北京大学

# 奇异值分解SVD

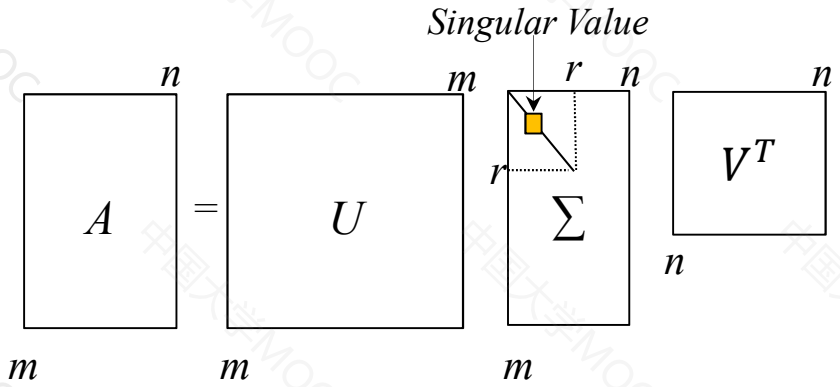
- SVD(Singular Value Decomposition)：线性代数中一种矩阵分解技术
- 任意一个$m \times n$的矩阵$\boldsymbol{R}$都可分解成三个矩阵$\boldsymbol{U}$、$\boldsymbol{\Sigma}$和$\boldsymbol{V}$的乘积：

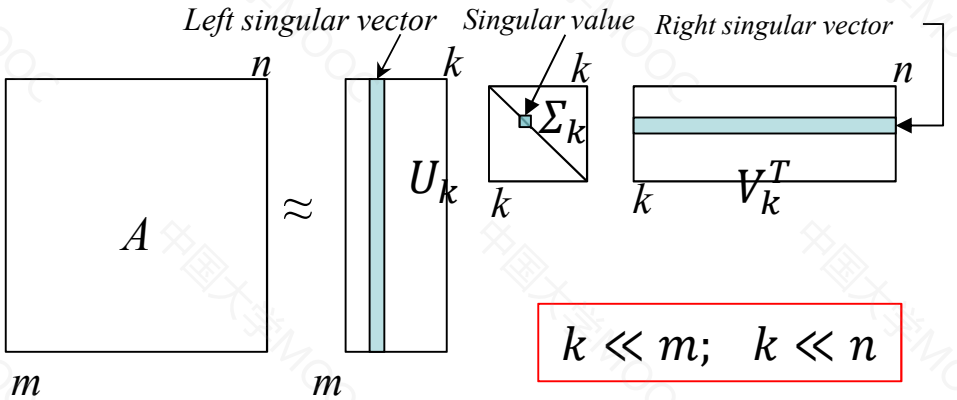
$$\boldsymbol{R}_{m\times n} = \boldsymbol{U}_{m\times m} \times \boldsymbol{\Sigma}_{m\times n} \times \boldsymbol{V}^T_{n\times n}$$

  - $\boldsymbol{U}$和$\boldsymbol{V}$分别是$m \times m$和$n \times n$的正交矩阵
  - $\boldsymbol{\Sigma}$是$m \times n$的对角矩阵，对角元素为矩阵$\boldsymbol{R}$的奇异值（从大到小排列）

- 矩阵降维（估计）
  - SVD分解后，若只保留前$k$个最大奇异值，能实现对矩阵的降维（估计）
  - 利用前$k$个奇异值和对应特征向量所包含的信息来近似描述原矩阵$\boldsymbol{R}$：

$$\boldsymbol{R}_{m\times n} = \boldsymbol{U}_{m\times m} \times \boldsymbol{\Sigma}_{m\times n} \times \boldsymbol{V}^T_{n\times n} \Rightarrow \boldsymbol{R}_{m\times n} \approx \boldsymbol{U}_{m\times k} \times \boldsymbol{\Sigma}_{k\times k} \times \boldsymbol{V}^T_{n\times k}$$




$k \ll m;\quad k \ll n$



# 奇异值分解SVD：示例

原始评分矩阵

| | 项目1 | 项目2 | 项目3 | 项目4 | 项目5 |
|---|---|---|---|---|---|
| 用户1 | 1 | 3 | 4 | 2 | 3 |
| 用户2 | 2 | 4 | 2 | 2 | 4 |
| 用户3 | 1 | 3 | 3 | 2 | 3 |
| 用户4 | 3 | 5 | 4 | 3 | 5 |
| 用户5 | 1 | 2 | 1 | 1 | 2 |

SVD重构矩阵

| | 项目1 | 项目2 | 项目3 | 项目4 | 项目5 |
|---|---|---|---|---|---|
| 用户1 | 1.0 | 3.0 | 4.0 | 2.1 | 3.0 |
| 用户2 | 2.2 | 3.9 | 2.1 | 2.1 | 3.9 |
| 用户3 | 1.3 | 2.9 | 3.1 | 1.9 | 2.9 |
| 用户4 | 2.6 | 5.1 | 3.9 | 3.0 | 5.1 |
| 用户5 | 1.1 | 2.0 | 1.0 | 1.0 | 2.0 |

$$R_{m\times n} = U_{m\times m} \times \Sigma_{m\times n} \times V^T_{n\times n}$$
$$R_{m\times n} \approx U_{m\times k} \times \Sigma_{k\times k} \times V^T_{n\times k}$$

用户特征矩阵

| $U_k$ | 特征维度1 | 特征维度2 |
|---|---|---|
| 用户1 | 0.42 | -0.71 |
| 用户2 | 0.46 | 0.55 |
| 用户3 | 0.39 | -0.31 |
| 用户4 | 0.64 | 0.17 |
| 用户5 | 0.23 | 0.27 |

奇异值矩阵（$k$=2）

| Σ | | | | | |
|---|---|---|---|---|---|
| | 14.33 | 0 | 0 | 0 | 0 |
| | 0 | 2.07 | 0 | 0 | 0 |
| | 0 | 0 | 0.61 | 0 | 0 |
| | 0 | 0 | 0 | 0.17 | 0 |
| | 0 | 0 | 0 | 0 | 0 |

项目特征矩阵

| $V_k^T$ | 项目1 | 项目2 | 项目3 | 项目4 | 项目5 |
|---|---|---|---|---|---|
| 特征维度1 | 0.27 | 0.55 | 0.46 | 0.33 | 0.55 |
| 特征维度2 | 0.42 | 0.26 | -0.83 | -0.07 | 0.26 |

# 隐语义模型LFM

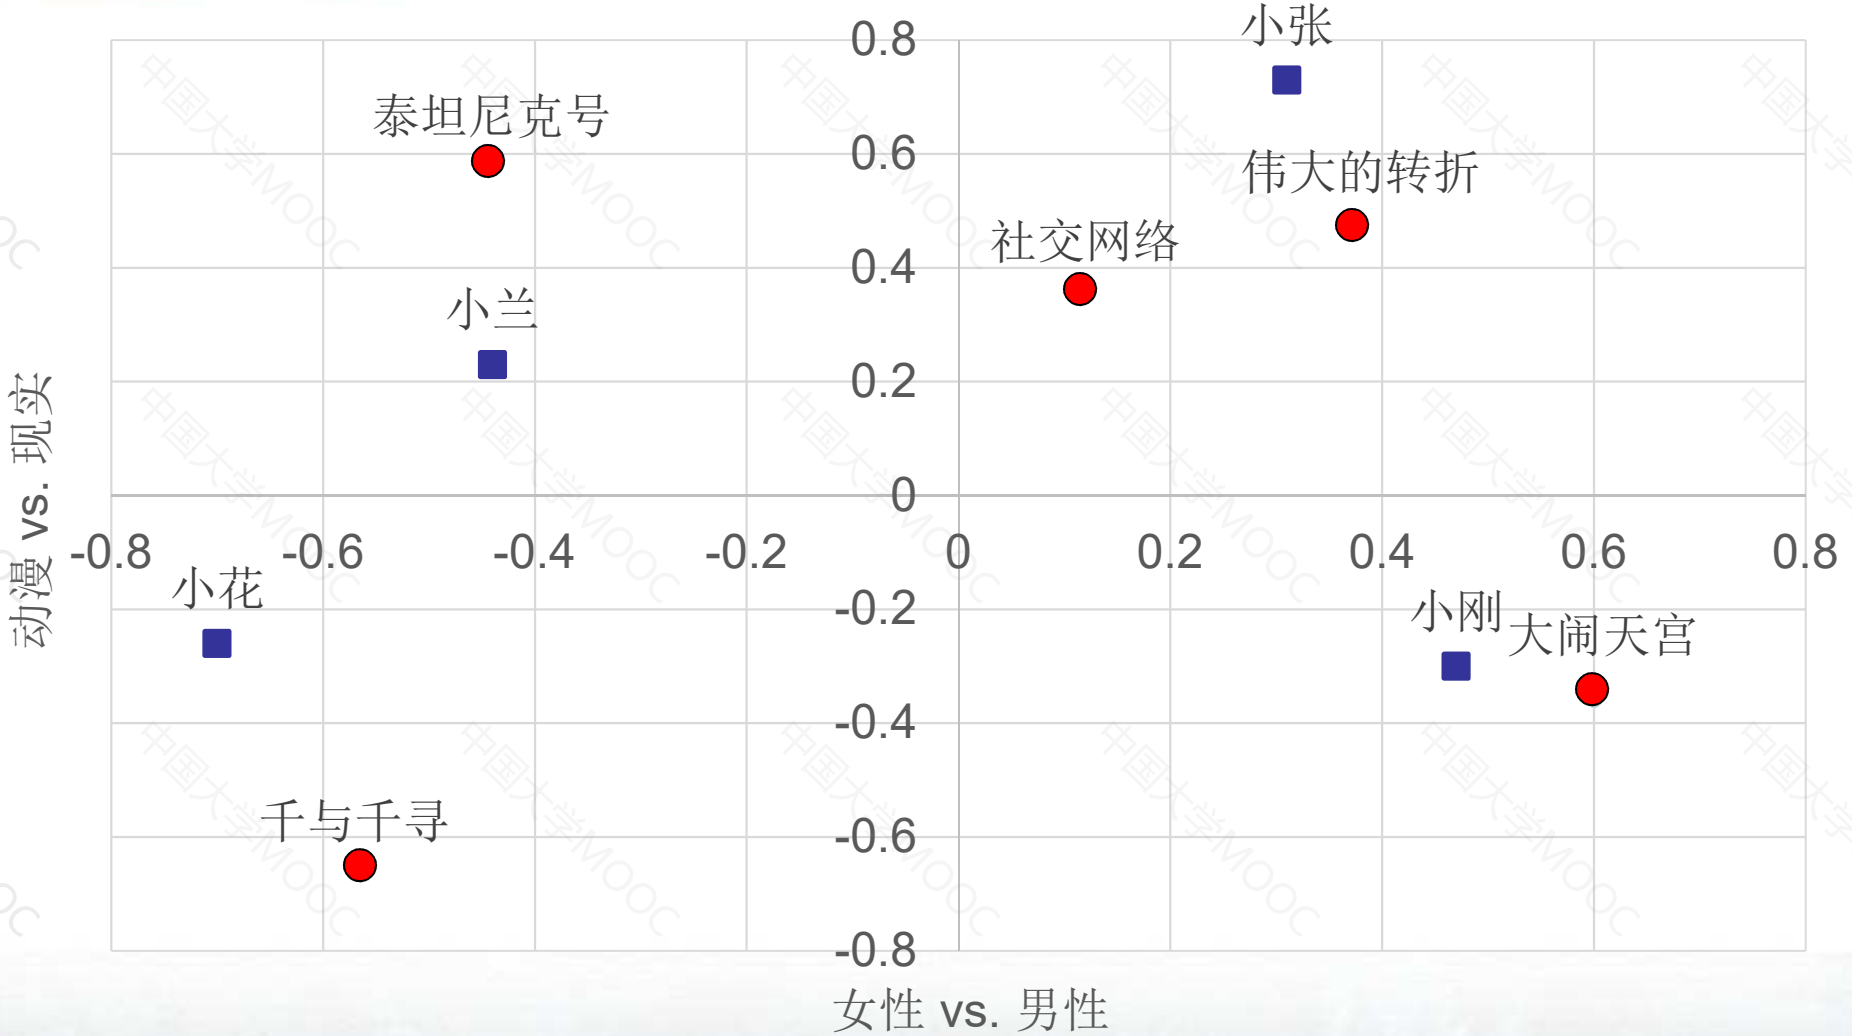
- 动机：
  - SVD分解需要知道完整的矩阵信息
  - 当矩阵的数据（信息）不完整时，传统SVD分解无法直接应用
  - 用户评分行为是稀疏的，存在大量的缺失值
- 理论依据：
  - 对任意$m \times n$的矩阵$\boldsymbol{R}$，存在如下分解（可基于SVD分解证明得到）

$$\boldsymbol{R}_{m\times n} = \boldsymbol{X}_{m\times k}\boldsymbol{Y}^{T}_{n\times k}$$

  $\boldsymbol{X}$是$m\times k$的矩阵，$\boldsymbol{Y}$是$n\times k$的矩阵，$k$表示矩阵$\boldsymbol{R}$的秩
- 基本思想：
  - 将用户和项目映射到同一个隐藏的（潜在的）因子空间中
  - 直接对用户和项目进行比较，即直接计算用户和项目的相关度

北京大学

# 隐语义空间：示例




北京大学

# 隐语义模型LFM：示例

- 将用户和项目映射到同一个隐藏的（潜在的）因子空间中
- 直接对用户和项目进行比较，即直接计算用户和项目的相关度

$$\boldsymbol{R} = \boldsymbol{P} \times \boldsymbol{Q}^T$$

评分矩阵$\boldsymbol{R}$

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 3 | | | 5 | | | | 4 | |
| | 5 | 4 | | | 4 | | 2 | 1 | 3 |
| 2 | | 1 | 2 | | 3 | | 3 | 5 | |
| | 4 | | 5 | | | 4 | | 2 | |
| | 4 | 3 | 4 | 2 | | | | 2 | 5 |
| 1 | 3 | | 3 | | | 2 | | 4 | |

$\sim$

用户隐特征矩阵$\boldsymbol{P}$

| | | |
|---|---|---|
| 1.3 | -1.3 | 1.6 |
| -0.5 | -2.4 | 1.7 |
| 2.5 | -0.1 | 0.5 |
| 1.2 | -2.1 | -1.1 |
| 0.9 | -1.9 | -0.3 |
| 1.5 | -1.4 | 1.0 |

项目隐特征矩阵$\boldsymbol{Q}^T$

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 0.8 | 0.1 | 0.3 | 0.8 | -0.6 | 1.0 | 0.4 | 1.1 | 1.9 | 2.3 |
| 0.3 | -2.0 | -1.5 | -1.7 | -1.7 | -1.1 | -1.5 | -0.5 | -0.3 | -1.6 |
| 0.2 | 0.1 | 0.3 | -0.5 | 2.2 | 1.1 | -.5 | 0.7 | 0.7 | 0.2 |

重构评分矩阵$\boldsymbol{R'}$

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 3 | 3 | 2 | 5 | 4 | 2 | 3 | 4 | 5 |
| -1 | 5 | 4 | 3 | 8 | 4 | 2 | 2 | 1 | 3 |
| 2 | 1 | 1 | 2 | 0 | 3 | 1 | 3 | 5 | 6 |
| 0 | 4 | 3 | 5 | 0 | 2 | 4 | 1 | 2 | 6 |
| 0 | 4 | 3 | 4 | 2 | 3 | 3 | 2 | 2 | 5 |
| 1 | 3 | 3 | 3 | 4 | 4 | 2 | 3 | 4 | 6 |

北京大学

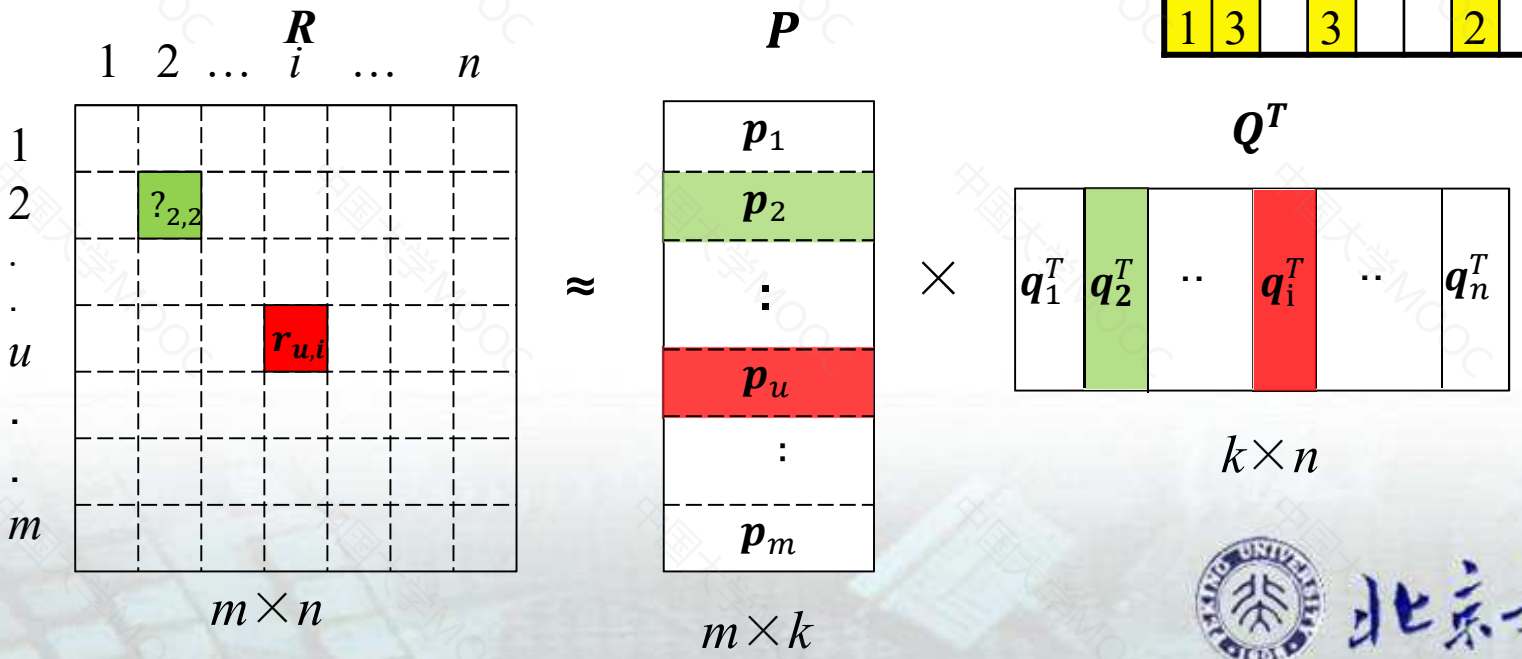
# 隐语义模型LFM：目标函数

- 目标函数: 最小化平方误差

$$\min_{P,Q} \sum_{(u,i)\in S} (r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2$$

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 3 | | | 5 | | | | 4 | |
| | 5 | 4 | | | 4 | | 2 | 1 | 3 |
| 2 | | 1 | 2 | | 3 | | 3 | 5 | |
| | 4 | | 5 | | | 4 | | 2 | |
| | 4 | 3 | 4 | 2 | | | | 2 | 5 |
| 1 | 3 | | 3 | | | 2 | | 4 | |

- $r_{ui}$: 已知的用户$u$ 对 项目 $i$ 的评分
- $\hat{r}_{ui} = < \boldsymbol{p}_u, \boldsymbol{q}_i >$: 预测评分值
- $S$: 观测到的用户评分数据集

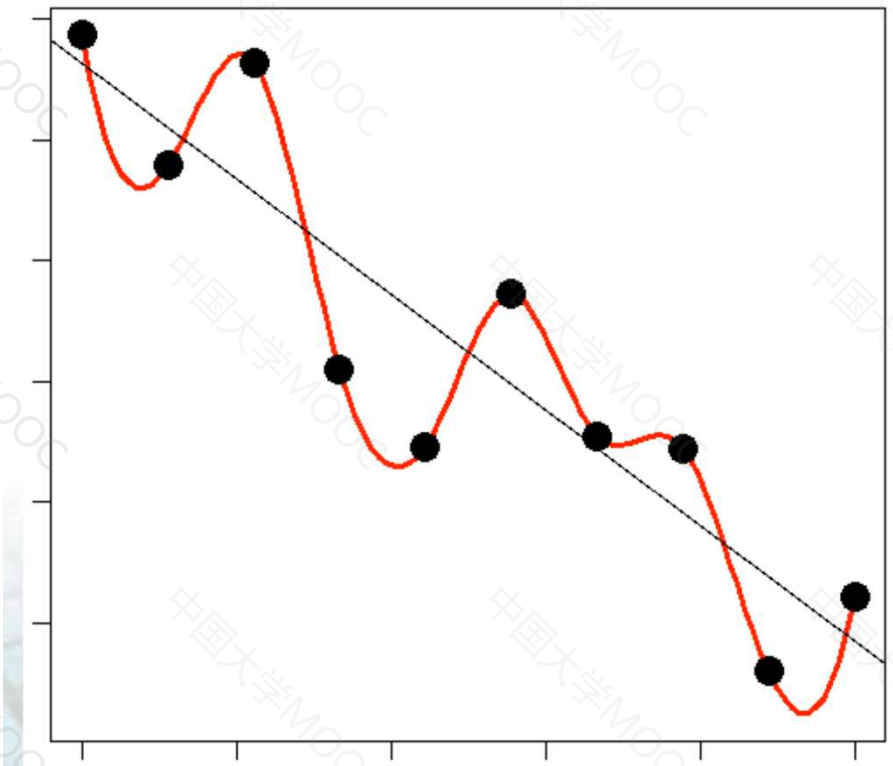


# 过拟合 与 正则化

- 过度拟合观测到的评分数据，缺乏对未知数据的预测能力
- 解决方案：在模型中添加正则化项

$$\min_{P,Q} \sum_{(u,i)\in S} (r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2 + \lambda[||\boldsymbol{P}||_F^2 + ||\boldsymbol{Q}||_F^2]$$

$$||\boldsymbol{A}||_F^2 = \sum_{i=1}^{m}\sum_{j=1}^{n} |a_{ij}|^2$$



引导一些不重要的参数被减少到0或可以被忽略，以降低模型的复杂度

奥卡姆剃刀原理：
"如无必要, 勿增实体", 即"简单有效原理"

北京大学

# 参数学习：随机梯度下降法

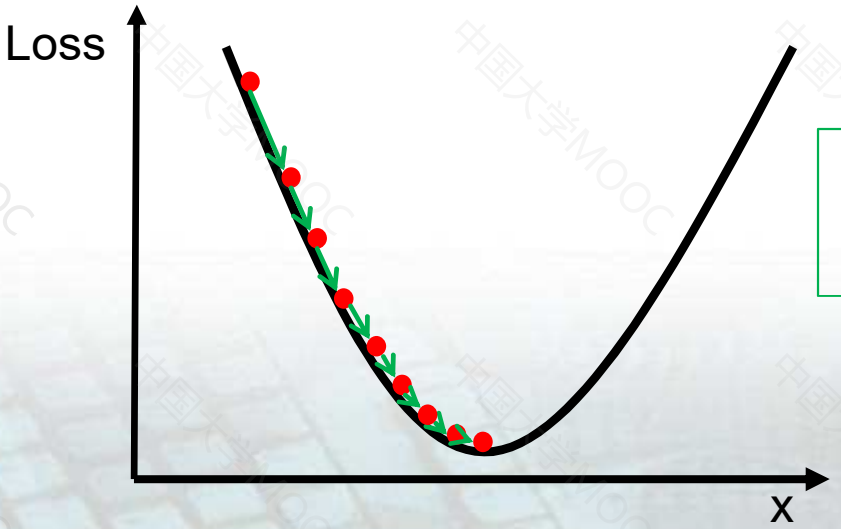
- 随机初始化参数：P和Q，并利用梯度信息迭代优化目标
- 每次随机地抽取一个（或一组）样本：（$u$，$i$，$r_{ui}$）
- 计算预测误差（或损失）和梯度，并根据梯度更新参数

$$L_{ui} = (r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2 + \lambda[||\boldsymbol{p}_u||^2 + ||\boldsymbol{q}_i||^2]$$

$$\boldsymbol{p}_u' = \boldsymbol{p}_u - \alpha\left(\frac{\partial L_{ui}}{\partial \boldsymbol{p}_u}\right); \qquad \boldsymbol{q}_i' = \boldsymbol{q}_i - \alpha\left(\frac{\partial L_{ui}}{\partial \boldsymbol{q}_i}\right)$$

$$\frac{\partial L_{ui}}{\partial \boldsymbol{p}_u} = -2\boldsymbol{q}_i(r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >) + 2\boldsymbol{p}_u; \qquad \frac{\partial L_{ui}}{\partial \boldsymbol{q}_i} = -2\boldsymbol{p}_u(r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >) + 2\boldsymbol{q}_i$$

- 如此反复，直至收敛或达到预设的最大迭代次数




$$\min_{P,Q} \sum_{(u,i)\in S} (r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2 + \lambda[||\boldsymbol{P}||_F^2 + ||\boldsymbol{Q}||_F^2]$$

北京大学

# 参数学习：交替最小二乘法

- 固定一组参数，例如$\boldsymbol{P}$，并用最小二乘法求另一组参数$\boldsymbol{Q}$的最优取值

$$\frac{\partial L}{\partial \boldsymbol{q}_i} = 0 \quad \Rightarrow \quad \boldsymbol{q}_i = \left( \sum_{u|(u,i)\epsilon S} \boldsymbol{p}_u \boldsymbol{p}_u{}^T + \lambda \boldsymbol{E} \right)^{-1} \sum_{u|(u,i)\epsilon S} \boldsymbol{p}_u r_{ui}$$

  - $\boldsymbol{E}$: $m \times m$的单位矩阵，$S$: 观测到的用户评分数据集, $r_{ui}$: 用户$u$对项目$i$的评分

- 交替优化，固定$\boldsymbol{Q}$，并用最小二乘法求$\boldsymbol{P}$的最优取值

$$\frac{\partial L}{\partial \boldsymbol{p}_u} = 0 \quad \Rightarrow \quad \boldsymbol{p}_u = \left( \sum_{i|(u,i)\epsilon S} \boldsymbol{q}_i \boldsymbol{q}_i{}^T + \lambda \boldsymbol{E} \right)^{-1} \sum_{i|(u,i)\epsilon S} \boldsymbol{q}_i r_{ui}$$

- 如此反复，直至收敛或达到预设的最大迭代次数

$$L = \sum_{(u,i)\in S} (r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2 + \lambda [||\boldsymbol{P}||_F^2 + ||\boldsymbol{Q}||_F^2]$$

北京大学