

基于模型的CF：概率矩阵分解

刘宏志 博士、副教授

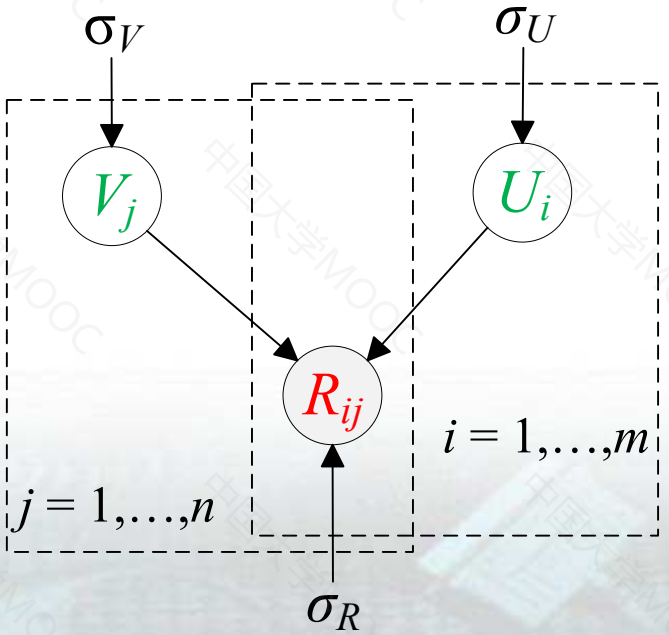
liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

概率矩阵分解模型 (PMF)

- 矩阵分解的困难：
  - 由于系统噪音存在，不可能做出完美的分解
  - 评分矩阵R 中包含很多未知元素（稀疏矩阵）
- 贝叶斯观点：
  - 评分矩阵R 是系统观测值
  - 用户和项目隐特征矩阵U和V 可看作系统内部特征，是需要估计的参数
  - 目标：根据观测得到的评分值R，推理系统隐藏的参数U和V



北京大学

概率分布假设

- 概率分布假设：
  - 用户特征U和项目特征V都服从均值为0的高斯分布（正态分布）

$$p(\boldsymbol{U}) = N(0, \sigma_U^2), \qquad p(\boldsymbol{V}) = N(0, \sigma_V^2)$$

  - 观测噪声（观测值矩阵R和近似值矩阵$\hat{R}$之差）服从均值为0的高斯分布

$$p(\boldsymbol{R}|\boldsymbol{U}, \boldsymbol{V}) = N\left(\hat{\boldsymbol{R}}, \sigma_R^2\right) = N(\boldsymbol{U}\boldsymbol{V}^T, \sigma_R^2)$$

- 独立同分布假设：
  - U中每个用户的特征值U_i是独立同分布：$p(\boldsymbol{U}|\sigma_U^2) = \prod_{i=1}^{m} N(\boldsymbol{U}_i|0, \sigma_U^2\boldsymbol{E})$
  - V中每个项目的特征值V_i是独立同分布：$p(\boldsymbol{V}|\sigma_V^2) = \prod_{i=1}^{n} N(\boldsymbol{V}_i|0, \sigma_V^2\boldsymbol{E})$
  - R中每个观察值R_{ij}是独立同分布：

$$p(\boldsymbol{R}|\boldsymbol{U}, \boldsymbol{V}, \sigma_R^2) = \prod_{i=1}^{m} \prod_{j=1}^{n} [N(\mathrm{R}_{ij}|\boldsymbol{U}_i\boldsymbol{V}_j^T, \sigma_R^2)]^{I_{ij}}$$

I_{ij}：评分指示函数，若用户i对项目j有过评分，则$I_{ij} = 1$，否则$I_{ij} = 0$

北京大学

贝叶斯推理

$$P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$$

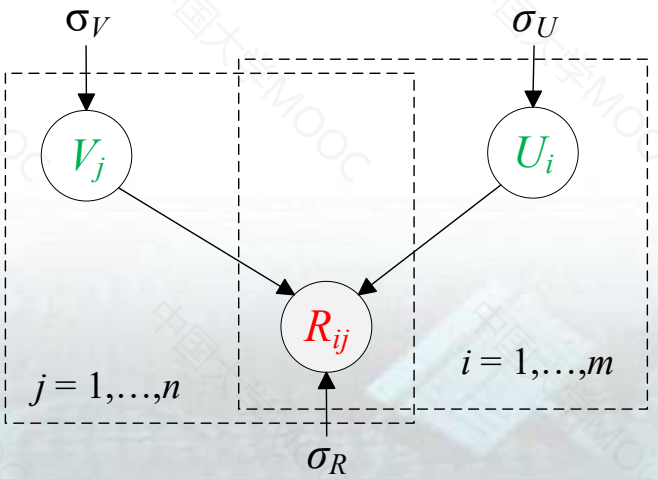
- 假设U和V相互独立，利用贝叶斯公式得到：

$$p(U,V|R,\sigma_R^2,\sigma_U^2,\sigma_V^2) \propto p(R|U,V,\sigma^2)p(U,V,\sigma_U^2,\sigma_V^2)$$
$$= p(R|U,V,\sigma^2)p(U|\sigma_U^2)p(V|\sigma_U^2)$$

- 利用用户U_i之间独立性、项目V_i之间独立性和观测值R_{ij}之间独立性

$$p(U,V|R,\sigma_R^2,\sigma_U^2,\sigma_V^2) \propto p(R|U,V,\sigma_R^2)p(U|\sigma_U^2)p(V|\sigma_U^2)$$

$$= \prod_{i=1}^{m}\prod_{j=1}^{n}[N(R_{ij}|\boldsymbol{U}_i\boldsymbol{V}_j^T,\sigma_R^2)]^{I_{ij}} \prod_{i=1}^{m} N(\boldsymbol{U}_i|0,\sigma_U^2\boldsymbol{E}) \prod_{i=1}^{n} N(V_i|0,\sigma_V^2\boldsymbol{E})$$



参数估计:最大后验概率估计(MAP)

$$N(x|\mu,\sigma)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 目标：最大化对数后验概率值

$$\ln p(\boldsymbol{U},\boldsymbol{V}|\boldsymbol{R},\sigma^2,{\sigma_U}^2,{\sigma_V}^2) \propto -\frac{\sum_{i=1}^{m}\sum_{j=1}^{n}I_{ij}\left(R_{ij}-\boldsymbol{U}_i\boldsymbol{V}_j^T\right)^2}{2\sigma_R^2}-\frac{\sum_{i=1}^{m}\boldsymbol{U}_i\boldsymbol{U}_i^T}{2\sigma_U^2}-\frac{\sum_{j=1}^{n}\boldsymbol{V}_j\boldsymbol{V}_j^T}{2\sigma_V^2}$$

- 等价于求下式的最小值：

$$\mathrm{E}=\sum_{i=1}^{m}\sum_{j=1}^{n}I_{ij}\left(R_{ij}-\boldsymbol{U}_i\boldsymbol{V}_j^T\right)^2+\lambda_U\sum_{i=1}^{m}||\boldsymbol{U}_i||_F^2+\lambda_V\sum_{j=1}^{n}||\boldsymbol{V}_j||_F^2$$

  - $\lambda_U=\sigma_R^2/\sigma_U^2,\ \ \lambda_V=\sigma_R^2/\sigma_V^2$

- PMF的最大后验概率估计 与 优化带正则项的LFM的目标函数等价

$$\min_{P,Q}\sum_{(u,i)\in S}(r_{ui}-<\boldsymbol{p}_u,\boldsymbol{q}_i>)^2+\lambda[||\boldsymbol{P}||_F^2+||\boldsymbol{Q}||_F^2]$$

$$p(U,V|R,\sigma^2,\sigma_U^2,\sigma_V^2)\propto p(R|U,V,\sigma^2)p(U|\sigma_U^2)p(V|\sigma_U^2)$$

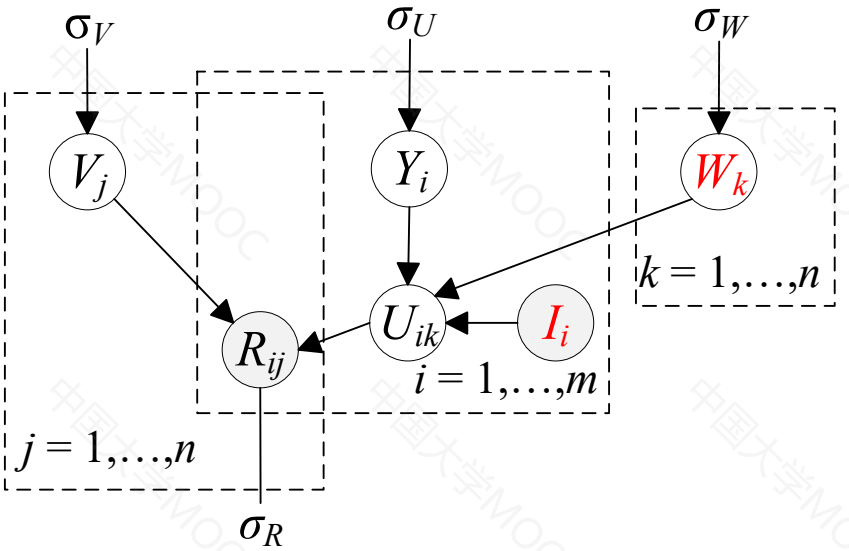
$$=\prod_{i=1}^{m}\prod_{j=1}^{n}[N(R_{ij}|\boldsymbol{U}_i\boldsymbol{V}_j^T,\sigma_R^2)]^{I_{ij}}\prod_{i=1}^{m}N(\boldsymbol{U}_i|0,\sigma_U^2\boldsymbol{E}))\prod_{i=1}^{n}N(V_i|0,\sigma_V^2\boldsymbol{E}))$$

限制性PMF

- 基本思想：
  - “用户是否给某项目评过分”这一信息本身就能在一定程度上反映用户偏好
  - 用户对某项目有过评分，说明该项目有某些特征吸引用户对它有过消费行为
- $W \in R^{n \times d}$表示潜在的项目影响矩阵
  - 第k行W_k：如果用户对第k个项目有过评分，则用户应该具有特征W_k
- 用户特征U由两部分组成：

$$\boldsymbol{U}_{\mathrm{i}} = \boldsymbol{Y}_i + \frac{\sum_{k=1}^{n} I_{ik} W_k}{\sum_{k=1}^{n} I_{ik}}$$

  - 用户自身特征向量Y
  - 用户评过分的项目I的影响向量W加权
  - I_{ij}=1：用户i 对项目j 有过评分，否则等于0



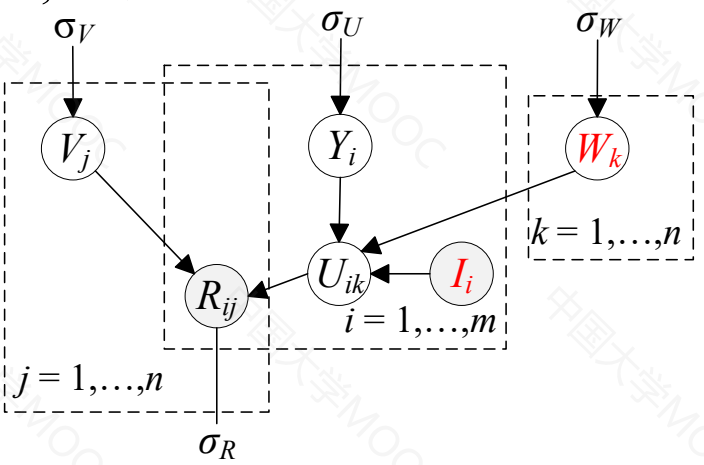
限制性PMF

- 概率分布假设：均值为0的高斯分布
  - $p(\boldsymbol{W}) = N(0, \sigma_W^2)$，　$p(\boldsymbol{Y}) = N(0, \sigma_U^2)$
  - 其他变量的概率分布假设与无限制PMF相同
- 目标函数：
  - 基于独立性假设，利用贝叶斯公式，采用最大后验概率估计法MAP

$$\mathrm{E} = \sum_{i=1}^{m}\sum_{j=1}^{n} I_{ij}\left(R_{ij} - \left(\boldsymbol{Y}_i + \frac{\sum_{k=1}^{n} I_{ik}\boldsymbol{W}_k}{\sum_{k=1}^{n} I_{ik}}\right)\boldsymbol{V}_j^T\right)^2 + \lambda_Y \sum_{i=1}^{m}\left|\left|\boldsymbol{Y}_i\right|\right|_F^2 + \lambda_V \sum_{j=1}^{n}\left|\left|\boldsymbol{V}_j\right|\right|_F^2 + \lambda_W \sum_{k=1}^{n}\left|\left|\boldsymbol{W}_k\right|\right|_F^2$$

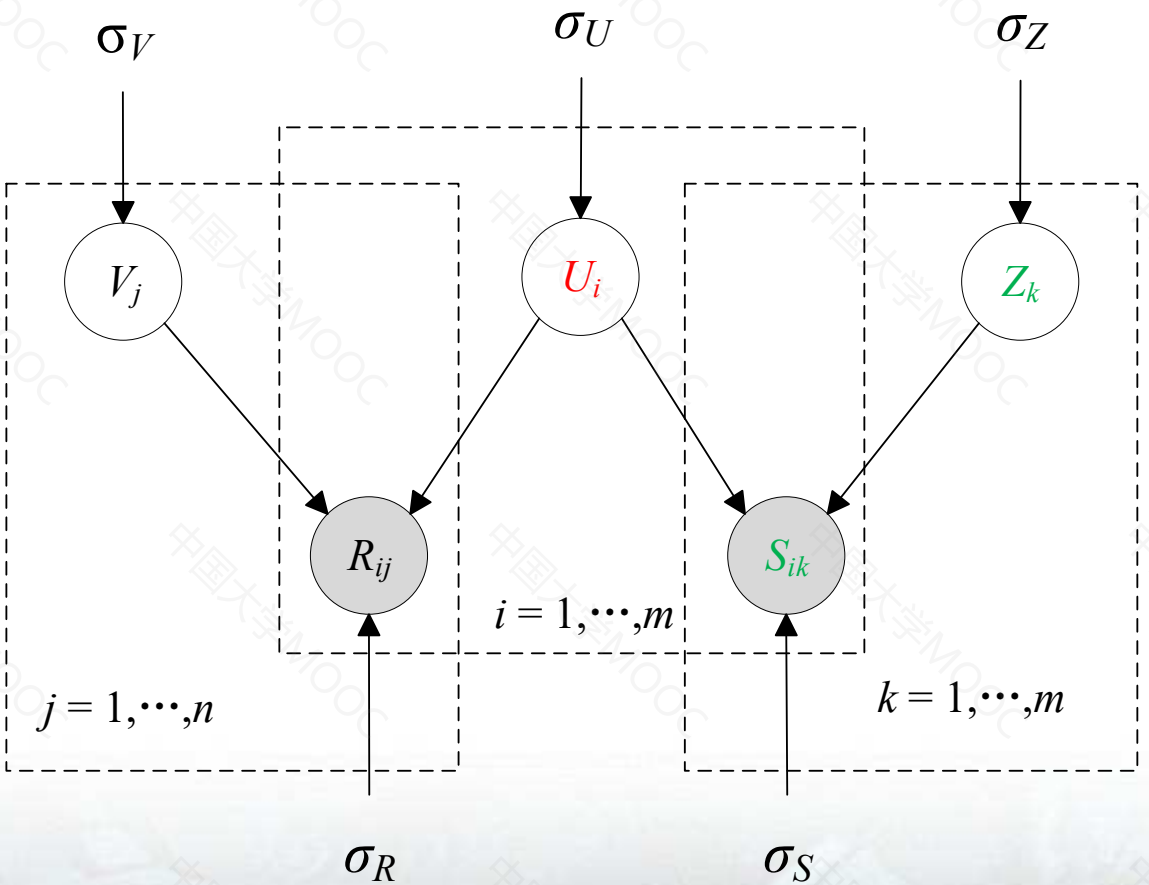
- 参数学习：利用随机梯度下降法，学习参数矩阵Y, V 和W
- 评分预测：$\hat{R}_{ij} = \left(\boldsymbol{Y}_i + \frac{\sum_{k=1}^{n} I_{ik}\boldsymbol{W}_k}{\sum_{k=1}^{n} I_{ik}}\right)\boldsymbol{V}_j^T$

$$\boldsymbol{U}_i = \boldsymbol{Y}_i + \frac{\sum_{k=1}^{n} I_{ik} W_k}{\sum_{k=1}^{n} I_{ik}}$$



PMF模型扩展

- 只要有共享潜在特征矩阵的附加数据矩阵，就可以扩展PMF模型
- 例如: 社交推荐中社交关系矩阵和用户行为矩阵共享潜在用户特征矩阵



SoRec算法示意图

北京大学