

基于模型的CF：SVD++与Top-N推荐

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

带偏置的矩阵分解（BiasSVD）

- 假设：
  - 用户有一些和项目无关的评分因素，称为用户偏置项
    有些人较宽容并习惯于给别人好评 vs. 有些人较苛刻且评分普遍较低
  - 项目有一些和用户无关的评分因素，称为项目偏置项
- 评分预测公式：

$$\hat{r}_{ui} = \mu + b_u + b_i + \boldsymbol{p}_u \boldsymbol{q}_i^T$$

  - μ表示总体的评分平均值（矩阵均值）
  - b_u表示用户评分偏置，即用户评分与评分均值μ之间的偏差（行偏差）
  - b_i表示项目评分偏置，即项目评分相对于评分平均值的偏差（列偏差）
  - $\boldsymbol{p}_u$表示用户u的隐特征向量，$\boldsymbol{q}_i$表示项目i的隐特征向量

用户\项目	*a*	*b*	*c*	*d*
A	5	3	3	?
B	3	1	1	2
C	3	3	3	3

北京大学

SVD++

- 动机：评分数据过于稀疏，导致矩阵分解困难
- 基本思想：通过引入有关用户的其他信息源来对模型进行改进
  - 和限制性PMF模型类似：使用隐式反馈来帮助了解用户的显式评分偏好

    如：点击、浏览、收藏、购买、评过分等，都从某些方面反映了用户的偏好特征
  - 在BiasSVD基础上，增加项目因子集合，为每个项目i关联一个因子向量$\boldsymbol{y}_i$

    如果用户对项目i有过隐式反馈，则该用户具有特征$\boldsymbol{y}_i$
- 评分预测公式：

$$\hat{r}_{ui} = \mu + b_u + b_i + (\boldsymbol{p}_u + |R(u)|^{-\frac{1}{2}}\Sigma_{j\in R(u)}\boldsymbol{y}_j)\boldsymbol{q}_i^T$$

  - $R(u)$表示用户u有过（隐式）反馈的项目集合
  - 当没有其他可用信息源时，$R(u)$可表示为用户u评过分的项目集合

北京大学



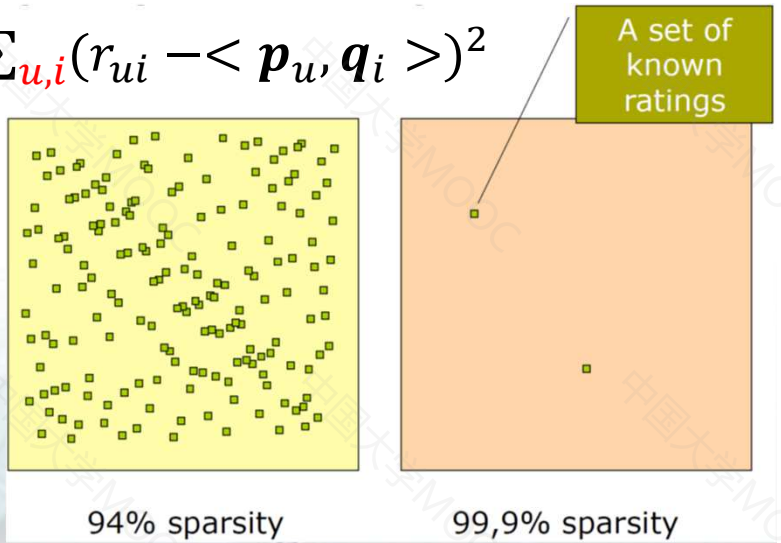
基于矩阵分解的Top-N推荐

中国大学MOOC

北京大学

动机

- 缺少负样本，评分矩阵分解方法不适用
  - 观测到是用户有过正反馈（点击、购买等）的项目，即用户喜欢$r_{ui}=1$
  - 目标函数：$\min_{P,Q}\sum_{(u,i)\in S}(r_{ui}-<\boldsymbol{p}_u,\boldsymbol{q}_i>)^2$，$S$: 观测到的用户反馈样本集
  - 一种最优解：$\boldsymbol{p}_u=\boldsymbol{q}_i=(1,0,0,\ldots,0)$，导致所有：$\hat{r}_{ui}=<\boldsymbol{p}_u,\boldsymbol{q}_i>=1$
- 反馈样本数量少（数据稀疏、样本不均）
  - 假设用户未反馈的项目为负样本：$r_{ui}=\begin{cases}1 & \text{用户}u\text{对项目}i\text{有过正反馈}\\ 0 & \text{其他}\end{cases}$
  - 考虑所有用户-项目对的目标函数：$\min_{P,Q}\sum_{u,i}(r_{ui}-<\boldsymbol{p}_u,\boldsymbol{q}_i>)^2$
  - 导致所有：$\hat{r}_{ui}=<\boldsymbol{p}_u,\boldsymbol{q}_i>\approx 0$



基于正样本过采样的矩阵分解

- 基本思想：
  - 通过对正样本进行过采样（oversampling）
  - 以解决正负样本分布不均衡的问题
- 目标函数： WRMF（Weighted Regularized Matrix Factorization）

$$\min_{\boldsymbol{P},\boldsymbol{Q}} \sum_{u,i} c_{ui}(r_{ui} - < \boldsymbol{p}_u, \boldsymbol{q}_i >)^2 + \lambda[||\boldsymbol{P}||_F^2 + ||\boldsymbol{Q}||_F^2]$$

  - c_{ui}表示置信度：$c_{ui} = 1 + \alpha \cdot r_{ui}$
  - 超参α控制过采样的比率，默认为40（即对每个正样本进行40次重复采样）
- 参数学习：交替最小二乘法ALS
- 兴趣度预测：$\hat{r}_{ui} = < \boldsymbol{p}_u, \boldsymbol{q}_i >$
- Top-N推荐：给定用户u，根据兴趣度预测值$\hat{r}_{ui}$对候选项目进行排序

北京大学

基于负样本欠采样的矩阵分解

- 基本思想：
  - 通过对负样本进行欠采样（undersampling）
  - 从未观测到反馈行为的样本中采样出一个和正样本集相当的集合作为负样本集
- 采样策略：
  - 随机均匀：假设每个未观测到反馈的样本都是负样本且影响相同
  - 面向用户：某用户反馈过的项目越多，则其还未反馈过的项目越可能是负样本
  - 面向项目：项目越热门，用户越可能知道其存在，还未反馈就越可能是负样本

采样策略	正反馈 权值	“负”反馈 权重
随机均匀采样	$W_{ui} = 1$	$W_{ui} = \delta, \delta \in [0,1]$
面向用户采样	$W_{ui} = 1$	$W_{ui} \propto \sum_j r_{uj}$
面向项目采样	$W_{ui} = 1$	$W_{ui} \propto \sum_v r_{vi}$

北京大学

基于负样本欠采样的矩阵分解

- 目标函数与参数学习：
  - 交替最小二乘法ALS：

$$\min \sum_{u,i} W_{ui}(r_{ui} - \langle \boldsymbol{P}_u, \boldsymbol{Q}_i \rangle)^2 + \lambda \left(\sum_u \|\boldsymbol{P}_u\|^2 + \sum_i \|\boldsymbol{Q}_i\|^2 \right)$$

  - 随机梯度下降法SGD：

$$\min \sum_{r_{ui} \in R_+ \cup R_-} (r_{ui} - \langle \boldsymbol{P}_u, \boldsymbol{Q}_i \rangle)^2 + \lambda \left(\sum_u \|\boldsymbol{P}_u\|^2 + \sum_i \|\boldsymbol{Q}_i\|^2 \right)$$

R_+表示正样本，R_-表示负样本，以权重因子W_{ui}作为采样概率

采样策略	正反馈 权值	“负”反馈 权重
随机均匀采样	$W_{ui} = 1$	$W_{ui} = \delta, \delta \in [0,1]$
面向用户采样	$W_{ui} = 1$	$W_{ui} \propto \sum_j r_{uj}$
面向项目采样	$W_{ui} = 1$	$W_{ui} \propto \sum_v r_{vi}$

北京大学

基于负样本欠采样的矩阵分解

- 基本思想：
  - 通过对负样本进行欠采样（undersampling）
  - 从未观测到反馈行为的样本中采样出一个和正样本集相当的集合作为负样本集
- 采样策略：
  - 随机均匀：假设每个未观测到反馈的样本都是负样本且影响相同
  - 面向用户：某用户反馈过的项目越多，则其还未反馈过的项目越可能是负样本
  - 面向项目：项目越热门，用户越可能知道其存在，还未反馈就越可能是负样本
- 目标函数与参数学习：
  - 交替最小二乘ALS：$\min \sum_{u,i} W_{ui}(r_{ui} - \langle \boldsymbol{P}_u, \boldsymbol{Q}_i \rangle)^2 + \lambda(\sum_u \|\boldsymbol{P}_u\|^2 + \sum_i \|\boldsymbol{Q}_i\|^2)$
  - 随机梯度下降SGD：$\min \sum_{r_{ui} \in R_+ \cup R_-} (r_{ui} - \langle \boldsymbol{P}_u, \boldsymbol{Q}_i \rangle)^2 + \lambda(\sum_u \|\boldsymbol{P}_u\|^2 + \sum_i \|\boldsymbol{Q}_i\|^2)$

	正反馈	“负”反馈
随机均匀采样	$W_{ui} = 1$	$W_{ui} = \delta, \delta \in [0,1]$
面向用户采样	$W_{ui} = 1$	$W_{ui} \propto \sum_j r_{uj}$
面向项目采样	$W_{ui} = 1$	$W_{ui} \propto \sum_u r_{ui}$