

基于内容的推荐：向量空间模型

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

北京大学 软件与微电子学院

中国大学MOOC

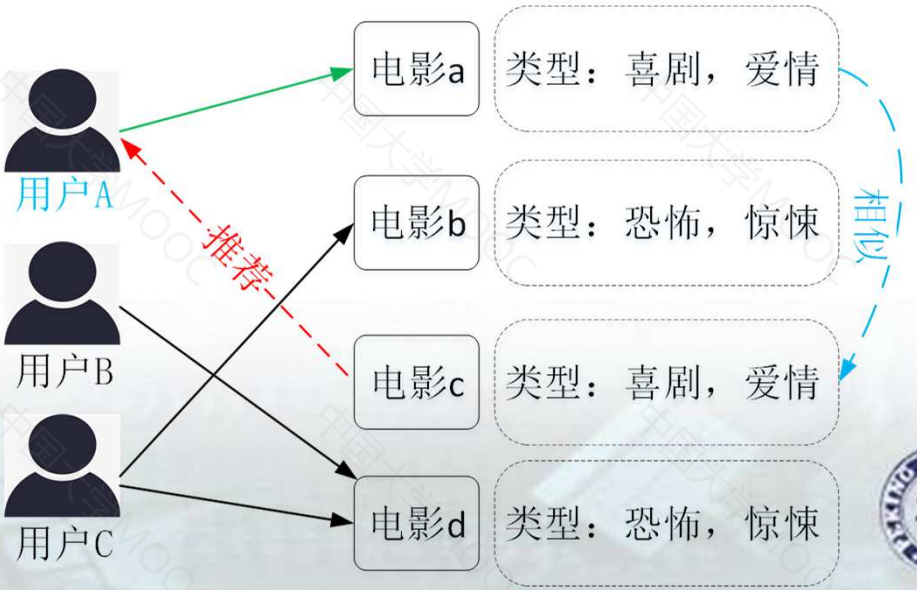
基于内容记忆的推荐

- Top-N推荐：用户u对候选项目i 的兴趣度

$$p(u,i) = \sum_{j \in N(u)} \omega_{ij} * r_{uj}$$

  - $N(u)$表示用户u有过正反馈的项目集合
  - r_{uj}表示用户u对项目j的兴趣度
  - ω_{ij}表示项目i和项目j之间的（内容）相似度

难点：非结构化内容数据，如：文本、图像、视频等



北京大学



基于向量空间模型的文本相似度

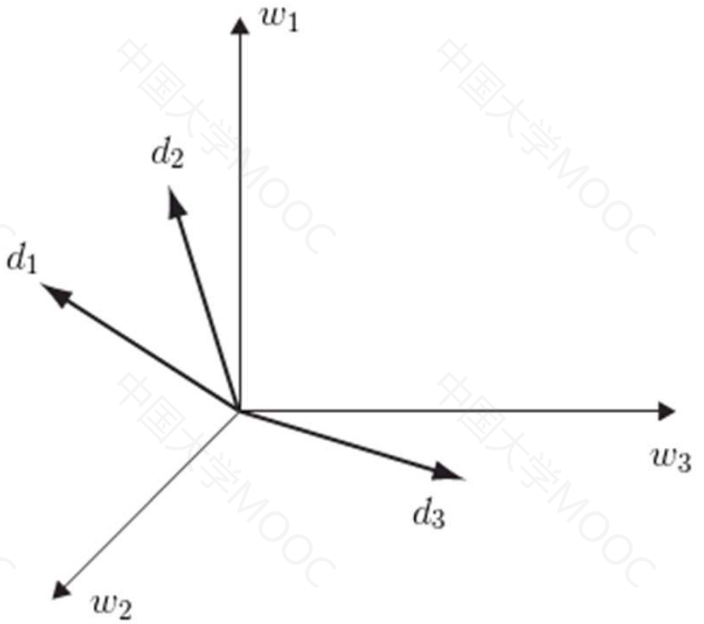
中国大学MOOC

北京大学

向量空间模型VSM

- 向量空间模型 (Vector Space Model, VSM)
- 一种把文本内容表示为标识符向量的代数模型
- 将非结构化文本描述数据进行向量化表示，使其具备可计算性





北京大学

词袋模型

- 基本思想：Bag of Words (BoW)
  - 将文档看作是由若干词构成的一个集合，即以词作为标识符
- 示例：
  - 三个简单的文本文档:

    文档d1：John likes to play football.

    文档d2：Jack likes to play basketball.

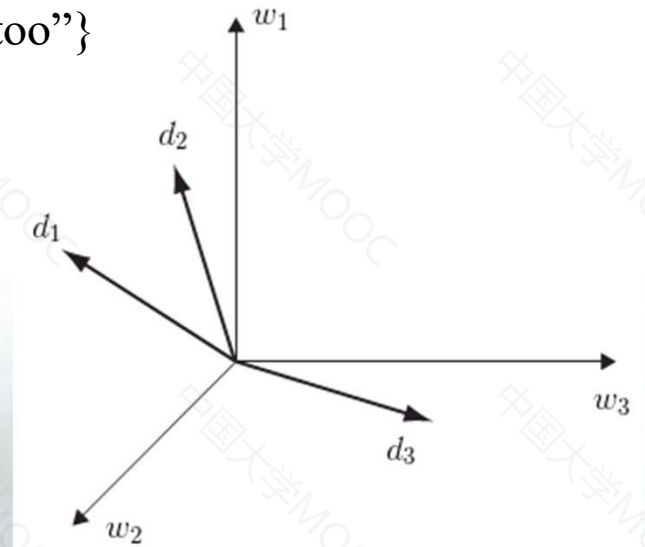
    文档d3：Jack plans to travel. John plans to travel too.
  - 基于这三个文本文档（语料库），可构造一个词典，如下：

    Dictionary={1.“John”, 2. “likes”, 3.“to”, 4.“play”, 5.“football”, 6.“Jack”, 7. “basketball”, 8.“plans”, 9.“travel”, 10.“too”}
  - 文本文档的词袋表示：（结构化表示）

    文档d1：[1, 1, 1, 1, 1, 0, 0, 0, 0, 0]

    文档d2：[0, 1, 1, 1, 0, 1, 1, 0, 0, 0]

    文档d3：[1, 0, 2, 0, 0, 1, 0, 2, 2, 1]

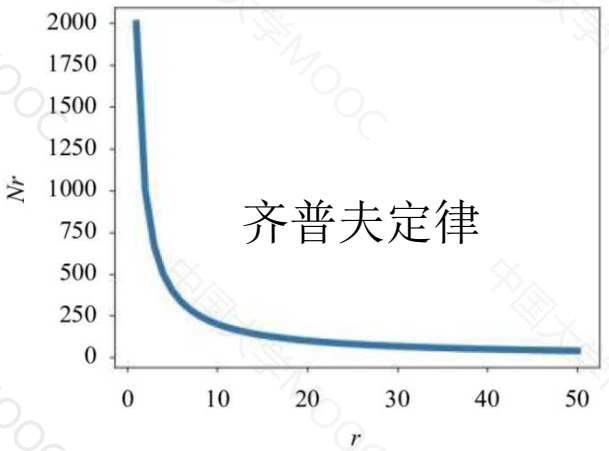


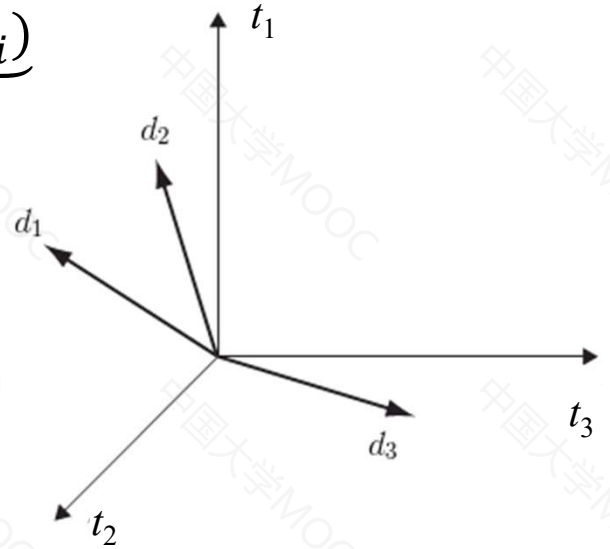
TF-IDF模型

- 动机：
  - 词袋模型假设各词的重要程度相同，导致文档表示受常用词的影响较大
    文本中不同词出现的频率分布服从长尾分布
  - 忽略文档长度，而同一词语在长文档里出现的次数可能会比短文档更大

- 基本思想：
  - 假设词的重要性会随着它在文档中出现的次数成正比增加
  - 同时也会随着它的普遍性（常用性）和文档长度成反比下降

$$\text{TF-IDF}(t_i, d_j) = \underbrace{\text{TF}(t_i, d_j)}_{\text{TF}} \cdot \underbrace{\text{IDF}(t_i)}_{IDF}$$





TF-IDF模型

- 词频（Term Frequency，TF）：

$$\mathrm{TF}(t_i, d_j) = \frac{n_{ij}}{\sum_k n_{kj}}; \quad \mathrm{TF}(t_i, d_j) = \frac{n_{ij}}{\max_k n_{kj}}$$

  - n_{ij}表示词t_i在文档d_j中出现的次数，$\max_k n_{kj}$表示文档d_j中的最大词频数

- 逆文档频率（Inverse Document Frequency，IDF）：
  - 对词语普遍重要性的度量，可用来缓解常用词的影响
  - 一个词在语料库中越普遍（例如a、the），对应的重要性（区分度）越低

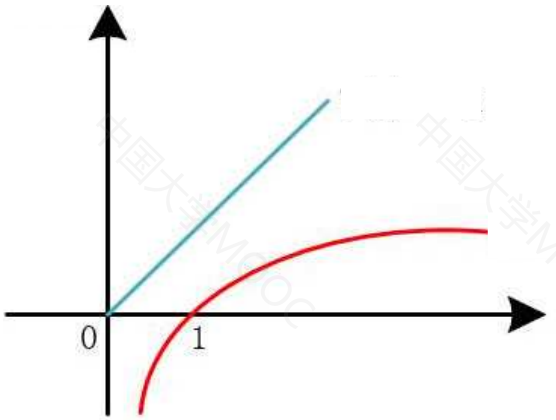
$$\mathrm{IDF}(t_i) = \log \frac{N}{n_i}$$

  - N：语料库中的文档总数；n_i：包含词t_i的文档数，即$n_i = |\{d \in D: t_i \in d\}|$

$$\mathrm{TF\text{-}IDF}(t_i, d_j) = \underbrace{\mathrm{TF}(t_i, d_j)}_{\mathrm{TF}} \cdot \underbrace{\mathrm{IDF}(t_i)}_{IDF}$$

北京大学

IDF值



- 对数函数的作用：$\mathrm{IDF}(t_i) = \log \frac{N}{n_i}$
  - 缩小IDF的绝对值范围，同时保持数值的相对关系
  - 可以缓解生僻词的影响
- 例如：$\mathrm{IDF}(t_i) = \log_{10} \frac{N}{n_i}$
  - 某语料库文档数N=10000，当n_i为10000、5000、10和1时

词	DF (n_i)	N/n_i	IDF值
t_1	10000	1	0
t_2	5000	2	0.3
t_3	10	1000	3
t_4	1	10000	4

北京大学



TF-IDF模型：示例

原始词频 （Frequency）

Frequency	d1	d2	d3	d4
car	10	40	20	0
auto	5	20	40	0
football	0	0	8	20
on	5	20	20	10

$$\mathrm{TF}(t_i, d_j) = \frac{n_{ij}}{\max_k n_{kj}}$$

	d1	d2	d3	d4
car	1	1	0.5	0
auto	0.5	0.5	1	0
football	0	0	0.2	1
on	0.5	0.5	0.5	0.5

$$\mathrm{IDF}(t_i) = \log_{10} \frac{N}{n_i}$$

	n_i	IDF
car	3	0.12
auto	3	0.12
football	2	0.30
on	4	0

$$\mathrm{TF\text{-}IDF}(t_i, d_j) = \mathrm{TF}(t_i, d_j) \cdot \mathrm{IDF}(t_i)$$

	d1	d2	d3	d4
car	0.12	0.12	0.06	0
auto	0.06	0.06	0.12	0
football	0	0	0.06	0.3
on	0	0	0	0

北京大学

模型改进

- 动机：
  - 包含所有词的文档向量表示通常会非常长并且很稀疏
- **简化词典**：去停用词、词干还原、特征选择 等
- 去停用词：
  - 停用词是指不具备文档区分度的词语，这些几乎在所有文档中都会出现
  - 例如英文中的“a”、“the”、“on”等，中文中的“了”、“的”等
- 词干还原：
  - 用单词的词干替换单词的变体，例如将“went”替换为“go”
- 特征选择：
  - 选取*n*个最具代表性的（关键）词对文本进行表示，以去掉文本中的噪声

北京大学

向量相似度度量

- 基于距离的相似度度量：

$$\mathrm{sim}(d_1, d_2) = \frac{1}{1 + \mathrm{dis}(d_1, d_2)}$$

  - 通过反比例函数揭示距离$\mathrm{dis}(d_1, d_2)$和相似性$\mathrm{sim}(d_1, d_2)$的关系

- 内积相似度：$\mathrm{sim}(d_1, d_2) = d_1^T d_2$

- 余弦相似度：$\mathrm{sim}(d_1, d_2) = \frac{d_1^T d_2}{|d_1| * |d_2|}$

