

基于内容的推荐：语义相似度

刘宏志 博士、副教授

liuhz@ss.pku.edu.cn

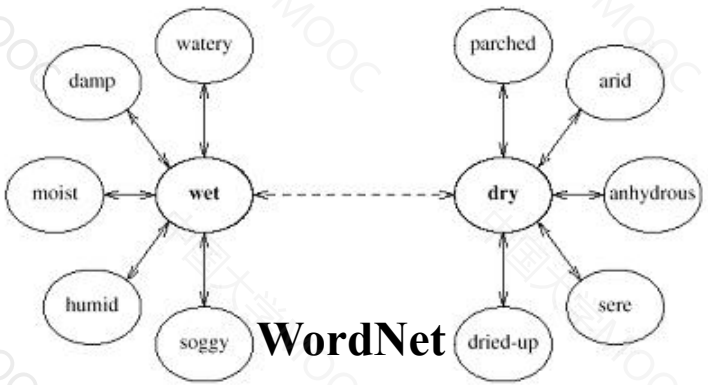
北京大学 软件与微电子学院

中国大学MOOC

基于语义的内容相似度

- 动机：
  - 基于关键词的模型虽思想简单、实现容易，但其只关注词形，忽略了词义
  - 导致无法准确地计算一些文本的相似度
  - 例如，“番茄” 和 “西红柿”，词形上完全不同，但词义相同，即语义相同
- 基于语义的文本相似度
  - 依赖于额外的语义知识
  - 基于知识库（Knowledge-Based） vs. 基于语料库（Corpus-Based）

    基于显式语义的模型 vs. 基于隐式语义（用法）的模型





百度百科



维基百科



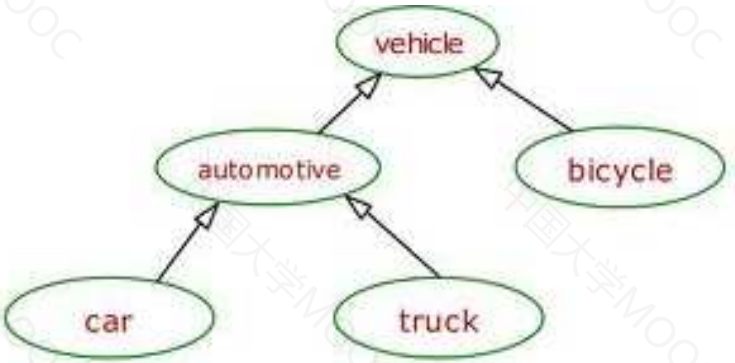
基于本体的内容相似度

- 基本思想：
  - 利用本体信息计算词与词之间的相似度 $\mathrm{sim}(w_i, w_j)$
  - 利用词语之间的相似度来计算文档之间的相似度

$$\mathrm{sim}(d_1, d_2) = \frac{\sum_{w_i \in d_1} \sum_{w_j \in d_2} \alpha_{i1} \cdot \alpha_{j2} \cdot \mathrm{sim}(w_i, w_j)}{\sum_{w_i \in d_1} \sum_{w_j \in d_2} \alpha_{i1} \cdot \alpha_{j2}}$$

α_{i1}和α_{j2}分别表示词w_i和w_j在文档d_1和d_2中的重要程度（1或TF-IDF）

- 数据源：本体库或语义信息网络
  - 本体库：相关领域词汇的基本术语和关系（同义、包含等）
  - 通用本体库：WordNet、HowNet（《知网》）等
  - 领域本体库：医疗本体库、电商本体库、地理本体库、农业本体库等



北京大学

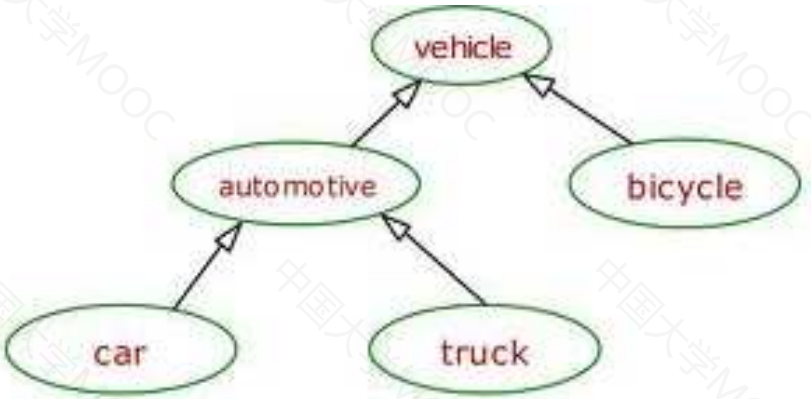
基于本体的相似度模型

- 基于本体的词与词之间的相似度 $\mathrm{sim}(w_i, w_j)$
  - 语义信息网络（本体库）中两个概念词越相近，它们的语义越相似
- 度量方法：基于最短路径

$$\mathrm{sim}_{lch}(w_i, w_j) = -\log\frac{\mathrm{length}(w_i, w_j)}{2 * D} = \log\frac{2 * D}{\mathrm{length}(w_i, w_j)}$$

$$\mathrm{sim}_{wup}(w_i, w_j) = \frac{2 * \mathrm{depth}(LCS(w_i, w_j))}{\mathrm{length}(w_i, w_j) + 2 * \mathrm{depth}(LCS(w_i, w_j))} = \frac{2 * \mathrm{depth}(LCS(w_i, w_j))}{\mathrm{depth}(w_i) + \mathrm{depth}(w_j)}$$

$\mathrm{depth}(w_i)$：概念词w_i的深度；$LCS(w_i, w_j)$：概念词w_i和w_j的最深公共子节点

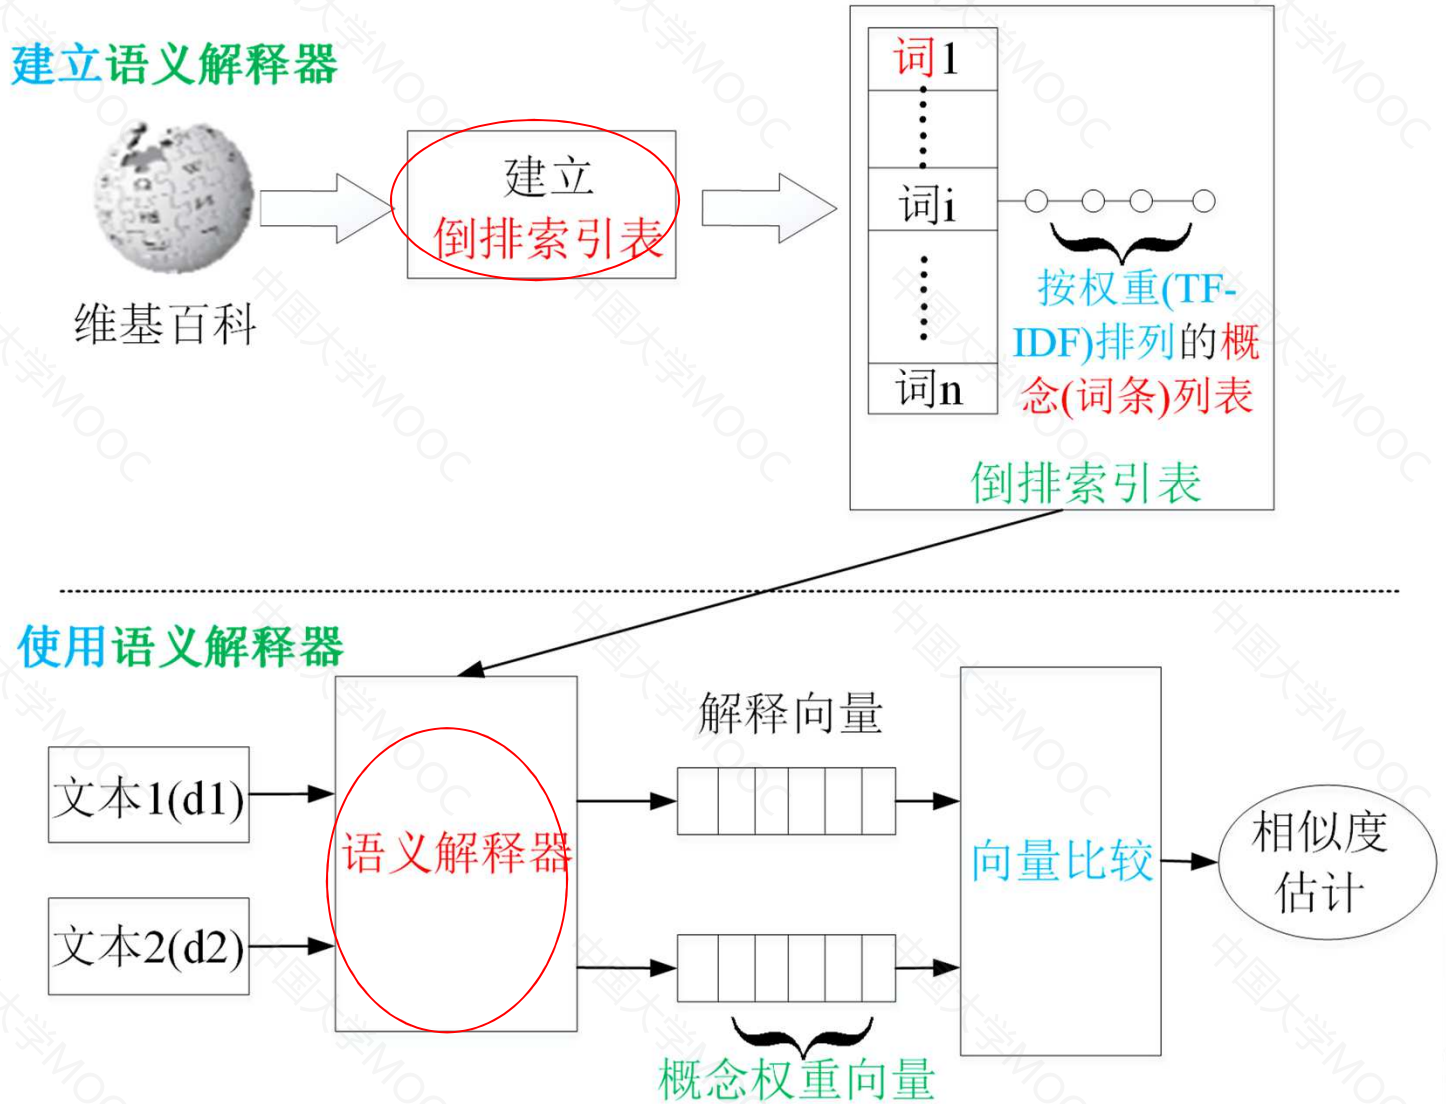


北京大学

基于网络知识的文本相似度

- 本体库或语义信息网络存在实体（本体）不全、更新速度慢等问题
- 网络知识（例如：维基百科、百度百科等）的覆盖范围更广、更新速度更快

显式语义分析(ESA)



显式语义分析ESA算法：示例

- 给定两个文档：
  - 文档一(d_1)：The dog caught the red ball. ⇒ {dog, caught, red, ball}
  - 文档二(d_2)：A labrador played in the park. ⇒ {labrador, played, park}
- 基于关键词的向量空间模型：
  - 两个文档相似度为0，因为去除停用词“the”、“a”、“in”后，两文本没有相同的词语
- 语义理解：文档d_1和d_2比较相似
  - 文档d_1描述的是“一只狗抓到了一个红球”
  - 文档d_2描述的是“一只拉布拉多狗在公园里面玩耍”
- ESA算法：将这两个文档映射到解释概念向量空间（词的概念向量的加和）

$$\mathrm{sim}(d_1, d_2) = \frac{20 * 1.1 + 4.5 * 1.2 + 5 * 1.2 + 6 * 0.5}{\sqrt{20^2 + 4.5^2 + 5^2 + 6^2} \cdot \sqrt{1.1^2 + 1.2^2 + 1.2^2 + 0.5^2}} \approx 0.7965$$

	Glossary of Cue Sports	American Football Strategy	Baseball	Boston Red Sox
d_1	20	4.5	5	6
d_2	1.1	1.2	1.2	0.5

基于语料库的文本相似度

- 动机：
  - 相比于人工网络知识库（如百度百科），语料库更容易获取，且覆盖面更为全面
- 基于点式互信息PMI的算词对（词与词之间）相似度
  - 利用词汇在语料库中的共现特征来计算词对（词与词之间）的相似度
  - 分布式假设：两个词同时出现在相同文档中的频率越高，则它们的相似度越大

$$\mathrm{PMI}(w_i, w_i) = \log_2 \frac{p(w_i \& w_j)}{p(w_i) * p(w_j)} = \log_2 \frac{c(w_i \& w_j) * N}{c(w_i) * c(w_j)}$$

$p(w_i \& w_j)$表示在语料库中词w_i和w_j同时出现在同一文档中的概率

- 基于词嵌入（embedding）的相似度：
  - 通过词的上下文得到词的向量化表示（在隐藏的语义空间中）
  - 分布式假设：一个词的语义可以根据频繁出现在它上下文的词推测出来
  - 常用模型：Word2Vec、GloVec、ELMo、BERT等

北京大学